

# 毕业设计说明书

## 基于深度学习的锂离子电池剩余寿命 预测研究与实现

学生姓名: 孙琪 学号: 1807004543

学 院: 大数据学院

专 业: 数据科学与大数据技术

指导教师: 崔方舒

2022 年 6 月

# 基于深度学习的锂离子电池剩余寿命预测研究与实现

## 摘要

锂离子电池因其优越的性能，广泛应用于众多工业领域。为了保障锂离子电池的安全性，需要对其健康状态进行监测。锂离子电池剩余寿命预测作为安全性保障中一种重要技术，国内外已有众多学者对其进行研究并取得了不错的成果。

本文应用集合经验模态分解算法对锂离子电池容量时间序列进行分解，分解后得到高频固有模态函数(Intrinsic Mode Function, IMF)分量和低频残差。其中高频 IMF 分量应用添加注意力机制的序列到序列模型建模预测，低频残差应用支持向量回归建模预测。本文中应用多种深度学习算法与该方法进行对比，包括普通的序列到序列模型和感知机模型，并与不使用集合经验模态分解的相同模型进行对比，最终应用 Python Web 框架 Django 和 Echarts 框架构建网页完成结果的展示。

本文在经过具体实验后，发现应用集合经验模态分解的方法能够显著提高模型的预测精度，其中精度最高的为添加注意力机制的序列到序列模型，它在一步预测和多步预测中均能取得误差较小的结果。

**关键词：**锂离子电池剩余寿命，注意力机制，序列到序列模型，集合经验模态分解

# Research and implementation of remaining life prediction of Lithium-ion battery based on deep learning

## Abstract

Lithium-ion batteries are widely used in many industrial fields because of their superior performance. In order to ensure the safety of lithium-ion batteries, its health status needs to be monitored. Remaining life prediction of lithium-ion batteries is an important technology in safety assurance. Many scholars at home and abroad have studied it and achieved good results.

In this thesis, the ensemble empirical mode decomposition algorithm is used to decompose the lithium-ion battery capacity time series, and the high-frequency Intrinsic Mode Function (IMF) components and low-frequency residuals are obtained after decomposition. Among them, the high-frequency IMF component is predicted by the sequence-to-sequence model with attention mechanism, and the low-frequency residual is predicted by the support vector regression model. In this thesis, a variety of deep learning algorithms are applied to compare with this method, including ordinary sequence-to-sequence model and perceptron model, and compared with the same model without ensemble empirical mode decomposition. Finally, the Python web framework Django and Echarts framework are applied to build a web page to display of the results.

After specific experiments in this thesis, it is found that the method of applying ensemble empirical mode decomposition can significantly improve the prediction accuracy of the model. The highest accuracy is the sequence-to-sequence model with attention mechanism, which can be used in both one-step prediction and multi-step prediction and get results with less error.

**Key words:** remaining life of Lithium-ion battery, attention mechanism, sequence-to-sequence model, ensemble empirical mode decomposition

## 目 录

1 绪论 .....	1
1.1 研究背景及意义 .....	1
1.2 国内外研究现状 .....	2
1.2.1 基于模型驱动方法的研究 .....	2
1.2.2 基于数据驱动方法的研究 .....	3
1.3 本文研究内容与章节安排 .....	4
2 锂离子电池容量衰退机理和容量自恢复机制 .....	6
2.1 引言 .....	6
2.2 锂离子电池容量衰退机理 .....	6
2.3 锂离子电池容量自恢复机制 .....	6
2.4 锂离子电池衰退影响 .....	7
2.5 电池容量与剩余寿命的关系 .....	8
2.6 本章小结 .....	8
3 基于 Seq2Seq Attention 的锂离子电池剩余寿命预测方法 .....	9
3.1 引言 .....	9
3.2 循环神经网络 .....	9
3.3 序列到序列模型 .....	10
3.4 注意力机制 .....	11
3.5 基于 Seq2Seq Attention 的电池剩余寿命预测 .....	12
3.5.1 模型介绍 .....	12
3.5.2 模型设置 .....	13
3.5.3 算法流程 .....	15
3.6 结果分析 .....	16
3.7 本章小结 .....	25
4 基于 EEMD、SVR 和 Seq2Seq Attention 的锂离子电池剩余寿命预测方法 .....	27
4.1 引言 .....	27
4.2 集合经验模态分解 .....	27

# 中北大学 2022 届毕业设计说明书

---

4.3 基于 EEMD、SVR 和 Seq2Seq Attention 的电池剩余寿命预测 .....	29
4.3.1 模型介绍 .....	29
4.3.2 模型设置 .....	30
4.3.3 算法流程 .....	31
4.4 结果分析 .....	32
4.5 本章小结 .....	41
5 基于深度学习的锂离子电池剩余寿命预测系统 .....	43
5.1 系统设计目的与意义 .....	43
5.2 系统总体设计 .....	43
5.3 系统展示界面 .....	44
5.3.1 集合经验模态分解结果展示界面 .....	44
5.3.2 支持向量回归残差预测结果展示界面 .....	45
5.3.3 感知机 IMF 分量预测结果展示界面 .....	45
5.3.4 序列到序列模型 IMF 分量预测结果展示界面 .....	46
5.3.5 添加注意力机制的序列到序列模型 IMF 分量预测结果展示界面 .....	47
5.3.6 模型对比结果展示界面 .....	48
5.4 本章小结 .....	49
6 总结与展望 .....	50
6.1 总结 .....	50
6.2 展望 .....	50
参考文献 .....	52
致谢 .....	54

## 1 絮论

### 1.1 研究背景及意义

电池储能系统(Battery Energy Storage System, BESS)已广泛应用于电动汽车、航空和其他相关工业领域<sup>[1]</sup>。使用电池储能系统作为电动汽车的主电源，能够减轻汽车废气对环境造成的影响<sup>[2]</sup>。由于移动手机、计算机和电动汽车等各行各业的快速发展，电池的需求大幅增长<sup>[3]</sup>。近几年，电池技术在许多领域取得突破性进展，例如能量密度和功率密度的提高<sup>[4]</sup>。电池组作为关键组件，对电动汽车的动力性能和经济性起到了决定性作用。因此，需要准确估计电池组剩余使用寿命，通过监控剩余使用寿命来提高电池组可靠性，并以此来降低成本<sup>[5]</sup>。

电动汽车依靠电池运作，而电池拥有有限的使用寿命，能量消耗很大程度上取决于电池的状态<sup>[6]</sup>。在不同种类的电池中，锂离子电池是发展最快且最具潜力的技术。锂离子电池具有众多优点，其单位体积能量高，损坏率较低且具有较高的性能<sup>[7]</sup>。保证电池的正常运行和安全运行是十分重要的事情，是众多制造商关注的核心问题<sup>[8]</sup>。

使用锂离子电池面临的问题主要是，电池经重复充放电循环之后，其工作环境会发生变化，最后导致其退化现象的发生<sup>[9]</sup>。因电池退化引起的电池容量和功率下降是不可避免的，电池多次充放电循环后，其内部工作环境发生变化，最大充放电倍率减小，容易造成过放电和过充电现象，从而产生一些安全隐患。为了更好地管理电池的运行状态，需要建立退化模型，以此来评估电池的工作状态。精确评估电池健康状态，对电池退化和老化机制进行建模，优化锂离子电池的电池设计和管理<sup>[10]</sup>。

健康状态(State Of Health, SOH)用于描述电池所处的状态是否健康，剩余使用寿命(Remaining Useful Life, RUL)用于描述电池此时距离无法正常工作的时刻还有多长的距离，这两个指标用于评估当前电池健康状态和电池性能<sup>[11]</sup>。这些指标反映了电池在运行中的实际性能，体现了锂离子电池的当前容量，并描述出退化和老化的程度，因为这些指标在很大程度上与电池退化模型有关<sup>[12]</sup>。利用健康状态和剩余使用寿命两个评价指标对电池运行状态进行描述，对其退化程度进行预测，从而保证电池的正常运行，避免危险事故的发生。利用 SOH 和 RUL 来监控潜在的退化，对实际性能进行预测<sup>[13]</sup>。

## 1.2 国内外研究现状

锂离子电池现已广泛应用于电动汽车、航空和其他相关工业领域，但随着大范围使用很多问题都暴露了出来。电池退化和老化引起电池容量和功率下降，甚至会产生一些安全隐患。基于此，为了更好的使用电池，确保其安全性和性能，国内外众多研究者和机构投入到锂离子电池剩余寿命预测的研究中。其中最著名的当属艾姆斯研究中心的卓越诊断学中心(Prognostics Center of Excellence, PCoE)，PCoE 为锂离子电池剩余寿命预测的发展贡献了巨大的力量，并发布了公共数据集供其他研究者使用。现阶段常使用的预测方法包含以下两种。

### 1.2.1 基于模型驱动方法的研究

模型驱动的 RUL 预测方法综合考虑电池多方面特征进行建模，常用的特征包含这几个，其中电池负载为电池工作时正常的输出功率，电池属性为电池构造所使用的材料蕴含的特性，衰退机理为电池衰退的原因和过程，根据这些特征进行建模，对电池剩余寿命进行预测。当前已有多种依据电化学和物理相关知识进行建模的模型，例如电化学第一原理模型，利用电化学方面的知识将电池按照各要素进行拆分考虑，最终实现对电池剩余寿命的预测方法。较为成熟的还有电化学阻抗谱模型，对电池阻抗的变化进行测量，从而对电池的腐蚀机理进行研究，最后得出电池的剩余寿命。退化机理模型、等效电路模型和经验退化模型三个模型基于不同的算法原理，从不同的角度考虑各种因素对电池进行建模分析，最后预测电池剩余寿命。

退化机理模型从电池内部的电化学反应进行考虑，分析电池在工作中内部状态的变化，以众多老化因素作为模型的变量建立衰退模型<sup>[14]</sup>。对电池的正常工作机理和衰退过程中其内外状态的改变进行研究，以此来建立衰退模型对剩余寿命进行预测。M Doyle 等人通过建立电化学第一原理模型，对锂聚合物电池容量进行建模分析，评估了电导率和转移数对电池性能的影响<sup>[15]</sup>。E.V.Thomas 等人通过建立基于退化率的物理模型，预测某个条件下的电池寿命，其中电池寿命定义为下降到某个临界水平的时间点<sup>[16]</sup>。

等效电路模型深度剖析电池工作电路，对电池工作时内外部状态进行分析，将其等效为一个电路模型，从而完成剩余寿命的预测。X Hu 等人对锂离子电池的十二个等效电路模型进行了对比研究<sup>[17]</sup>。等效电路模型将电池简化为一个电路，用电路方面的知识

对电池进行建模分析，最后利用等效电路获取电池运行状态，从而对电池剩余寿命进行预测。

经验退化模型对电池工作时内部状态在不同时刻的变化进行研究分析，寻找状态之间的联系，以此来对电池剩余寿命进行建模。主流的经验退化模型分为阻抗指数增长模型<sup>[18]</sup>和阻抗线性变参数模型<sup>[19]</sup>两类。阻抗经验退化模型通过电池在相邻时刻的阻抗传递关系得到模型外推预测结果，并利用阻抗与功率关系得到 RUL 预测结果。另一类是建立基于库仑定律的经验容量估计模型，描述相邻时刻间的容量转移关系<sup>[14]</sup>。

## 1.2.2 基于数据驱动方法的研究

锂离子电池的工作机理十分复杂，因此很难使用基于模型的方法来表示，许多研究人员开始研究数据驱动的方法。数据驱动方法不需要过多的锂离子电池相关知识背景，企图从电池历史数据中捕捉容量变化规律，以此来实现电池剩余容量的预测，因为基于数据驱动的方法不考虑电池之间的差异，具有更高的泛化性。主要应用于锂离子电池剩余使用寿命中的基于数据驱动的方法有以下几种。

自回归(Auto Regression, AR)模型具有简单和不需要额外资料的优点，通过使用系统状态过去时刻的记录值，来预测下一时刻的结果。自回归模型的一般公式如下：

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \epsilon_t \quad (1.1)$$

其中， $X_t$ 为 t 时刻系统状态的值。 $c$ 为常数项，类似于直线的截距。 $\epsilon_t$ 为平均值为 0，标准差为  $\sigma$  的随机噪声。简单来说， $X_t$  即为  $X_1$  至  $X_{t-1}$  的线性表达，之所以称为自回归，是因为传统的线性回归是将  $x$  映射到  $y$ ，而自回归模型利用  $x$  预测  $x$ 。自回归模型要求数据  $X_t$  对历史数据的相关性较高，否则自回归模型的预测精度将会很低。一般数据自相关系数小于 0.5 就无法使用自回归模型，自相关性太低说明未来数据与历史数据的相关性不高，利用历史数据对未来数据进行预测是一种不准确的方法。

人工神经网络(Artificial Neural Network, ANN)是一种由众多神经元组成的复杂网络模型，企图让计算机模拟人脑的运行，以此来实现诸多复杂的模型。人工神经网络可以轻易地拟合非线性曲线，在众多优化方法和计算机高效的计算能力加持下，拥有优秀的自学习能力。现已有众多用于时间序列分析方向的人工神经网络，其中 LSTM 和 GRU

## 中北大学 2022 届毕业设计说明书

---

是最为经典的两种算法。利用大量的过往数据训练神经网络，能够使得神经网络获得较好的泛化性，最终可用于 RUL 预测。人工神经网络的灵感来源于神经科学，利用人工神经元来模仿神经元的运行机理，以此来构造复杂的模型完成实际任务。人工神经网络分为很多不同的层，不同的层执行不同的功能，例如全连接层、卷积层、池化层等。其神经元实现不同的处理，从而构建出不同的层完成特定的工作。

支持向量回归(Support Vector Regression, SVR)通过最小化结构风险，获得全局最优解，让模型具有较好的泛化性。数据量较大时支持向量回归会无法训练，时间过长，并且支持向量回归在拟合非线性曲线时需要选取合适的核函数，较为麻烦。相比之下，使用人工神经网络要更加方便，需要考虑的因素较少。在较小的数据集上，使用支持向量回归往往会比人工神经网络取得的效果更好，泛化能力更优。

高斯过程回归(Gaussian Process Regression, GPR)模型是基于高斯过程先验的无参数模型。高斯过程回归计算开销较大，因此常用于小数据集中，大数据集运算时间过长。高斯过程回归通常结合核函数进行使用，这是因为在当前维度下数据特征可能不够明显，但通过核函数转换到另一个维度后特征变得明显，从而让高斯过程回归能够有更好的预测效果。高斯过程回归常用于低维时间序列预测问题，具有良好的预测精度，并且模型简单，不用选取超参数。

### 1.3 本文研究内容与章节安排

本文使用深度学习算法对锂离子电池剩余寿命进行预测，并结合信号处理算法进行优化。本文使用添加注意力机制的序列到序列模型对电池剩余容量进行预测，并提出使用集合经验模态分解的方法对容量时间序列进行分解的优化方法。

第一章为绪论，介绍了锂离子电池剩余寿命的研究背景及意义，并对基于模型驱动和数据驱动的两种建模方法进行了介绍。锂离子电池应用广泛，但电池的衰退现象使得电池容量持续下降，最后甚至导致安全隐患。建模对电池剩余寿命进行预测，有利于对锂离子电池的管理和应用，提高其可靠性。

第二章对电池衰退过程和容量自恢复现象进行了介绍，并从多方面对电池容量减小的原因进行了描述，并以 NASA 电池数据集为例展示了电池的容量自恢复机制，为后文算法的提出提供了理论基础。

## 中北大学 2022 届毕业设计说明书

---

第三章使用添加注意力机制的序列到序列模型对锂离子电池容量时间序列进行建模，并与长短期记忆网络和感知机进行对比分析，突出了此模型的优越性。

第四章使用集合经验模态分解和添加注意力机制的序列到序列模型对锂离子电池容量时间序列进行建模，并与第三章的模型进行对比分析。本章旨在突出经过集合经验模态分解后的容量时间序列更易预测。

第五章对文中提出的两种电池容量预测模型进行了总结分析，并指出了本文算法的不足，提出了一些能够使得预测精度更好的方法。

## 2 锂离子电池容量衰退机理和容量自恢复机制

### 2.1 引言

电池在当今时代发挥着重要的作用，生活中的方方面面都有电池的出现。电池通常以其正极所采用的材料类型或者电解质溶液命名，锂离子电池的命名即由其电池正极使用锂离子化合物材料而得名。随着长时间的使用，锂离子电池的性能会逐渐退化，最后报废。锂离子电池正常工作过程中会循环进行充放电操作，这个过程中电池内部状态会不断变化，部分未反应物堆积在电池两极，造成电池的容量下降，最后可能会引起安全隐患。因此，研究锂离子电池的衰退原因十分重要。本章通过对锂离子电池的运行原理进行分析，描述电池容量的衰退机理，并对电池容量自恢复机制进行阐述。

### 2.2 锂离子电池容量衰退机理

锂离子电池作为一种储能装置，在内部进行复杂的电化学反应产生能量，以此供应电能。随着电池不断地充电放电，电解质溶液中部分部分物质堆积在电池的两极，导致电池的性能下降，最后使得电池渐渐衰退。在电池静置一段时间后，两极附近的堆积物渐渐消散，导致电池容量小幅度增大。

锂离子电池的运行过程与内外因素均有联系，外部环境对电池内部状态产生影响，内部状态对化学反应产生电能造成影响，内部化学反应产生的物质堆积在两极，内阻增大，导致性能下降，容量衰退<sup>[20]</sup>。电池容量衰退的主要两类原因如下所示：

- (1) 外部因素包括电池外部环境温度、充放电循环次数等。
- (2) 内部因素包括 SEI 膜生长、电解液分解、锂离子电池自放电、电极活性材料损失、集流体腐蚀等。

### 2.3 锂离子电池容量自恢复机制

锂离子电池容量自恢复是指，在电池经过一段静置后，容量短暂地恢复的现象。电池的工作机理十分复杂，其寿命随着充放电循环次数的增长而逐步减小。在日常使用中，静置时间往往大于电池充放电循环时间，因此电池容量往往时增时降，但总体上仍呈下降的趋势。以 NASA 电池数据集为例，B05、B06、B07 和 B18 四个电池的容量变化曲线如图 2.1。

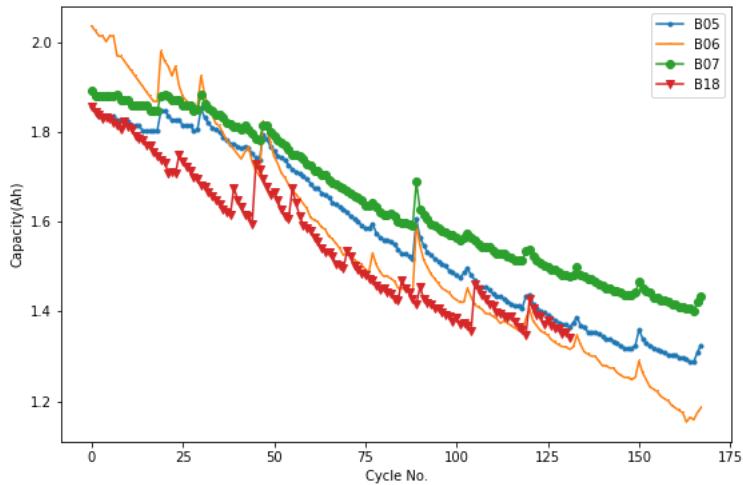


图 2.1 电池容量变化曲线

根据图 2.1 可以看出，四个电池均多次发生容量自恢复现象，可以说容量自恢复现象是一种普遍的现象，并且发生频率较高，因为静置的时间往往大于使用时间。锂离子电池在不断的充放电循环中，部分未反应物会堆积在两极附近，造成电池容量下降，但经过一段时间的静置后，两极附近堆积物会逐渐降解，使得容量短暂上升，这就是锂离子电池容量时而增加的原因。虽然静置会使得容量短暂增加，但电池在之后的运行中继续重复充放电的循环，剩余容量逐渐下降，因此上图呈总体下降的趋势。由于电池老化和容量自恢复现象，电池容量下降的曲线振荡十分严重，使用模型直接去预测往往效果较差，因此本文先采用集合经验模态分解对其进行分解，得到较为平稳的低频残差，和振荡相对较小的高频 IMF 分量，最后对其分别建模进行预测，取得了更好的预测效果。

#### 2.4 锂离子电池衰退影响

锂离子电池衰退会导致电池充放电效率变低，热稳定性下降和实际可使用容量减少，锂离子电池衰退的影响主要体现在这三个方面。

锂离子电池在正常运行中，部分未反应物会堆积在两极附近，导致电池内阻增大，可用容量下降。同时因为电池内阻增大，电池为了继续正常的运行需要释放更多的热量，因此电池温度上升，性能下降。随着电池的使用，电池中各部分的衰退程度不一，最终加剧了电池内部的不一致性，使得电池工作环境越来越不稳定。锂离子电池衰退到一定

## 中北大学 2022 届毕业设计说明书

程度后，内部内阻会变得很大，导致电池无法正常工作，工作时内部温度过高，最终导致危险的发生。随着锂离子电池衰退的发生，其最大充放电倍率会大幅下降，若不对电池管理策略进行调整，很容易造成过放电和过充电的发生，最终引发安全隐患。因此研究锂离子电池的剩余寿命预测方法十分重要，能够对电池的管理起到很好的帮助。

### 2.5 电池容量与剩余寿命的关系

电池容量能够从一定程度上反映剩余寿命，电池容量越大，往往能够使用的时间就越长，反之则越短。一般，电池寿命结束是指容量下降到初始容量的百分之七十以下，即电池无法再在保持安全的情况下正常工作。因为电池容量相较于初始容量的百分比可以反应电池当前的寿命，所以本文对电池容量进行建模预测。因此电池的剩余寿命为从当前容量下降到初始容量的百分之七十所经过的循环周期。本文所有预测方法均立足于对电池容量进行建模预测，通过预测电池容量下降到初始容量的百分之七十所需的循环周期来表征其剩余寿命。电池容量越大，说明电池工作环境正常，因此还可以正常的工作很久，距离无法正常工作还有很长一段时间。相反，电池容量越小，说明电池环境发生了异变，两极旁堆积了太多未反应物，电池内部环境不一致性增大，可能会造成过充电和过放电现象，使得电池温度急剧上升，造成安全事故。

### 2.6 本章小结

本章从内外两个方面对锂离子电池容量衰退的原因进行了介绍，环境和内部因素都会导致电池容量衰退，还对锂离子电池容量自恢复现象进行了介绍，并以 NASA 电池数据集举例展示了容量自恢复现象。在总体上，电池容量呈下降趋势，但由于容量自恢复这一内在特性，使得锂离子电池容量的变化过程呈现时增时减的现象。本章对电池容量衰退机理和容量自恢复现象进行了介绍，为后文奠定了理论基础。在本章还阐述了锂离子电池衰退会造成的影响，说明了研究锂离子电池剩余寿命预测方法对于电池管理的帮助，减少安全事故的发生。介绍锂离子电池衰退机理和容量自恢复机制，为后文提出集合经验模态分解的优化方法提供了理论基础。在本章的最后，阐述了电池容量和剩余寿命之间的关系，电池容量与剩余寿命严格正相关，因此本文采用预测电池容量的方法来替代直接预测剩余寿命。

### 3 基于 Seq2Seq Attention 的锂离子电池剩余寿命预测方法

#### 3.1 引言

本章使用添加注意力机制的序列到序列模型对锂离子电池寿命时间序列进行建模，并与普通的序列到序列模型和感知机进行对比分析。序列到序列模型是一种十分常用的时间序列预测算法，对于时间序列预测问题有着良好的表现。注意力机制能够导出电池容量时间序列中最重要的部分，让模型能够更加精确地对未来电池容量进行预测。本章对循环神经网络、序列到序列模型和注意力机制进行了详细介绍，为后文算法的介绍奠定了理论基础。通过具体的实验和评价指标，对模型的结果进行了分析，最后给出了结论。

#### 3.2 循环神经网络

循环神经网络(Recurrent Neural Network, RNN)是人工神经网络中的一个重要分支，在普通神经网络中加入了隐藏状态这一特殊机制。RNN 通过隐藏状态保存数据中的时序信息，结合时序信息和当前时刻的输入综合考虑计算出结果。作为神经网络的一种，循环神经网络也立足于数学公式之上，其前向传播公式如下：

$$a^{(t)} = b + Wh^{(t-1)} + Ux^{(t)} \quad (3.1)$$

$$h^{(t)} = \tanh(a^{(t)}) \quad (3.2)$$

$$o^{(t)} = c + Vh^{(t)} \quad (3.3)$$

$$y^{(t)} = \text{softmax}(o^{(t)}) \quad (3.4)$$

其中  $h^{(t-1)}$  为上一时刻隐藏状态， $x^{(t)}$  为这一时刻的网络输入， $U$  为对应  $x^{(t)}$  的权重矩阵， $W$  为对应  $h^{(t-1)}$  的权重矩阵， $b$  为偏置，由此计算出  $a^{(t)}$ 。再将  $a^{(t)}$  通过一个  $\tanh$  函数，计算得到  $h^{(t)}$ ，作为这一时刻的隐藏状态。将这一时刻隐藏状态  $h^{(t)}$  乘以权重矩阵  $V$ ，并加上偏置  $c$  得到  $o^{(t)}$ ，并最终通过  $\text{softmax}$  函数得到最终的这一时刻输出  $y^{(t)}$ 。此循环神经网络对应的前向传播计算图如图 3.1。

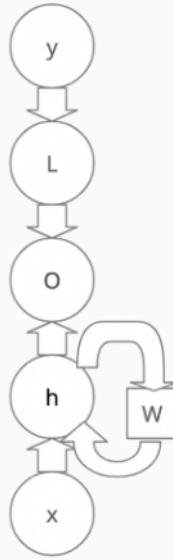


图 3.1 循环神经网络前向传播计算图

循环神经网络能够利用其特殊的机制捕捉到输入序列中所蕴含的历史信息，将其存储在隐藏状态中，结合历史信息可以使得当前时间步的输出更加的精准，使得模型整体的预测效果更好。虽然时间步的选取对循环神经网络的参数量没有影响，但是其计算无法并行，数据量较大的情况下，计算时间较长。相比之下，卷积神经网络因其独特的结构设置，很容易并行，在训练时间上会少于循环神经网络。因此，循环神经网络往往需要进行某些方面的优化，使得模型训练时间减短。

### 3.3 序列到序列模型

序列到序列模型分为编码器和解码器两部分，编码器对输入进行编码得到上下文表示，上下文表示包含了解码器输入的时序信息，结合解码器的输入送入解码器中，得到最终结果，编码器和解码器通常均为 RNN。序列到序列模型结构图如图 3.2。

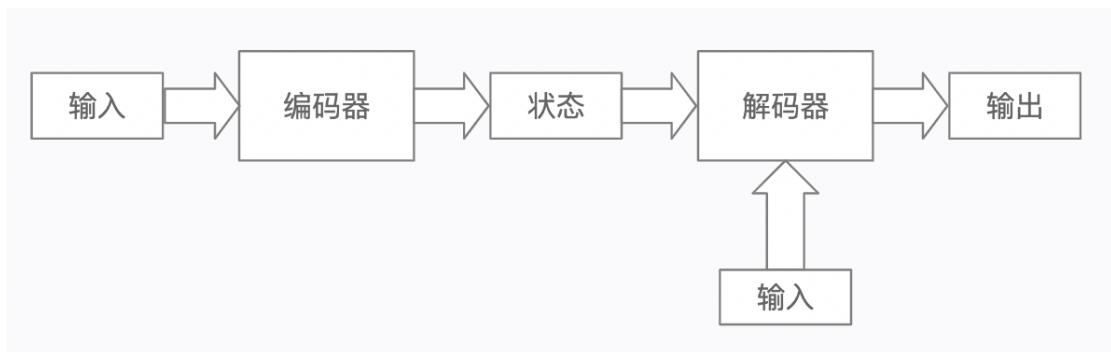


图 3.2 序列到序列模型结构图

序列到序列模型通常会输出一个小维度的向量作为上下文向量，但这种方法不能很  
第10页 共 54 页

好地表示一个较长的时间序列，因此可以引入注意力机制对模型进行优化，它能够导出较长时间序列中的重要信息，以此来让一个较短的上下文向量能够更好的表示原始数据，从而提高模型效果。

### 3.4 注意力机制

注意力机制的基础为非自主性提示和自主性提示，基于这两种提示人们会有选择性地将注意力集中在某些区域。非自主性提示是环境中某些物品的突出性，自主性提示是人主观的想要去关注某些区域。注意力机制正是基于这两种提示而创建的，非自主性提示对应注意力机制中的键，自主性提示对应注意力机制中的查询，而观察的物品则为注意力机制中的值。根据键和查询，有针对性地加大值某些区域的权重，因此更多的考虑那部分区域，使得重要的信息能够更多的提取出来。注意力机制通过设计注意力汇聚方法，将查询和键进行匹配，引导得出最匹配的值。

注意力机制中最重要的部分就是评分函数，不同的评分函数会引导出不同的值，在不同情况下可以选取不同的注意力机制算法，使得模型效果更佳。注意力机制函数  $f$  的公式如下：

$$f(q, (k_1, v_1), \dots, (k_m, v_m)) = \sum_{i=1}^m \alpha(q, k_i) v_i, \forall i \in R^v \quad (3.5)$$

其中查询  $q$  和键  $k_i$  通过评分函数  $a$  映射为标量，然后经过  $softmax$  运算后得到：

$$\alpha(q, k_i) = softmax(a(q, k_i)) = \frac{exp(a(q, k_i))}{\sum_{j=1}^m exp(a(q, k_j))} \in R \quad (3.6)$$

从上式可得，选用不同的评分函数  $a$ ，会对原始数据执行不同的注意力操作，其中常用的注意力机制算法包括加性和缩放点积两种。当查询和键是不同长度的向量时，可以使用加性注意力，其公式为

$$a(q, k) = w_v^T \tanh(W_q q + W_k k) \in R \quad (3.7)$$

其中  $w_v$ ,  $W_q$ ,  $W_k$  为模型参数， $\tanh$  为激活函数， $q$  和  $k$  分别为查询和键，对应自主性提示和非自主性提示。 $\tanh$  激活函数的公式如下：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3.8)$$

当查询和键是相同长度  $d$  的向量时，通过使用 GPU 加速点积运算，能够加快缩放

点积注意力的运算效率。缩放点积注意力的评分函数公式如下：

$$a(q, k) = \frac{q^T k}{\sqrt{d}} \quad (3.9)$$

在实际使用中，通常将数据样本划分为一个个小批量，利用 GPU 的矩阵乘法加速模型的计算，以此来提高效率，此时的公式可以写作：

$$\alpha(Q, K) = \text{softmax} \left( \frac{QK^T}{\sqrt{d}} \right) V \in R^{n \times v} \quad (3.10)$$

其中查询  $Q$  和键  $K$  的长度为  $d$ ，小批量中样本数为  $n$ ，值  $V$  的长度为  $v$ 。

注意力机制常和暂退法（Dropout）相结合，以此提高模型的泛化性。注意力机制主要有两个功能，一是决定要关注的是数据的哪部分，二是定向分配计算能力，让重要的数据能够快速地进行计算。这两个优点使得注意力机制能够广泛使用，可以添加到大部分神经网络中以提高模型效果。

### 3.5 基于 Seq2Seq Attention 的电池剩余寿命预测

#### 3.5.1 模型介绍

本章中使用的添加注意力机制的序列到序列模型、普通的序列到序列模型和感知机模型涉及到门控循环神经单元层、全连接层和暂退层。下面对这三种人工神经网络层进行介绍。

门控循环神经单元与一般的循环神经网络的区别在于前者加入了控制隐藏状态的门控机制。普通的循环神经网络会对过去所有时刻的信息进行存储，而加入门控机制的门控循环神经单元能够通过特殊的门控机制来决定是否存储当前时刻的信息，或者是否重置隐藏信息等。门控循环神经单元中最重要的组成部分为更新门和重置门，两个门控利用上一时刻的隐藏状态和当前时刻的输入计算各自的输出。重置门和更新门的计算公式如下：

$$R_t = \sigma(X_t W_{xr} + H_{t-1} W_{hr} + b_r) \quad (3.11)$$

$$Z_t = \sigma(X_t W_{xz} + H_{t-1} W_{hz} + b_z) \quad (3.12)$$

其中  $X_t$  为时刻  $t$  的门控神经单元的输入， $W_{xr}$  为输入所对应的权重矩阵，对  $X_t$  进行线性变换。 $H_{t-1}$  为时刻  $t - 1$  的隐藏状态，记录从时刻 1 到时刻  $t - 1$  的输入的历史信息， $W_{hr}$  为其对应的权重矩阵，对  $H_{t-1}$  进行线性变换， $b_r$  为其对应的偏置项，对输出进行平移，然后对整体使用 sigmoid 函数激活，得到最后重置门的输出  $R_t$ ；对于更新门，使用

## 中北大学 2022 届毕业设计说明书

相同的方法得到输出 $Z_t$ 并根据重置门的输出 $R_t$ 计算当前时刻 $t$ 的候选隐状态 $H_t^{\sim}$ 。

$$H_t^{\sim} = \tanh(X_t W_{xh} + (R_t \odot H_{t-1}) W_{hh} + b_h) \quad (3.13)$$

使用 $W_{xh}$ 权重矩阵对时刻 $t$ 的输入 $X_t$ 进行线性变换，将重置门时刻 $t$ 的输出 $R_t$ 与时刻 $t - 1$ 的隐藏状态 $H_{t-1}$ 进行按元素乘法，并通过权重矩阵 $W_{hh}$ 进行维度转换，然后使用偏置项 $b_h$ 进行平移，最后使用 $\tanh$ 函数进行激活，将所有值映射到 (-1, 1) 的区间中。

利用候选隐状态 $H_t^{\sim}$ 和当前时间步更新门输出 $Z_t$ 计算隐藏状态 $H_t$ ，公式如下：

$$H_t = Z_t \odot H_{t-1} + (1 - Z_t) \odot H_t^{\sim} \quad (3.14)$$

当更新门 $Z_t$ 接近于 1 时，模型会尽量地保存旧隐藏状态，当更新门 $Z_t$ 接近于 0 时，模型会基本上丢弃旧隐藏状态，用候选隐状态 $H_t^{\sim}$ 替代 $H_t$ 。

全连接层对数据的不同特征进行线性加权求和，从而整合出新的高级特征，利用底层特征计算高层特征，对特征进行总结，将重要的信息从底层特征中提取出来，整合为更具有概括意义的特征。

暂退层依靠于暂退法 (Dropout)，是一种正则化的方法，正则化即为给模型增加某种约束，减轻模型的过拟合现象，使得模型能够取得更低的泛化误差。详细来说，暂退法通过指定概率随机选取神经元失活，使得每次运行的模型都不一样，类似于多个模型的集成。暂退法能够很好地对模型容量进行控制，使得模型难以过拟合，暂退法以概率 $p$ 使得单元输出置为 0，使得模型不过分依赖于某些特征，能够综合地考虑所有特征，从而减轻模型过拟合现象的发生。

暂退法计算十分方便，按指定概率生成与神经元相同数量的 0 和 1，其中生成 0 的概率为 $p$ ，生成 1 的概率为 $1-p$ ，更新的时间消耗与神经元数量呈线性关系。暂退法不会对模型的结构和训练过程造成影响，在大部分人工神经网络中均可取得不错的效果。暂退法按照指定概率随机让神经元失活，使得模型每次运行均为不同的模型，对模型实行了严格的约束，缓解了模型的过拟合现象的发生。正则化的使用通常需要多方面进行考虑，数据集过大时正则化带来的收益太小，而计算代价却很大，因此需要就实际问题考虑是否要引入暂退法作为正则化手段。

### 3.5.2 模型设置

本章中使用添加注意力机制的序列到序列模型、普通的序列到序列模型和感知机模

## 中北大学 2022 届毕业设计说明书

型对电池容量时间序列进行建模预测，其中第一个模型的参数设置如下。

首先对数据进行处理，处理为可以传入神经网络的形式，其维度为[小批量样本数，时间步长度，特征数]，其中批量数选为 32，时间步长度选为 30，特征数为 1。首先使用拉伸层(Flatten)将数据维度修改为[小批量样本数，时间步长度乘以特征数]，此处为[32, 30]。随后使用线性层(Linear)对数据进行线性映射，此层输出维度为[小批量样本数，隐藏层输出数]，此处为[32, 8]。此层之后，使用线性整流层(ReLU)，对线性层的输出进行激活。最后使用线性层完成结果的预测，输出维度为[小批量样本数，1]，此处为[32, 1]。

编码器使用输入维度 1，输出维度为 `num_hiddens`，层数为 `num_layers`，丢弃率为 `dropout` 的 GRU 层，其中 `num_hiddens` 选为 8，`num_layers` 选为 2，`dropout` 为 0.1。先使用 `permute` 将编码器输入 X 进行维度顺序调换，将时间步维度切换到第一维，然后让数据通过 GRU 层，得到输出和隐藏状态。解码器首先是一层 GRU 层，输入维度为 `embed_size+num_hiddens`，输出维度为 `num_hiddens`，层数为 `num_layers`，丢弃率为 `dropout`，其中 `embed_size` 为 1，`num_hiddens` 为 8，`num_layers` 为 2，`dropout` 为 0.1。首先利用 `permute` 函数将解码器输入的维度进行调换，将时间步调为第一维度。结合编码器的隐藏状态与解码器输入进行综合考虑，将调换维度后的解码器输入与编码器隐藏状态在第三维上进行连接，将其作为输入通过 GRU 层。接下来使用全连接层对输入进行维度转换，将其转换为第三维度为 1 的张量，然后在第二维度上进行求平均运算，最后得到预测结果。

在解码器添加注意力机制能够对编码器的隐藏状态中所蕴含的时序信息进行提取，提取编码器输出中最重要的信息。加性注意力包括三个全连接层，利用全连接层  $W_k$  和  $W_q$  将键和查询转换为在第三维度上相等的数据，然后将其结果相加并通过  $\tanh$  函数将值拉到 (-1, 1) 的范围内，最后将结果输入到全连接层进行维度转换，并对其进行线性映射。输出通过 softmax 函数，取得值对应的评分，评分通过 Dropout 层，丢弃率选为 0.1，得到 Dropout 层输出后，将其与值在批量维度上进行矩阵乘法，得到最后加性注意力的输出。

### 3.5.3 算法流程

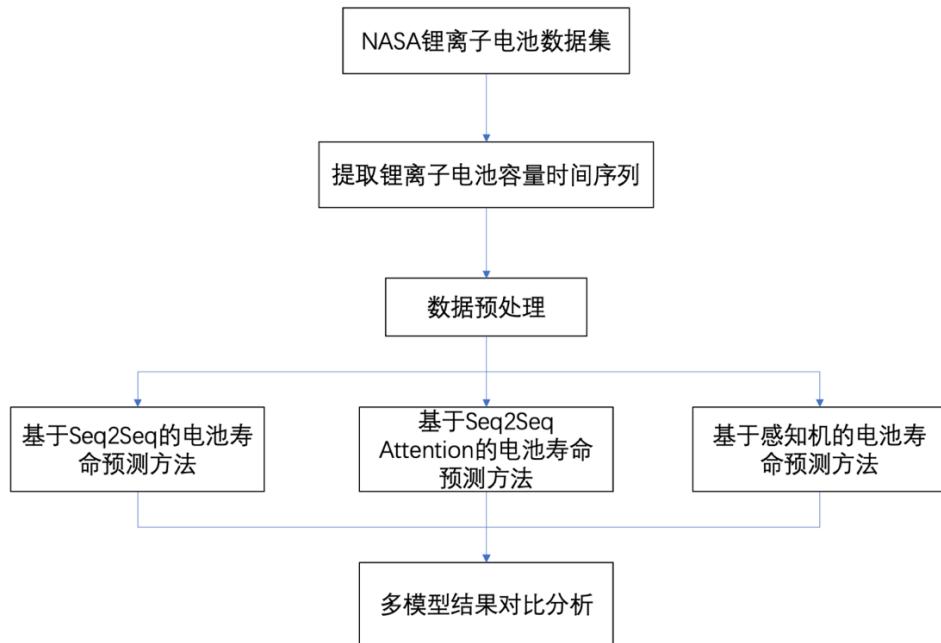


图 3.3 算法流程图

基于 Seq2Seq Attention 的锂离子电池剩余寿命预测方法流程图如图 3.3，详细步骤流程如下。

第一步，对原始 NASA 锂离子电池数据集进行操作，提取出锂离子电池容量时间序列。

第二步，对时间序列进行数据预处理操作，加载为可输入到模型中的形式。输入模型的电池容量时间序列的维度应为[小批量样本数，时间步长度，特征数]，在此文中选取时间步为 30，小批量样本数为 32，特征数为 1。利用 numpy 和 torch 完成数据的处理，加载为 torch.utils.DataLoader 类型的数据，最后对其进行训练集和测试集的划分。

第三步，选取适当的超参数进行建模，超参数包括隐藏层输出维度，学习率，训练迭代次数，暂退层丢弃率等。利用选定后的超参数建立添加注意力机制的序列到序列电池容量预测模型并使用训练集进行训练，绘制训练损失值变化曲线，若非正常下降，则重新选取合适的超参数重新训练，直至损失正常下降。

第四步，检验训练后的模型在测试集上的效果，使用平均绝对误差和均方根误差作为评价指标对电池剩余寿命预测模型预测精度进行评价，并绘制单步和多步预测曲线图，与实际容量变化曲线进行对比。

第五步，将第三步中的模型更换为感知机模型和序列到序列模型，对新模型进行训练，最终分别使用此三个模型对电池剩余容量进行预测，并将容量预测结果依据评价指标进行对比分析。

两个容量预测模型评价指标的计算公式如下：

$$MAE(x, y) = \frac{1}{n} \sum_{i=1}^n |x_i - y_i| \quad (3.15)$$

$$RMSE(x, y) = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2} \quad (3.16)$$

其中  $n$  为数据中样本的数目， $x_i$  为第  $i$  个样本的真实电池容量， $y_i$  为第  $i$  个样本的预测电池容量。

$MAE$  和  $RMSE$  的大小能够评价电池容量预测模型的好坏，这两个评价指标越小说明模型预测得到的容量与真实数据相差无几，能够准确地对电池容量进行预测。反之则说明模型预测得到的容量与真实数据差距较大，无法正确地对电池容量进行预测。

### 3.6 结果分析

使用 3.5 节中的方法对电池容量进行建模预测，首先将预测起点定为 100，分别绘制单步预测曲线和实际曲线，并对三个模型的电池容量预测结果进行对比分析。

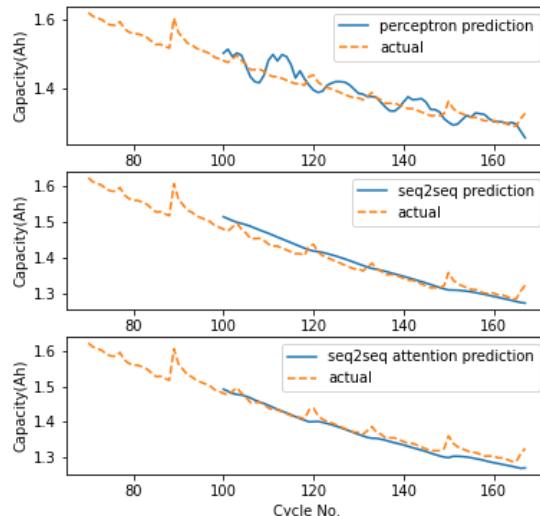


图 3.4 B05 电池容量单步预测结果

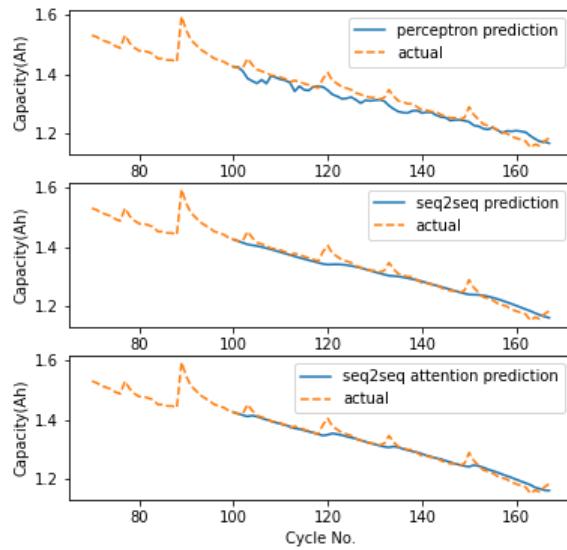


图 3.5 B06 电池容量单步预测结果

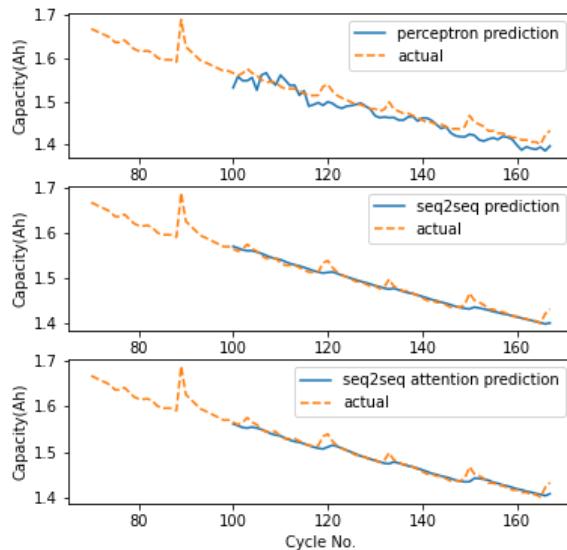


图 3.6 B07 电池容量单步预测结果

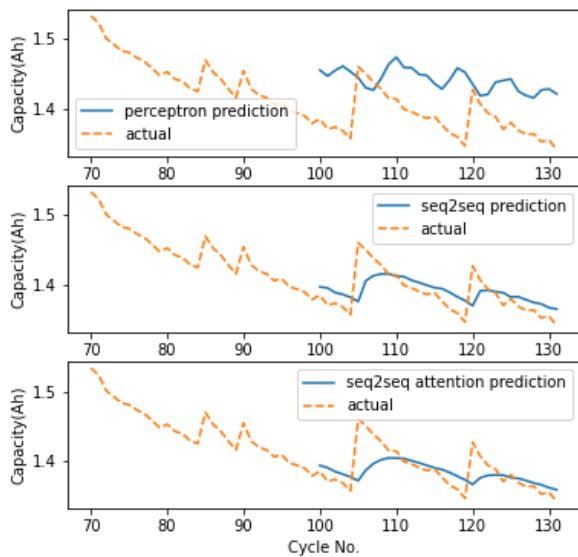


图 3.7 B18 电池容量单步预测结果

由图 3.4 至图 3.7 可以看出,这三个模型中只有感知机对容量自恢复感知比较敏感,在尝试捕捉容量自恢复,而其他两个模型几乎没有去尝试捕捉这个变化,因此在第四章中我们引入信号分解算法,尝试去分解信号,让多个模型去拟合这种变化,最后集合到一起得到预测结果。整体上看,序列到序列模型和添加注意力机制的序列到序列模型都表现得不错,具有一定的实用性能。四个电池中 B18 的预测效果较差, B18 的电池自恢复现象幅度比较大,导致模型预测结果较差。这说明这三个模型中虽然感知机模型能够感知这个现象,但是都无法很好地对容量自恢复现象造成的影响完成预测。

## 中北大学 2022 届毕业设计说明书

表 3.1 单步预测结果

电池序号	模型	MAE	RMSE
B05	Perceptron	0.023991	0.030135
B05	Seq2Seq	0.01478	0.018519
B05	Seq2Seq Attention	0.013427	0.018079
B06	Perceptron	0.020421	0.026323
B06	Seq2Seq	0.01243	0.017914
B06	Seq2Seq Attention	0.009539	0.014909
B07	Perceptron	0.020113	0.023298
B07	Seq2Seq	0.007786	0.009858
B07	Seq2Seq Attention	0.007313	0.011742
B18	Perceptron	0.057456	0.063279
B18	Seq2Seq	0.01913	0.025362
B18	Seq2Seq Attention	0.018719	0.026931

由表 3.1 结果可以看出, 容量预测结果最好的是添加注意力机制的序列到序列模型, 预测精度略高于原始模型。序列到序列模型是一个效果还不错的时间序列预测算法, 同时添加注意力机制能够优化其预测精度, 使得模型效果更好。感知机模型相较于序列到序列模型缺少隐藏状态, 因此不会保存过去的历史信息, 而序列到序列模型结合历史信息与当前时间步的输入, 综合考虑最后对当前容量进行预测, 因此具有更好的效果。而添加注意力机制后, 模型能够更高效地找出输入数据中最重要的部分, 以此来对容量进行预测。

为了比较模型的多步预测能力, 仍然将预测起点定为 100, 分别绘制 5 步预测曲线和实际曲线, 结果图如图 3.8 至图 3.11。

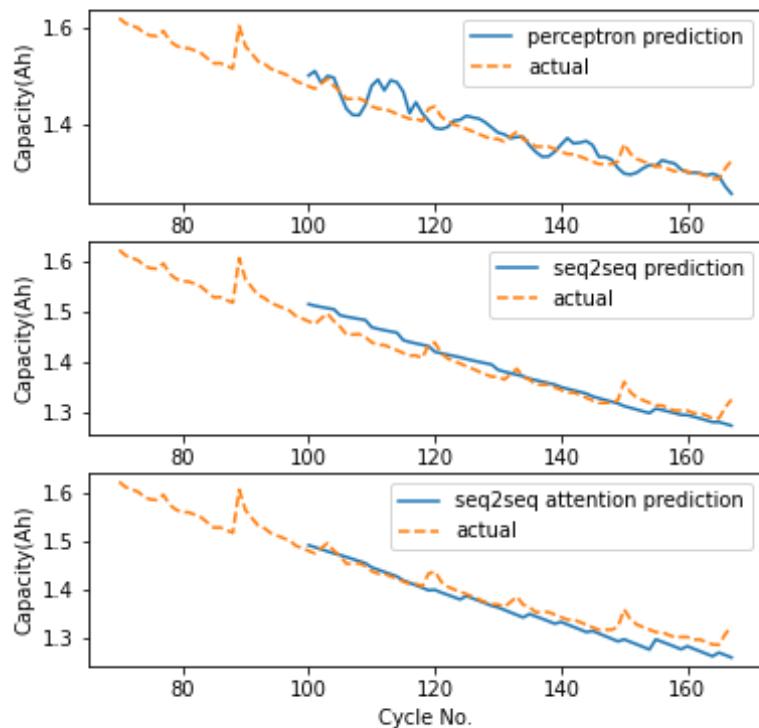


图 3.8 B05 电池容量 5 步预测结果

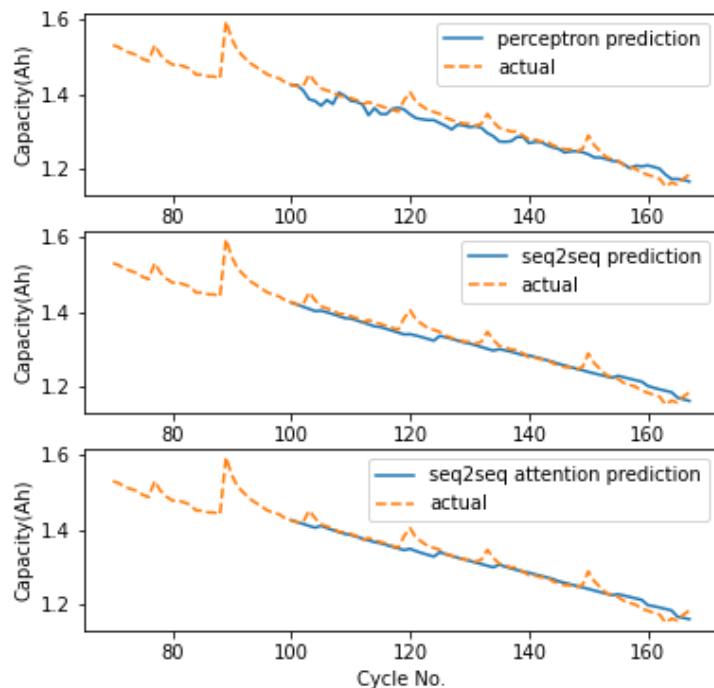


图 3.9 B06 电池容量 5 步预测结果

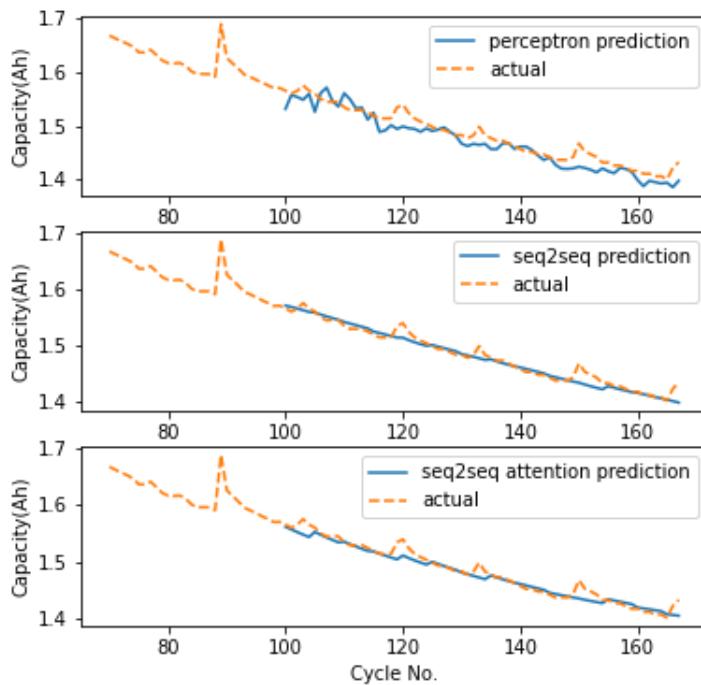


图 3.10 B07 电池容量 5 步预测结果

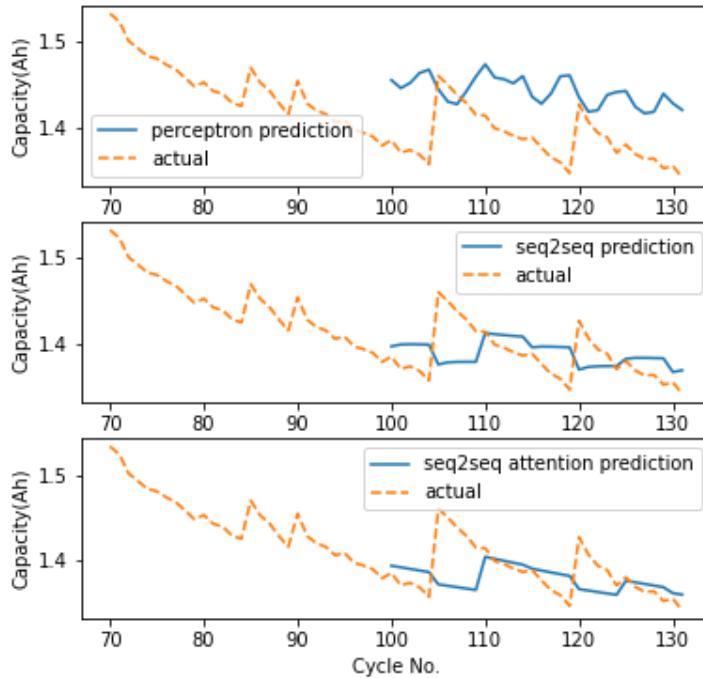


图 3.11 B18 电池容量 5 步预测结果

由图 3.8 至图 3.11 可以看出，5 步预测情况下，除感知机模型外的两个模型还是能  
第21页 共 54 页

## 中北大学 2022 届毕业设计说明书

够很好地对电池容量进行预测，感知机模型则有点无法正确预测电池容量，但两个模型都无法较好地把握电池自恢复现象带来的变化。序列到序列模型在 5 步预测中仍然能取得不错的效果，添加注意力机制依然可以使得效果更佳。

表 3.2 5 步预测结果

电池序号	模型	MAE	RMSE
B05	Perceptron	0.022201	0.028139
B05	Seq2Seq	0.016792	0.020742
B05	Seq2Seq Attention	0.016965	0.021927
B06	Perceptron	0.018065	0.023999
B06	Seq2Seq	0.014149	0.019785
B06	Seq2Seq Attention	0.011653	0.01748
B07	Perceptron	0.017079	0.019944
B07	Seq2Seq	0.009281	0.01132
B07	Seq2Seq Attention	0.009165	0.01378
B18	Perceptron	0.058699	0.065231
B18	Seq2Seq	0.028622	0.034729
B18	Seq2Seq Attention	0.025315	0.034638

由表 3.2 得出，在 5 步预测下，添加注意力机制的序列到序列模型仍然能取得较小的平均绝对值误差和均方根误差，这说明此模型对于多步预测也有着不错的精度，但与不添加注意力机制的模型的差距较小。5 步预测中，预测误差会一步步进行积累，最后导致预测结果与原始数据差距加大，因此 5 步预测的平均误差要大于单步预测。

接下来将预测起点定为 100，分别绘制 10 步预测曲线和实际曲线，结果图如图 3.12 至图 3.15。

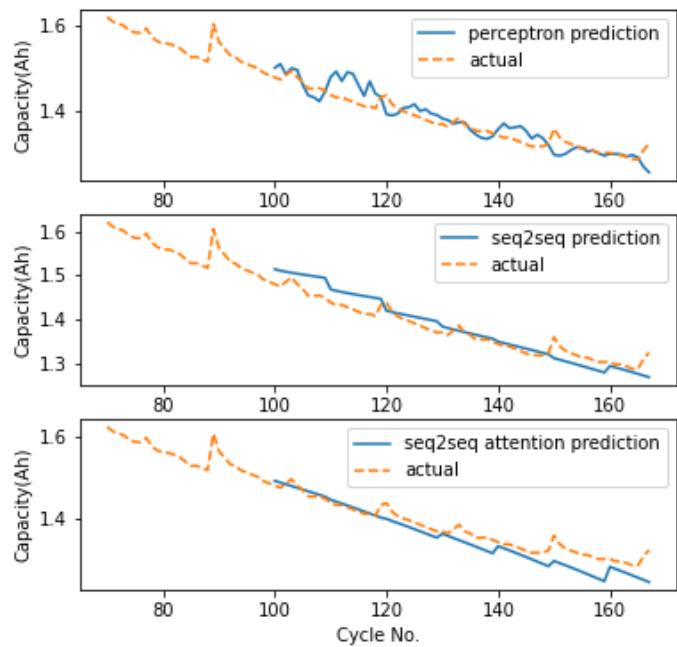


图 3.12 B05 电池容量 10 步预测结果

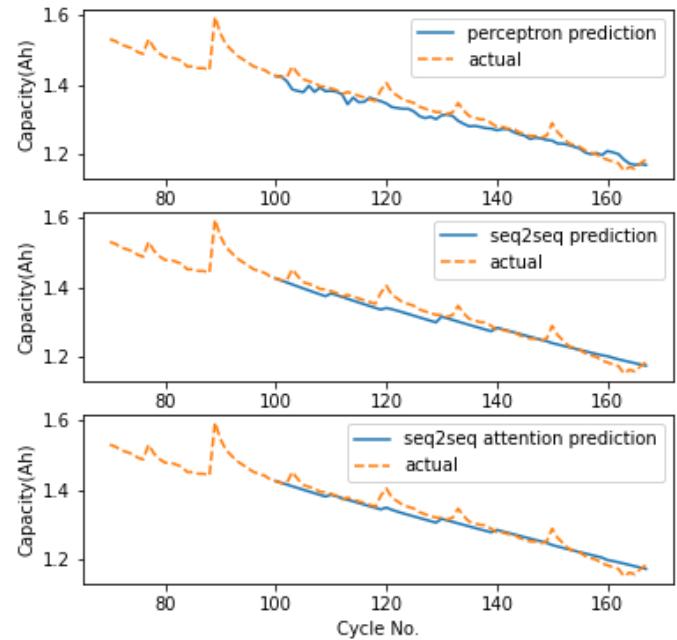


图 3.13 B06 电池容量 10 步预测结果

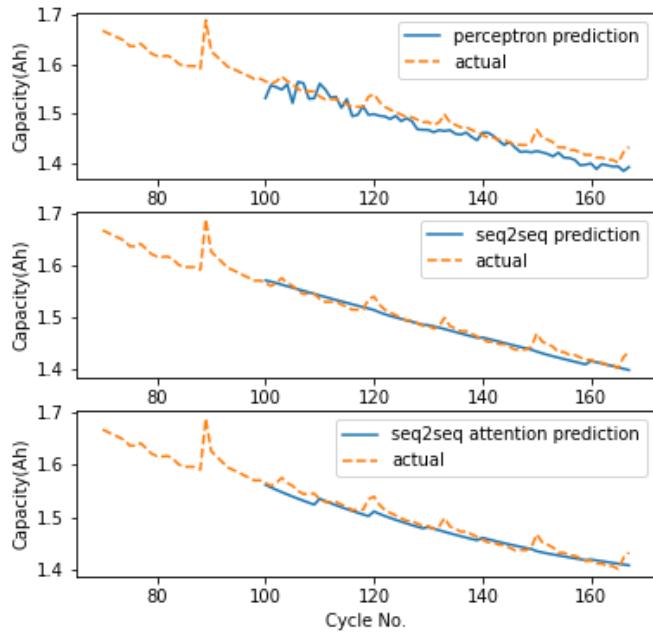


图 3.14 B07 电池容量 10 步预测结果

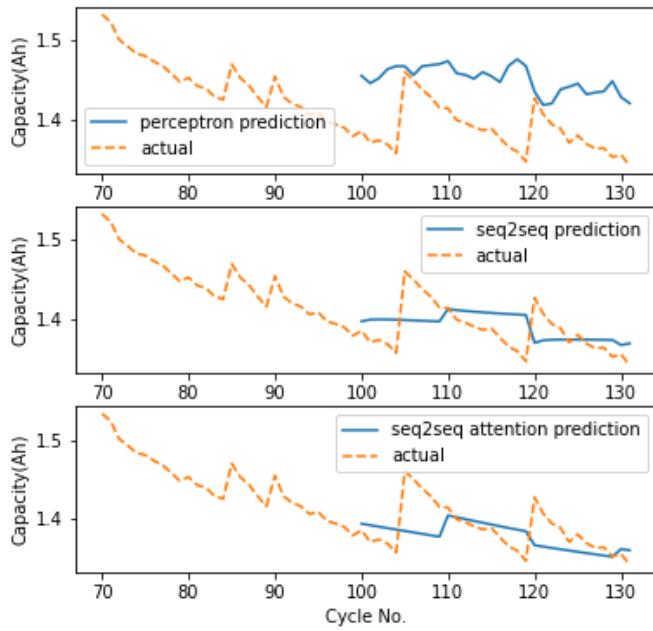


图 3.15 B18 电池容量 10 步预测结果

由图 3.12 至图 3.15 可以看出，十步预测时后两个模型仍然能够较为准确地进行容量预测，这说明这两个模型对于多步预测仍有着不错的精度，有着预测未来容量变化的

## 中北大学 2022 届毕业设计说明书

能力，隐藏状态可以保存上一时间步的信息，供下一次计算输出时使用，因此序列到序列模型能够很好地处理时间序列预测问题，无论是单步预测还是多步预测都有着不错的效果。

表 3.3 10 步预测结果

电池序号	模型	MAE	RMSE
B05	Perceptron	0.021245	0.027897
B05	Seq2Seq	0.020193	0.024453
B05	Seq2Seq Attention	0.021973	0.027416
B06	Perceptron	0.018098	0.023605
B06	Seq2Seq	0.016516	0.021419
B06	Seq2Seq Attention	0.013783	0.018415
B07	Perceptron	0.017927	0.021327
B07	Seq2Seq	0.009311	0.011608
B07	Seq2Seq Attention	0.01223	0.01616
B18	Perceptron	0.064278	0.070963
B18	Seq2Seq	0.026012	0.030846
B18	Seq2Seq Attention	0.024169	0.031298

由表 3.3 得出，10 步预测下平均绝对值误差和均方根误差显著增大，这是因为多步预测下，误差累计积累，最后导致误差显著增大。10 步预测情况下，添加注意力机制并没有使得模型效果更好，这说明多步预测的情况下，注意力机制没有很好地把握最重要的信息，最终导致三个模型的结果误差较小，都呈比较高的数值。

### 3.7 本章小结

本章首先对循环神经网络的基础知识和特殊机制进行了介绍，在此基础上，又介绍了序列到序列模型，其分为编码器和解码器，编码器对输入进行编码，得到上下文表示，并结合解码器输入作为额外信息输入到解码器中，得到预测结果。在此之后，还介绍了注意力机制，注意力机制的灵感来源于人类本身的行为，人的注意力分为非自主性提示

## 中北大学 2022 届毕业设计说明书

---

和自主性提示，在注意力机制中，自主性提示作为查询，非自主性提示作为键，待查询的东西作为值，结合查询和键，导出最佳匹配值。本章的最后使用添加注意力机制的序列到序列模型对电池容量时间序列建模预测，并结合多个精度评价指标进行了评价，将其与感知机模型和序列到序列模型进行对比分析。序列到序列模型无论是在单步预测还是多步预测中，都有着良好的表现，添加注意力机制优化后模型的精度得到了小幅度提升。

## 4 基于 EEMD、SVR 和 Seq2Seq Attention 的锂离子电池剩余寿命预测方法

### 4.1 引言

本章使用集合经验模态分解算法将电池容量时间序列分解为高频 IMF 分量和低频残差，再对分解后的不同频率的数据分别建模预测。高频分量（IMF）使用 Seq2Seq Attention 进行建模，低频残差（Residual）使用支持向量回归（Support Vector Regression, SVR）进行建模预测。考虑到电池容量自恢复机制，这种方法相较于不使用信号分解算法更加好，对于不同频率的信号使用不同的模型建模预测，最后整合到一起作为预测结果，能够得到更好的预测结果。

### 4.2 集合经验模态分解

集合经验模态分解通过把握信号内部特征对原始信号进行局部平稳，将高频的信号分解为多个频率较原始信号低的信号，最后通过将分解后的信号加和可以完成对原始信号的重构。信号经分解后分为残差和多个分量，残差存储了信号的总体变化趋势，多个分量则在 0 的上下不停变化，不停下降和上升。集合经验模态分解对各种时间序列及信号都有不错的分解效果，尤其是非线性，抑或是非平稳时间序列均可，能够将原始信号分解为低频残差和高频 IMF 分量，残差为单调序列或常值序列。

在研究经验模态分解的基础上，通过添加白噪声来缓解模态混叠的现象，这种方法叫做集合经验模态分解。经验模态分解将初始信号分解为多个频率不一的分量，这些分量蕴含了不同时间维度的信息，通过将这些分量进行线性求和，可以重构出初始信号。

经验模态分解的算法步骤如下：

(1) 首先，找出原始信号  $w(t)$  的所有极大值和极小值，使用三次样条插值法生成上、下包络线  $l_1(t)$  和  $l_2(t)$ ，则均值包络线  $m_1(t)$  的公式为：

$$m_1(t) = \frac{1}{2}(l_1(t) + l_2(t)) \quad (4.1)$$

(2) 从原始信号  $w(t)$  中剔除掉  $m_1(t)$ ，得到第一向量  $h_1(t)$ ，其公式如下：

$$h_1(t) = w(t) - m_1(t) \quad (4.2)$$

如果  $h_1(t)$  不满足 IMF 分量条件，则将  $h_1(t)$  当作新的  $w(t)$ ，重复操作 1 和操作 2，

## 中北大学 2022 届毕业设计说明书

假设直到  $k$  次计算后满足条件，则第一个 IMF 分量表示为：

$$h_{1k}(t) = h_{1k-1}(t) - m_{1k}(t) \quad (4.3)$$

(3) 将第一个 IMF 分量  $h_1(t)$  从原始信号  $w(t)$  中剔除出去，然后重复操作 1 到操作 3，直到最后剩余部分满足单调或常值序列，剩余部分称作为残差。

经分解后的原始信号  $w(t)$  就分解为了许多 IMF 分量和残差  $r_n$  的和。

$$w(t) = \sum_{i=1}^N h_i(t) + r_n(t) \quad (4.4)$$

通过引入白噪声和集合平均操作，集合经验模态分解缓解了模态混叠现象，使得分解后的分量之间尺度更加清晰，各个分量蕴含着不同时间尺度的数据。集合经验模态分解的算法步骤如下：

- (1) 向初始信号  $w(t)$  中添加固定振幅的白噪声  $\epsilon(t)$ 。
- (2) 对经操作后的信号进行经验模态分解，得到高频 IMF 分量和低频残差。
- (3) 多次重复操作 1 和操作 2，以此得到多组结果。
- (4) 对各组结果进行集合平均，从而消除固定振幅白噪声的影响，得到最终的分解结果。

集合经验模态分解通过添加白噪声，解决了经验模态分解的部分缺点，是经验模态分解之上一个更佳的选择。经过集合经验模态分解后，原始信号分解为了低频残差和高频 IMF 分量，残差为单调序列或常值序列，对于电池容量时间序列而言，分解后的残差为单调下降曲线，这是因为电池容量在总体上是呈下降趋势的，随着使用和时间的流逝，容量一步步减小，最终报废。但是由于容量自恢复现象的发生，电池容量会呈波动下降，所以使用集合经验模态分解能够把自恢复部分给提出来，以 B05 为例，经分解后的低频残差和高频 IMF 分量如图 4.1 所示。

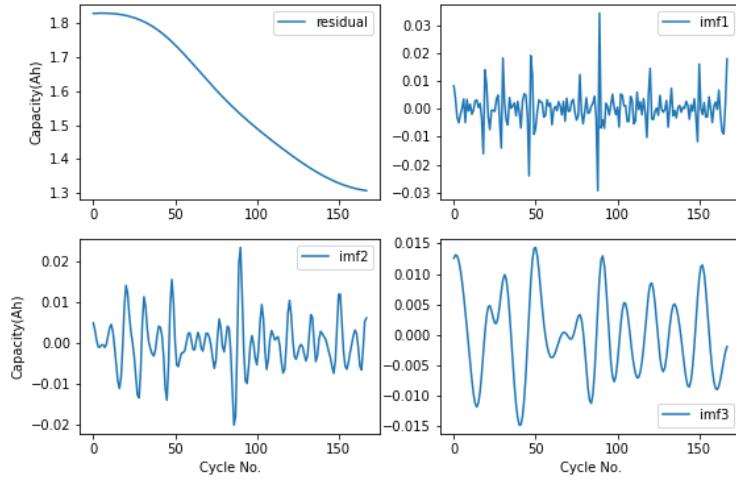


图 4.1 B05 电池容量时间序列 EEMD 分解图

由图 4.1 可以看出，残差蕴含了原始信号的整体变化趋势，呈下降趋势。IMF 分量均为有规律的振荡曲线，振荡程度相较于原始信号要低，更适合建模预测。IMF 分量反映了容量自恢复造成的影响，将其从原始信号中分解出来，可以使用添加注意力机制的序列到序列模型进行建模预测，相较于直接进行建模预测效果会更好。

### 4.3 基于 EEMD、SVR 和 Seq2Seq Attention 的电池剩余寿命预测

#### 4.3.1 模型介绍

本章相较于第三章方法新引入了支持向量回归，作为低频残差部分的预测方法。支持向量回归结合支持向量机的思想，利用支持向量的原理来解决线性回归问题。支持向量回归的优化目标为：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (4.5)$$

其中  $w$  为支持向量回归直线的权重向量， $b$  为其对应的偏置项。

其中位于间隔带内的点满足以下条件：

$$|y_i - (wx_i + b)| \leq \epsilon \quad (4.6)$$

支持向量回归的代价函数为：

$$\sum_{i=1}^m l_\epsilon(f(x_i), y_i) \quad (4.7)$$

其中

$$l_\epsilon(z) = \begin{cases} 0, & \text{if } |z| \leq \epsilon \\ |z| - \epsilon, & \text{otherwise} \end{cases} \quad (4.8)$$

最终支持向量回归优化问题可以写作：

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m l_\epsilon(f(x_i), y_i) \quad (4.9)$$

支持向量回归常和核函数结合使用，用作拟合非线性函数，因此结合核函数，支持向量回归能够灵活地拟合非线性函数。使用不同的核函数能够达到不同的效果，实际应用中需要就具体问题选择特定的核函数，常用的有线性核和高斯核等。

#### 4.3.2 模型设置

本章使用支持向量回归对经集合经验模态分解后的低频残差进行建模预测，使用添加注意力机制的序列到序列模型、普通的序列到序列模型和感知机模型对分解后的高频 IMF 分量进行建模预测。

感知机模型输入数据维度为[小批量样本数，时间步长度，特征数]，其中小批量样本数为 32，时间步长度为 30，特征数为 1。首先使用拉伸层将输入进行拉伸，拉伸后的数据维度为[32, 30]。拉伸后的数据通过全连接层映射为[32, num\_hiddens]的输出，此处 num\_hiddens 为 8。输出使用线性整流层（ReLU）进行激活，ReLU 能够将输入中的负数置为 0，从而完成非线性转换，最后模型整体的输出维度为[32, 1]。

序列到序列模型编码器仅为单层模型，使用 GRU 层提取编码器输入的信息，输入维度为 1，输出维度为 num\_hiddens，此处定为 8，模型层数 num\_layers 定为 2，丢失率 dropout 定为 0.1。首先将编码器输入维度顺序进行转换，将时间步维度更改为第一维度，然后通过 GRU 层计算出 GRU 层输出和隐藏状态，隐藏状态中包含了编码器输入中的历史信息。解码器包含 GRU 层和全连接层两层，GRU 层的输入维度为 embed\_size + num\_hiddens，其中 embed\_size 和 num\_hiddens 分别为 1 和 8，输出维度为 num\_hiddens，num\_hiddens 为 8，层数 num\_layers 为 2，丢失率 dropout 选定为 0.1。全连接层的输入维度为 num\_hiddens，num\_hiddens 选为 8，输出维度为 1。将编码器输出作为解码器隐藏状态的初始值，解码器输入传入解码器后，首先将其转换为时间步为第一维度的数据形式，然后结合隐藏状态作为整体，输入到 GRU 层中，得到 GRU 层的输出和新的隐藏状态。GRU 层的输出作为全连接层的输入传入全连接层中，全连接层的输出转换维度顺

序，将时间步转换回第二维度，最后沿第二维度求平均，作为最后的模型输出。

添加注意力机制的序列到序列模型在普通序列到序列模型的基础上，添加了加性注意力，通过加性注意力筛选编码器输出中重要的部分。加性注意力中包括三个全连接层和一个暂退层，三个全连接层分别叫做 $W_k$ 、 $W_v$ 和 $W_q$ 。 $W_k$ 的输入维度为 key\_size，key\_size 选定为 30，输出维度为 num\_hiddens，num\_hiddens 选定为 8，不需要偏置项。 $W_q$ 的输入维度为 query\_size，query\_size 选定为 30，输出维度为 num\_hiddens，num\_hiddens 选定为 8，不设置偏置项。 $W_v$ 的输入维度为 num\_hiddens，num\_hiddens 选定为 8，输出维度为 1，不设置偏置项。利用 $W_k$ 和 $W_q$ 对键和查询进行线性映射，将其转换为第三维度大小相同的数据，将转化后的数据相加，得到后的结果通过 tanh 函数进行激活，将值映射到(-1, 1)之中。最后通过 $W_v$ 将输出映射为与值 values 相同维度的矩阵，称作评分 scores。对评分 scores 在最后一维进行 softmax 函数操作，将评分中所有值映射到 (0, 1) 之间，然后将输出通过暂退层进行正则化，作为最终的评分。将最终的评分与值在批量维度上执行矩阵乘法，获得最终的输出。

#### 4.3.3 算法流程

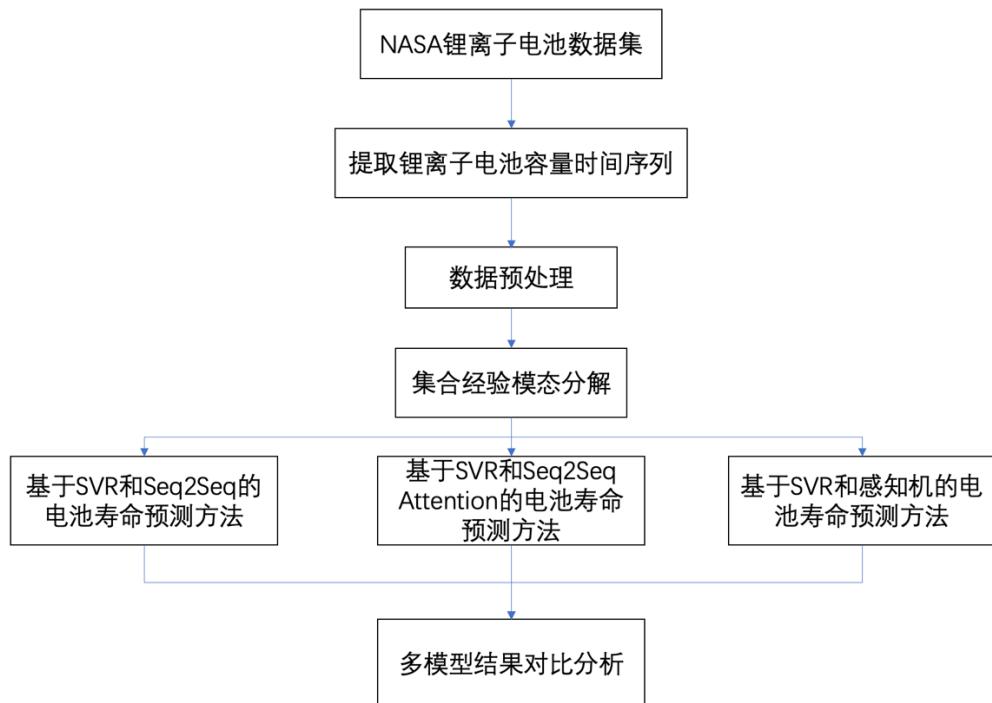


图 4.2 算法流程图

基于 EEMD、SVR 和 Seq2Seq Attention 的锂离子电池剩余寿命预测方法流程图如

图 4.2，其步骤流程为：

第一步，对 NASA 锂离子电池数据集进行操作，提取锂离子电池容量时间序列。

第二步，对数据进行预处理，并使用集合经验模态分解对电池容量时间序列进行分解，分解得到低频残差和高频 IMF 分量。由于电池自恢复效应的影响，电池容量会随着搁置而暂时恢复，造成电池容量时间序列时增时减。使用集合经验模态分解后能够将电池容量时间序列的总体变化趋势（残差）提取出来，剩下的部分为多个频率低于原始信号的 IMF 分量。

第三步，选用支持向量回归对低频残差时间序列建模预测，并选用添加注意力机制的序列到序列模型对高频 IMF 分量建模预测。支持向量回归可以很好地拟合单调函数，残差曲线中容量近似呈线性下降，可以选用线性核的支持向量回归进行建模预测。分解得到的几个 IMF 分量，都是在 0 的上下不停波动的信号，可以采用 Seq2Seq Attention 进行建模预测，该模型对于这种复杂的信号有较好的拟合效果。选取合适的超参数建立模型，利用训练集数据完成模型的训练。模型超参数包括学习率、模型的隐藏层输出维数、训练迭代次数和暂退法丢弃率等。利用选定的超参数建立添加注意力机制的序列到序列模型后，将划分后的数据集中的训练集用作模型的训练，模型训练过程中存储训练误差，训练完后绘制损失变化曲线，如果曲线持续下降则说明模型正常训练，否则需要重新选定适合的超参数重复训练过程，直到曲线正常下降方可结束。

第四步，测试训练好的模型在测试集上的效果，并绘制单步和多步的容量预测曲线和真实曲线，使用 MAE 和 RMSE 对预测结果进行评估。

第五步，将模型更换为感知机模型和序列到序列模型，重复以上操作，与第一个模型进行对比分析。

### 4.4 结果分析

首先将预测起点定为 100，分别绘制添加注意力机制的序列到序列模型、序列到序列模型和感知机单步预测曲线和实际容量变化曲线，对三个模型的对比分析图如下：

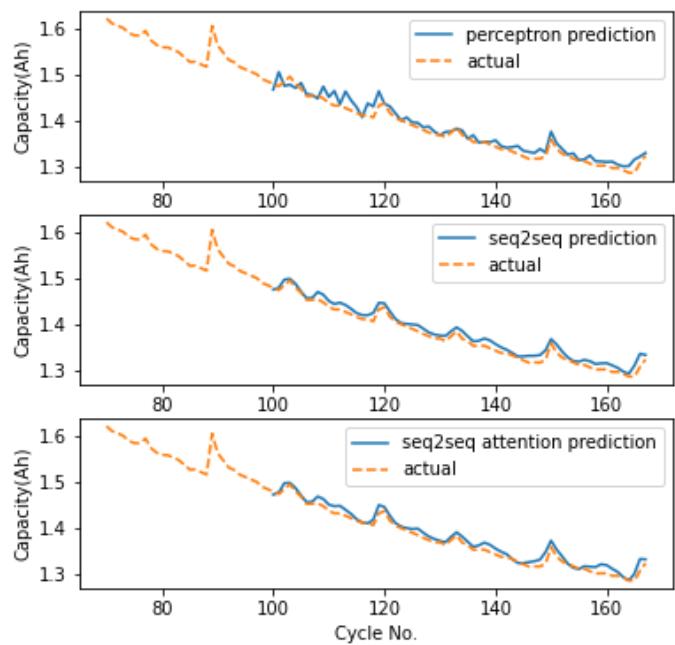


图 4.3 B05 电池容量单步预测结果

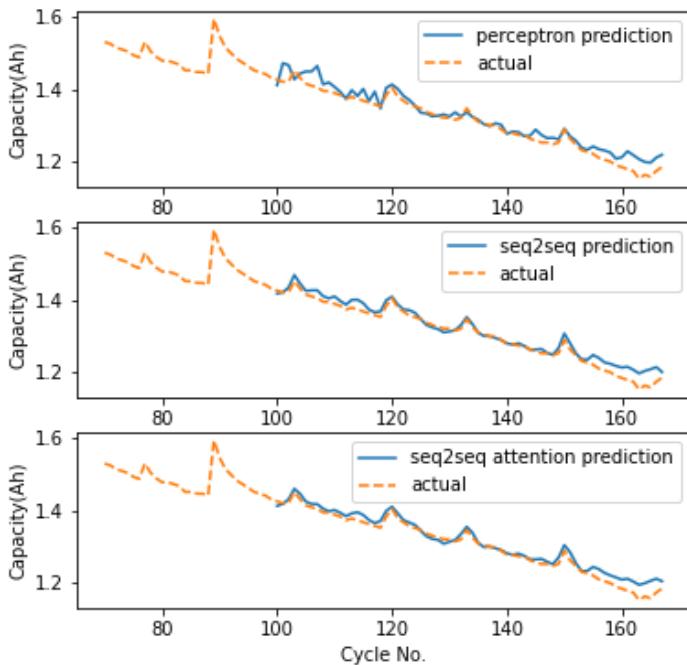


图 4.4 B06 电池容量单步预测结果

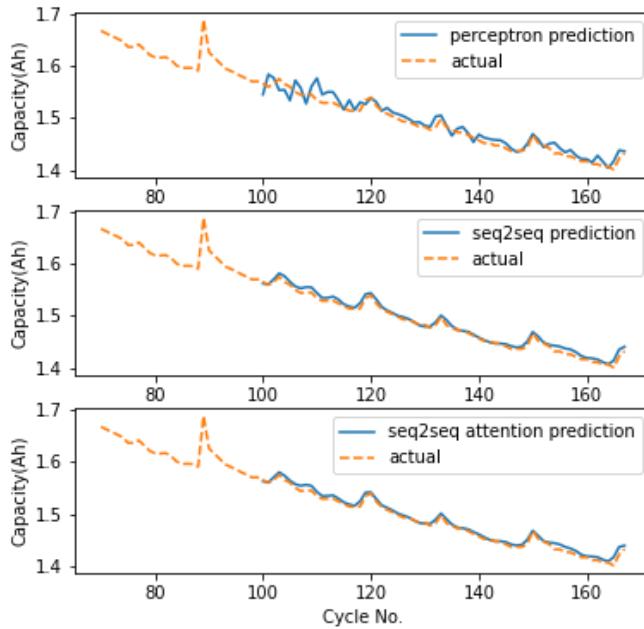


图 4.5 B07 电池容量单步预测结果

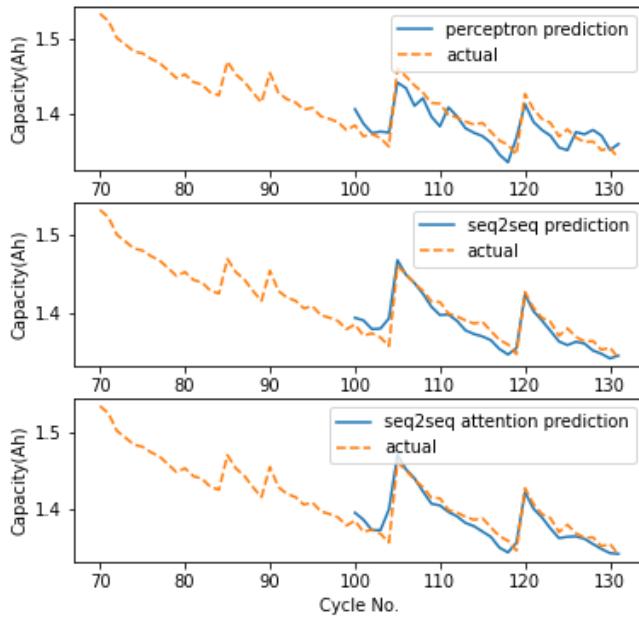


图 4.6 B18 电池容量单步预测结果

由图 4.3 至图 4.6 可以发现，单步预测的情况下，三个模型均对电池容量自恢复效应有比较好的把控，其中无论是否添加注意力机制的序列到序列模型都有较好的预测效果，这说明集合经验模态分解能够很好地对原始时间序列进行分解，分解后再使用模型

## 中北大学 2022 届毕业设计说明书

建模预测，这样模型能够更加容易地对电池容量自恢复效应进行把握，因此预测结果明显好于第三章中使用的方法。使用平均绝对误差和均方根误差对电池容量预测结果进行评估，得到的结果如表 4.1：

表 4.1 单步预测结果

电池序号	模型	MAE	RMSE
B05	Perceptron	0.011496	0.014207
B05	Seq2Seq	0.010841	0.011993
B05	Seq2Seq Attention	0.009228	0.010938
B06	Perceptron	0.017779	0.023133
B06	Seq2Seq	0.013631	0.017902
B06	Seq2Seq Attention	0.013201	0.016762
B07	Perceptron	0.010587	0.012973
B07	Seq2Seq	0.005301	0.006346
B07	Seq2Seq Attention	0.004976	0.006054
B18	Perceptron	0.015351	0.016894
B18	Seq2Seq	0.009726	0.012162
B18	Seq2Seq Attention	0.00892	0.011811

由表 4.1 可以看出，先使用集合经验模态分解再建模对电池容量预测的方法明显优于第三章中所使用的方法，取得的平均绝对误差和均方根误差均较小，并且三个模型都对电池容量自恢复效应有不错的预测。对分解后的电池容量时间序列进行建模预测，无论是否添加注意力都能取得较小的预测误差，并且感知机模型也能很好地对电池容量进行预测。

将预测起点定为 100，分别绘制添加注意力机制的序列到序列模型、序列到序列模型和感知机的 5 步预测曲线和实际容量变化曲线，实际容量变化曲线和预测容量变化曲线如图 4.7 至图 4.10。

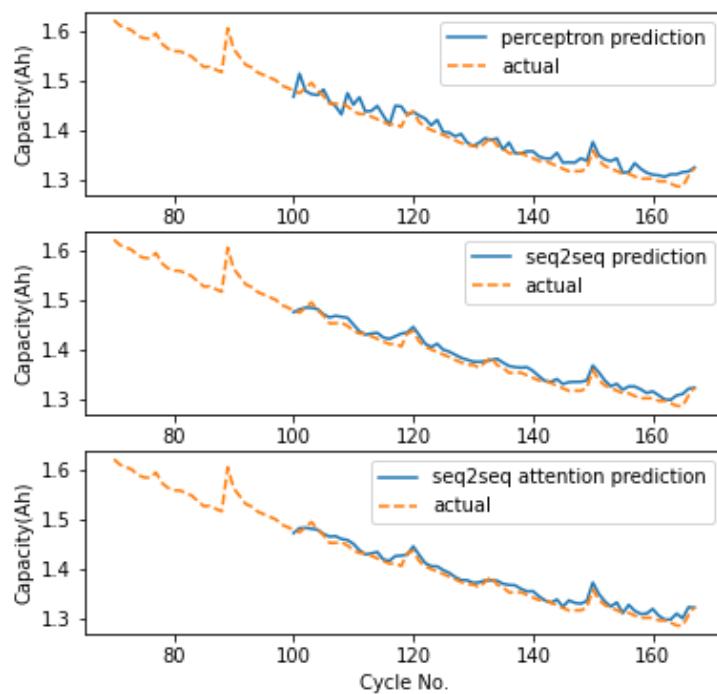


图 4.7 B05 电池容量 5 步预测结果

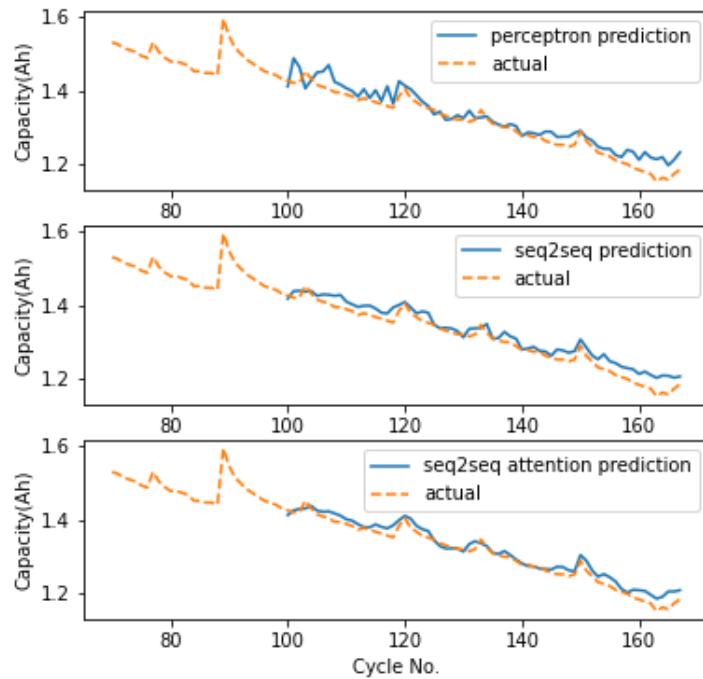


图 4.8 B06 电池容量 5 步预测结果

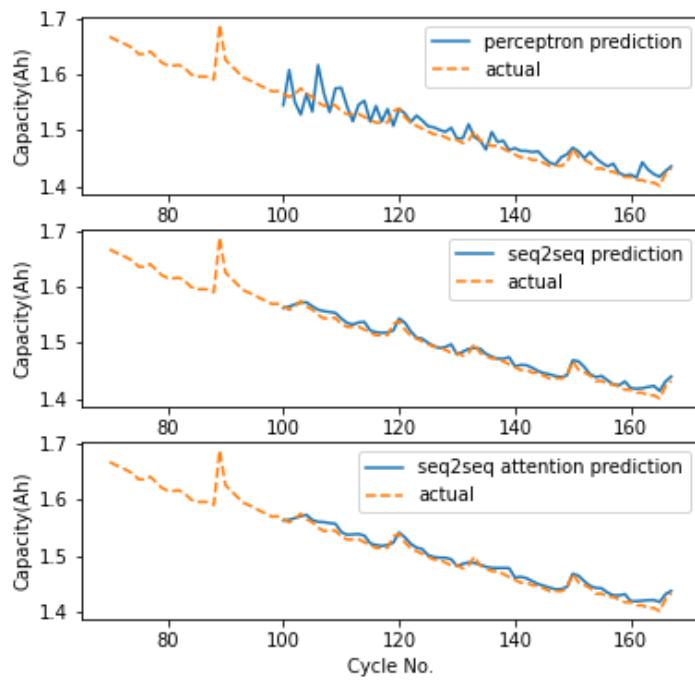


图 4.9 B07 电池容量 5 步预测结果

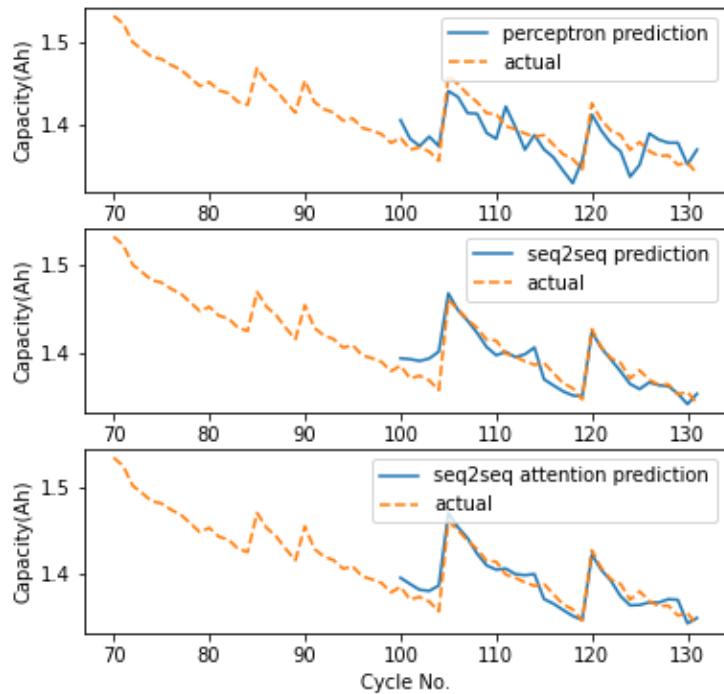


图 4.10 B18 电池容量 5 步预测结果

## 中北大学 2022 届毕业设计说明书

由图 4.7 至图 4.10 可以看出，在 5 步预测的情况下两个基于编码器解码器架构的模型都能有不错的预测效果，感知机的预测结果相对较差。除感知机模型外的两个模型均对电池自恢复效应有比较准确地预测，虽然感知机模型在尝试完成电池自恢复现象的预测，但预测效果较差，波动频率明显高于实际情况，这说明基于循环神经网络的隐藏状态这一特殊机制，序列到序列模型能够更准确地利用历史数据，并对未来电池容量做出更精确的预测。使用平均绝对误差和均方根误差对三个模型的 5 步预测结果进行评估，得到的结果如表 4.2。

表 4.2 5 步预测结果

电池序号	模型	MAE	RMSE
B05	Perceptron	0.013817	0.016937
B05	Seq2Seq	0.010453	0.011885
B05	Seq2Seq Attention	0.008874	0.010383
B06	Perceptron	0.022493	0.028255
B06	Seq2Seq	0.020268	0.023466
B06	Seq2Seq Attention	0.014688	0.017607
B07	Perceptron	0.014831	0.019394
B07	Seq2Seq	0.006695	0.007874
B07	Seq2Seq Attention	0.007182	0.00822
B18	Perceptron	0.018099	0.019822
B18	Seq2Seq	0.009943	0.013772
B18	Seq2Seq Attention	0.008924	0.010791

由表 4.2 可以看出，三个模型的平均绝对误差和均方根误差都较小，尤其是添加注意力机制的序列到序列模型和普通的序列到序列模型，均取得非常低的误差，这说明对电池容量原始时间序列进行分解后的数据，模型更容易根据历史数据对未来电池容量进行预测，从而取得更低的误差和更高的预测精度。

将预测起点定为 100，绘制三个模型的 10 步容量预测曲线和实际容量变化曲线，容  
第38页 共 54 页

# 中北大学 2022 届毕业设计说明书

量预测曲线和实际容量变化曲线如下：

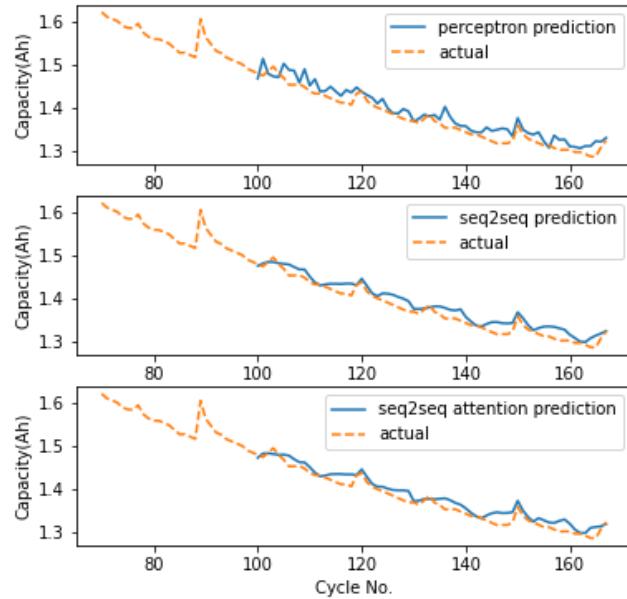


图 4.11 B05 电池容量 10 步预测结果

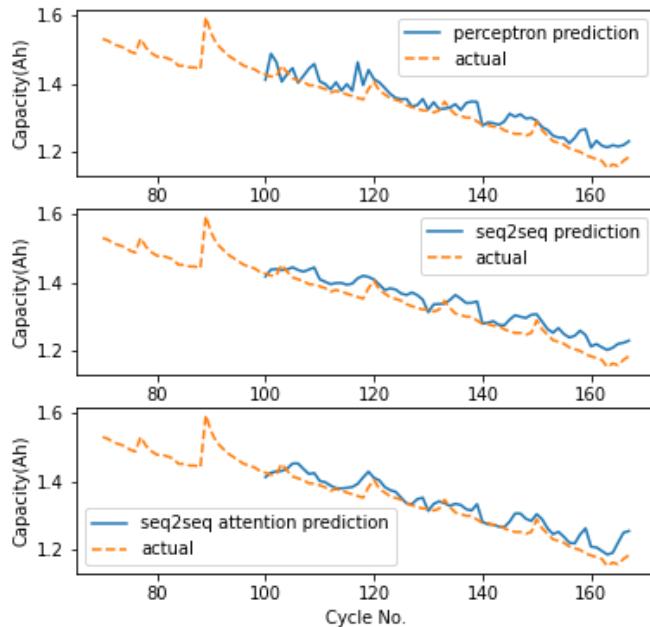


图 4.12 B06 电池容量 10 步预测结果

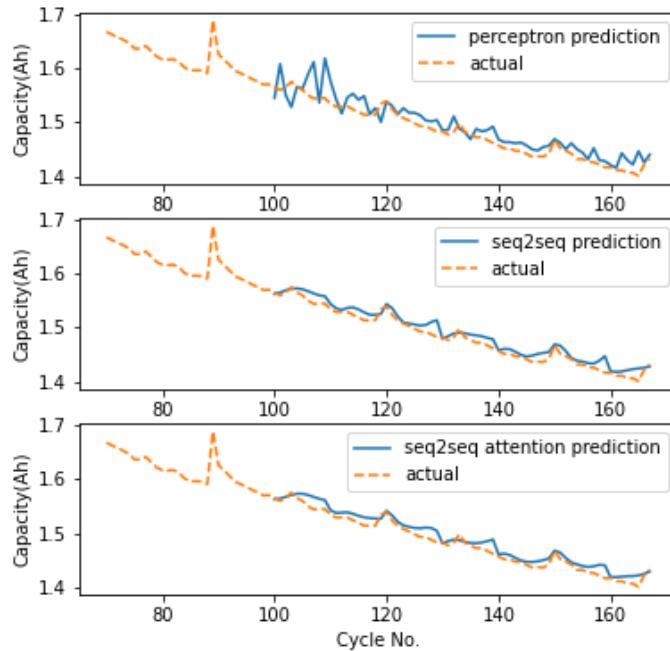


图 4.13 B07 电池容量 10 步预测结果

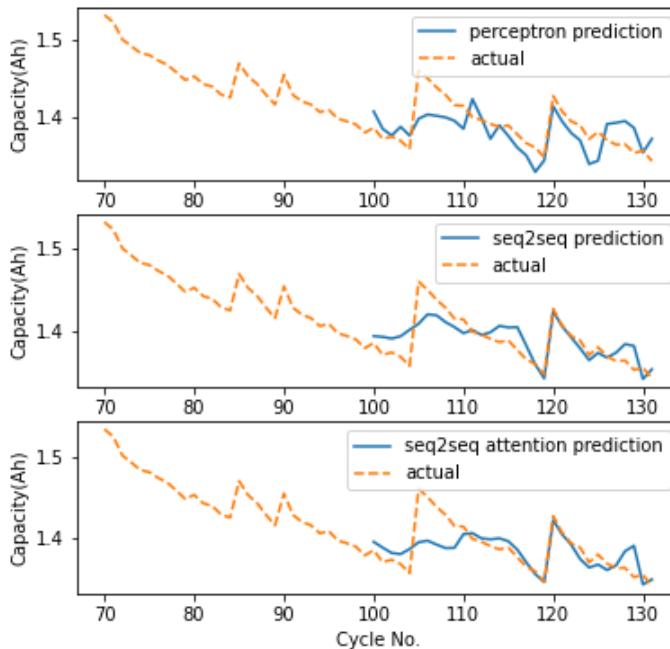


图 4.14 B18 电池容量 10 步预测结果

由图 4.11 至图 4.14 可以看出，在 10 步预测的情况下，是否添加注意力机制都对预测精度影响不大，模型预测误差因预测步长的增大一步步上升，最后引起预测结果与真

## 中北大学 2022 届毕业设计说明书

实结果差距较大，但仍有着不错的预测效果。使用平均绝对误差和均方根误差对三个模型 10 步预测的结果进行评估，得到的结果如表 4.3。

表 4.3 10 步预测结果

电池序号	模型	MAE	RMSE
B05	Perceptron	0.01766	0.020811
B05	Seq2Seq	0.014541	0.016923
B05	Seq2Seq Attention	0.013254	0.015648
B06	Perceptron	0.029813	0.037109
B06	Seq2Seq	0.030484	0.034609
B06	Seq2Seq Attention	0.023974	0.030079
B07	Perceptron	0.017519	0.022919
B07	Seq2Seq	0.010231	0.012025
B07	Seq2Seq Attention	0.010427	0.012119
B18	Perceptron	0.022273	0.026046
B18	Seq2Seq	0.014885	0.019261
B18	Seq2Seq Attention	0.016003	0.022649

由表 4.3 可以得出，相较于第三章中算法的 10 步预测结果，此处三个模型所取得的预测结果误差更小，远小于第三章模型的误差。因此，可以推断使用集合经验模态分解对原始电池容量进行分解后再建模预测是一个非常好的办法，能够让不同的模型针对不同时间尺度的数据进行建模预测，最后将多个模型结果整合得到最终的预测结果。对数据分解后，即使是最简单的感知机模型仍然能够取得较小的预测误差，这足以说明这种方法的优越性。

### 4.5 本章小结

本章在第 3 章的基础上进行了改进，添加了集合经验模态分解方法，对原始电池容量时间序列进行了分解，对分解后的 IMF 分量和残差采用不同的算法进行建模预测，使用支持向量回归对 IMF 分量进行建模，使用添加注意力机制的序列到序列模型对残差

## 中北大学 2022 届毕业设计说明书

---

进行建模。受电池容量自恢复机制的影响，电池容量时间序列的振荡幅度较大，传统的建模方法效果较差，使用集合经验模态分解后得到的 IMF 分量和残差更易拟合。分解后得到的残差是一个单调序列或常值序列，使用支持向量回归可以很好的拟合。而分解后的 IMF 分量，相较于原始信号，振荡的幅度要小得多，因此使用基于注意力机制的序列到序列模型可以很好的拟合。实验证明，基于集合经验模态分解、支持向量回归和添加注意力机制的序列到序列模型效果明显优于基于添加注意力机制的序列到序列模型，因此足以证明使用集合经验模态分解的优越性，它使得电池剩余寿命的预测变得更加地精确。

## 5 基于深度学习的锂离子电池剩余寿命预测系统

### 5.1 系统设计目的与意义

锂离子电池在当今时代广泛应用于各行各业，但是由于其复杂的工作机理和衰退机理，难以对其进行管理。电池衰退会使得其性能下降，严重会造成安全事故的发生，因此建模对锂离子电池的状态进行监控是十分重要的。因此，在本文的基础上，本章设计并实现了基于深度学习的锂离子电池剩余寿命预测系统，结合第三章和第四章的预测结果进行综合展示，展现了本研究课题的实用价值。

### 5.2 系统总体设计

本系统采用 Python Web 框架 Django 和百度 JavaScript 绘图框架 Echarts 对结果进行展示，基于深度学习的锂离子电池剩余寿命预测系统主要包含以下六个模块。

- (1) 第一部分展示集合经验模态分解对 B05、B06、B07 和 B18 四个原始电池时间序列进行分解的结果。
- (2) 第二部分展示使用支持向量回归对四个电池分解后的低频残差部分建模预测的结果。
- (3) 第三部分展示使用感知机对四个电池分解后的高频 IMF 分量建模预测的结果。
- (4) 第四部分展示使用序列到序列模型对四个电池分解后的高频 IMF 分量建模预测的结果。
- (5) 第五部分展示使用添加注意力机制的序列到序列模型对四个电池分解后的高频 IMF 分量建模预测的结果。
- (6) 第六部分对不使用集合经验模态分解的三个模型和使用该算法的三个模型进行对比展示，并列表格展示其预测精度结果。

### 5.3 系统展示界面

#### 5.3.1 集合经验模态分解结果展示界面

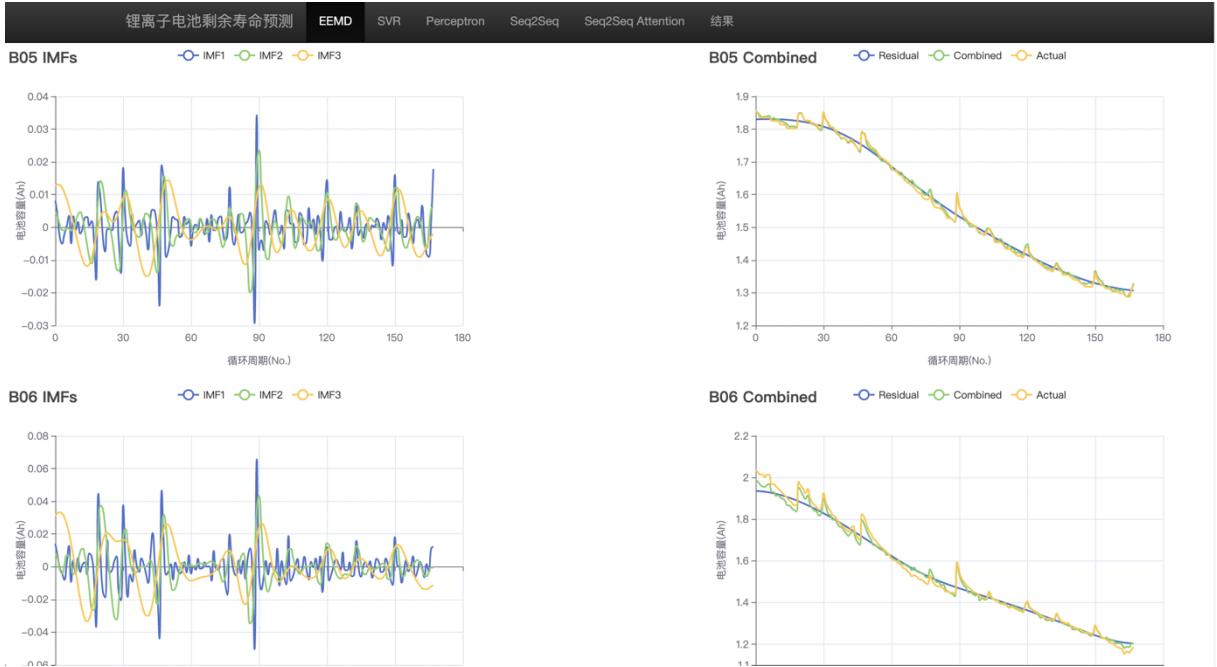


图 5.1 电池 B05 和 B06 集合经验模态分解图

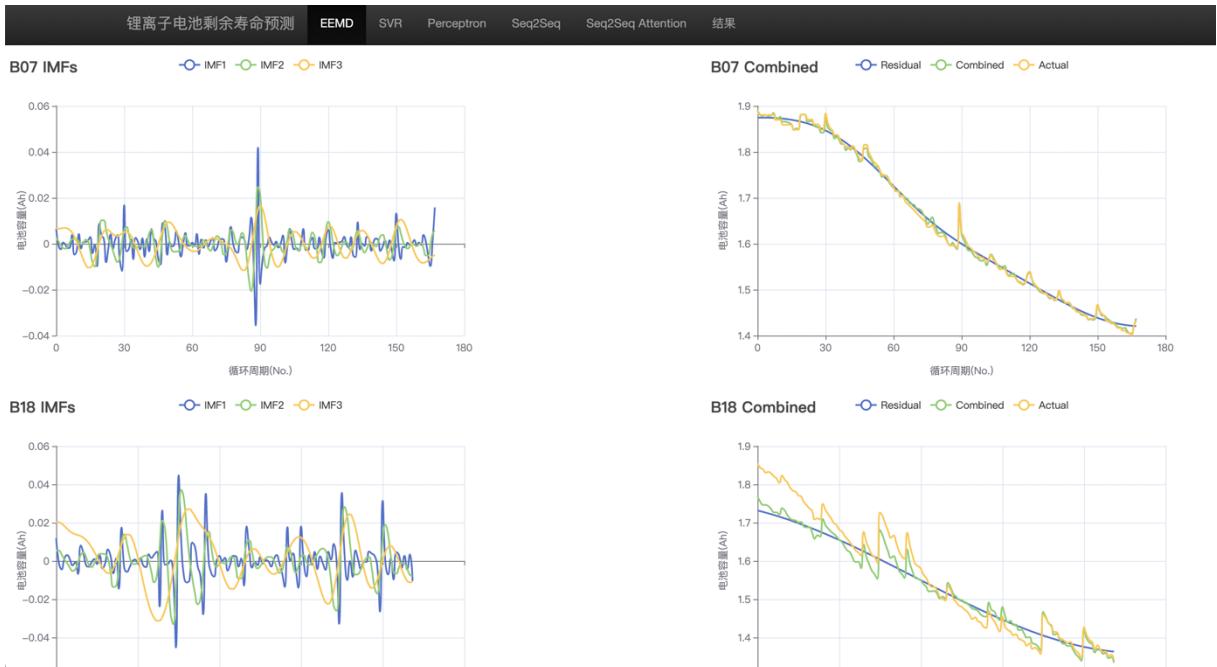


图 5.2 电池 B07 和 B18 集合经验模态分解图

图 5.1 和图 5.2 展示了电池 B05、B06、B07 以及 B18 使用集合经验模态分解后的分量曲线图，并绘制了残差、原始曲线和重构曲线的对比图。

# 中北大学 2022 届毕业设计说明书

## 5.3.2 支持向量回归残差预测结果展示界面

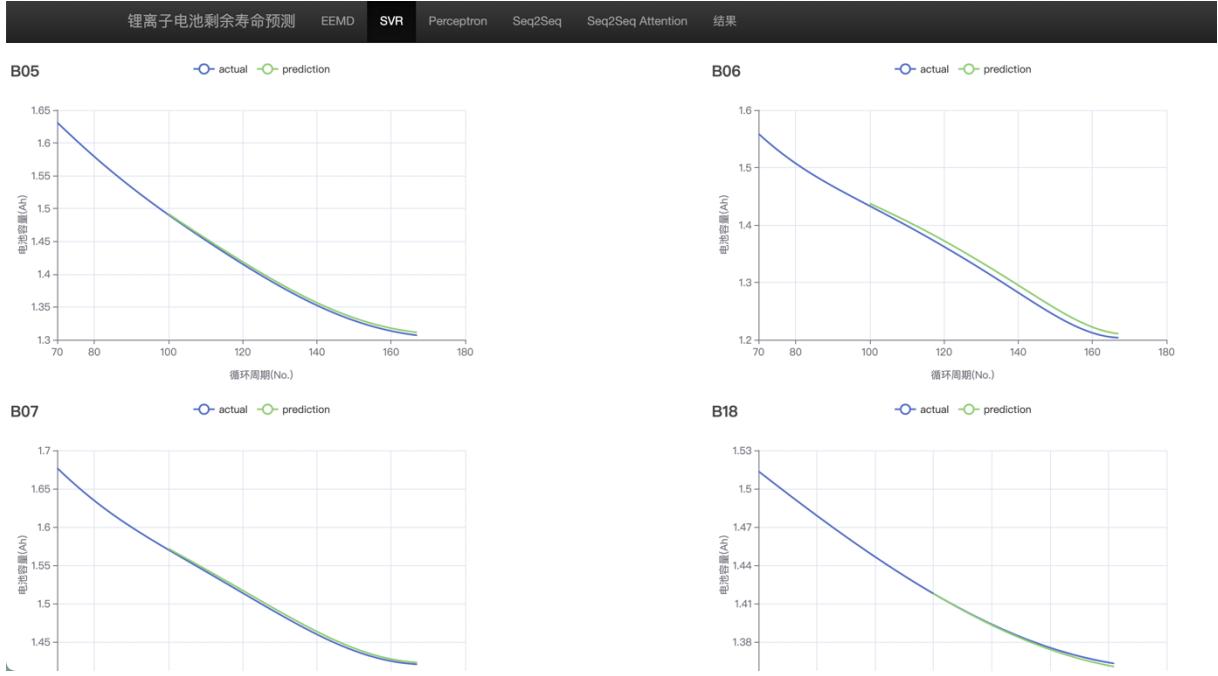


图 5.3 支持向量回归残差预测结果图

图 5.3 中展示了使用支持向量回归对分解后的残差进行建模预测的结果，并与残差曲线进行对比。

## 5.3.3 感知机 IMF 分量预测结果展示界面



图 5.4 电池 B05 和 B06 感知机 IMF 分量预测结果图

# 中北大学 2022 届毕业设计说明书

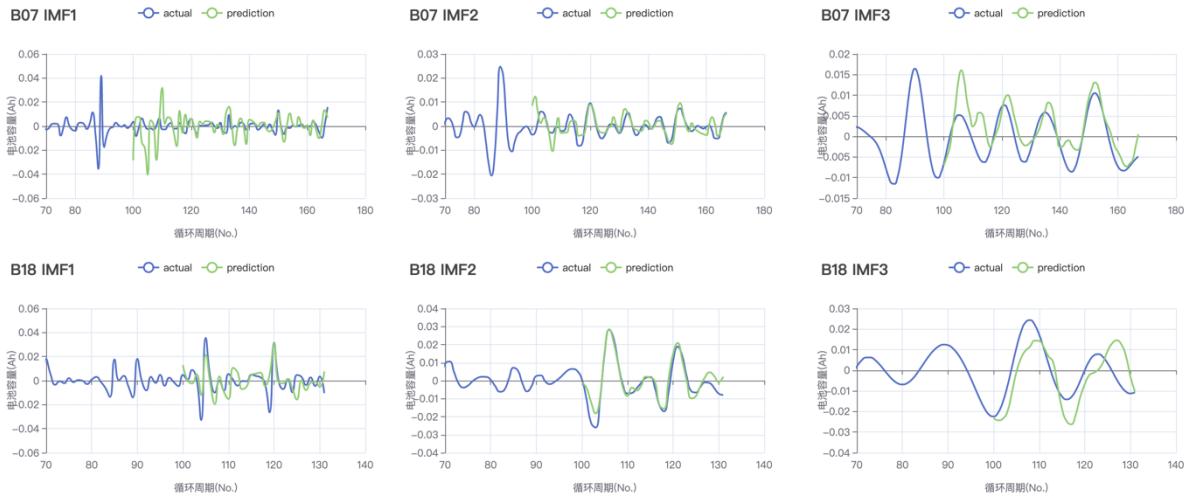


图 5.5 电池 B07 和 B18 感知机 IMF 分量预测结果图

图 5.4 和图 5.5 展示了感知机模型对分解后的 IMF 分量的预测结果，并与分解后的原始 IMF 进行对比展示。

#### 5.3.4 序列到序列模型 IMF 分量预测结果展示界面



图 5.6 电池 B05 和 B06 序列到序列模型 IMF 分量预测结果图

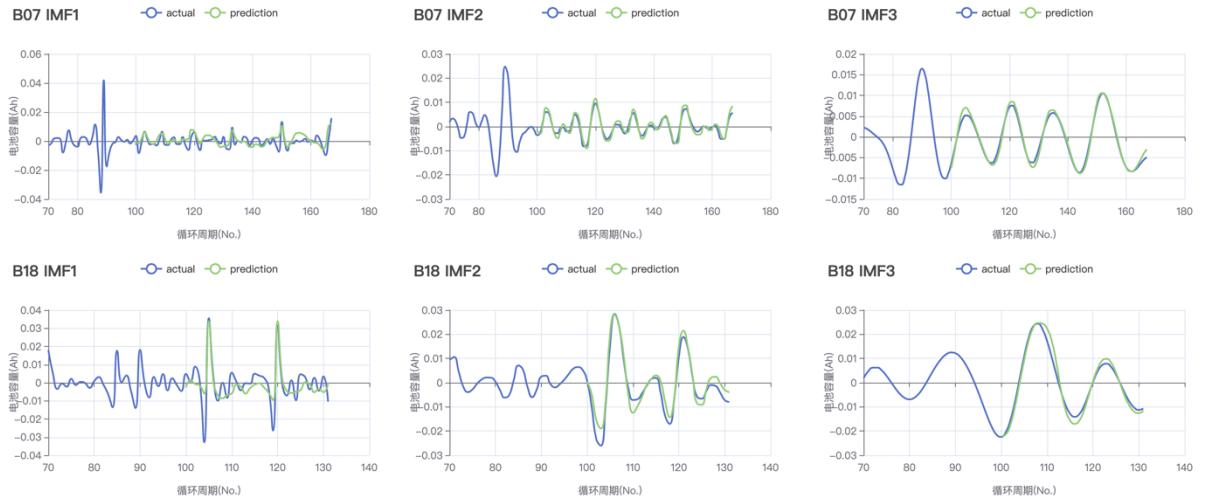


图 5.7 电池 B07 和 B18 序列到序列模型 IMF 分量预测结果图

图 5.6 和图 5.7 展示了序列到序列模型对分解后的 IMF 分量建模预测的结果，并与原始 IMF 分量进行对比。

### 5.3.5 添加注意力机制的序列到序列模型 IMF 分量预测结果展示界面

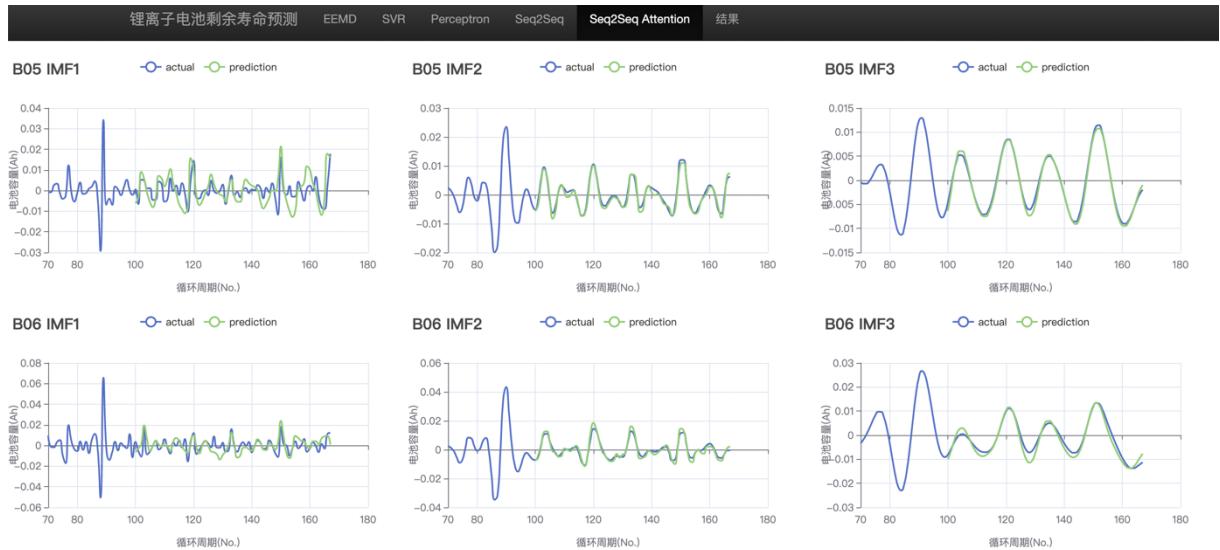


图 5.8 电池 B05 和 B06 添加注意力机制的序列到序列模型 IMF 分量预测结果图

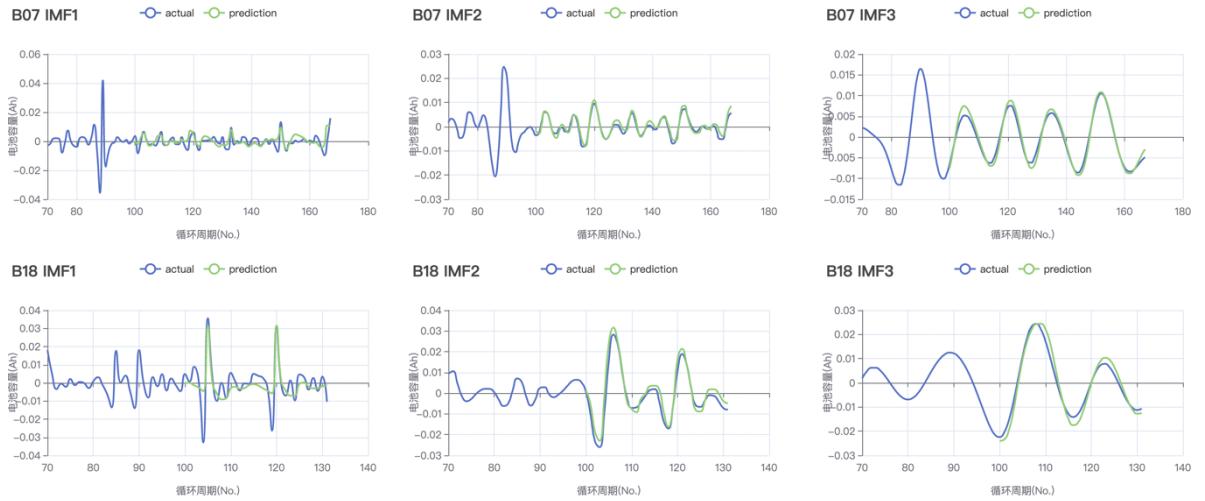


图 5.9 电池 B07 和 B18 添加注意力机制的序列到序列模型 IMF 分量预测结果图

图 5.8 和图 5.9 展示了添加注意力机制的序列到序列模型对分解后的 IMF 分量建模预测的结果，并与原始 IMF 分量进行对比。

### 5.3.6 模型对比结果展示界面

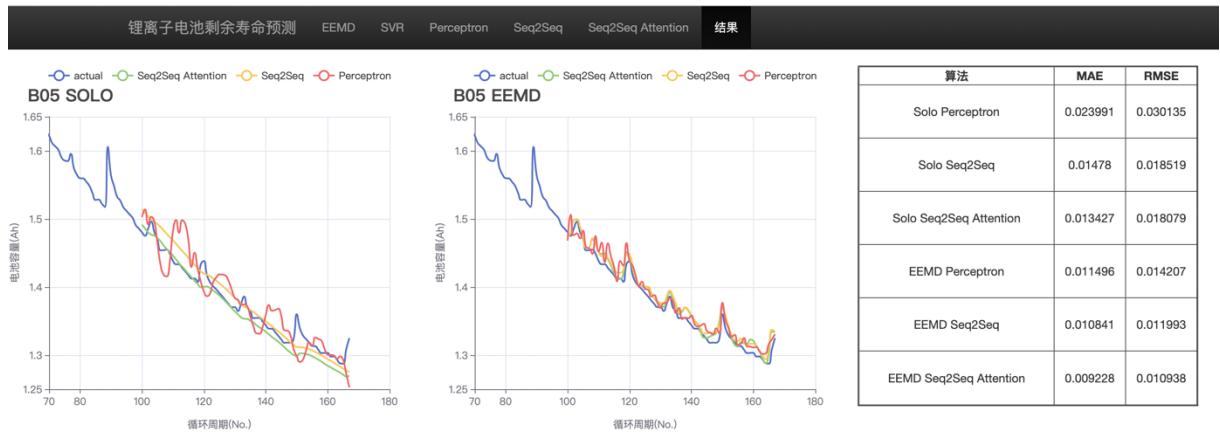


图 5.10 电池 B05 模型对比图

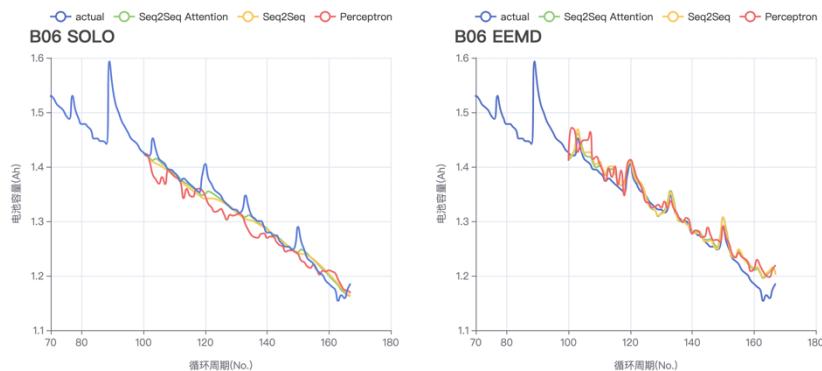


图 5.11 电池 B06 模型对比图

算法	MAE	RMSE
Solo Perceptron	0.020421	0.026323
Solo Seq2Seq	0.01243	0.017914
Solo Seq2Seq Attention	0.009539	0.014909
EEMD Perceptron	0.017779	0.023133
EEMD Seq2Seq	0.013631	0.017902
EEMD Seq2Seq Attention	0.013201	0.016762

# 中北大学 2022 届毕业设计说明书

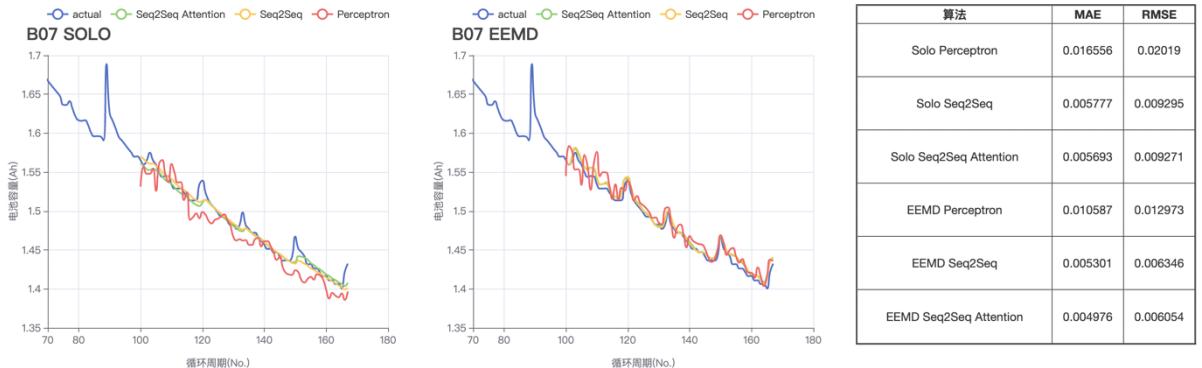


图 5.12 电池 B07 模型对比图

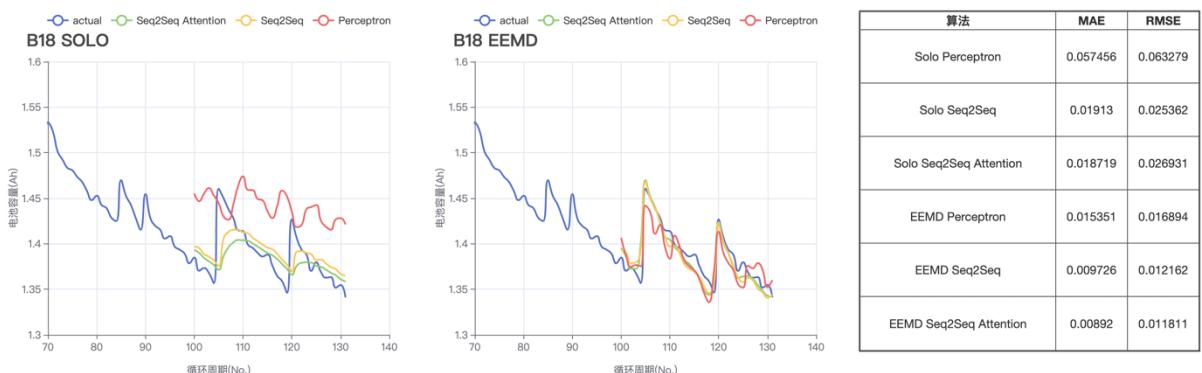


图 5.13 电池 B18 模型对比图

图 5.10 至图 5.13 将第三章和第四章中六个模型进行对比展示，并使用 MAE 和 RMSE 对模型精度进行了评价。

## 5.4 本章小结

本章首先对基于深度学习的锂离子电池剩余寿命预测系统的设计目的和意义进行了阐述，并对系统总体设计进行了介绍。本章使用 Django 和 Echarts 进行网站和前端页面的编写，并在第三节中对界面进行了展示和介绍。

## 6 总结与展望

### 6.1 总结

本文在结合锂离子电池工作机理和容量自恢复现象的基础上，引入一种信号处理算法，对原始信号进行集合经验模态分解，然后对分解得到的 IMF 分量使用添加注意力机制的序列到序列模型进行建模，残差则使用支持向量回归进行建模，最后将各分量的预测结果进行重构，以此预测锂离子电池的剩余寿命，具体的工作如下：

(1) 使用常用作时间序列分析中的序列到序列模型对电池容量数据建模，并添加注意力机制提高模型精度。序列到序列模型包含编码器和解码器两个循环神经网络，两个部分完成不同的工作，编码器提取输入数据中的时序信息并总结为一个上下文向量，解码器利用这个向量和其输入共同计算得到预测结果。添加注意力机制后，能够更容易地导出上下文向量以及解码器输入中重要的部分，使得模型精度变高。

(2) 在 (1) 的基础上，先对电池容量数据进行集合经验模态分解，将原始信号分解为低频残差和高频 IMF 分量。受电池容量自恢复效应的影响，原始信号振荡比较严重，利用集合经验模态分解可以将其分解为多个振荡幅度较小的信号，更利于建模预测。低频残差是单调序列或常值序列，使用支持向量回归进行建模预测。高频 IMF 分量相对于原始信号振荡幅度较小，使用添加注意力机制的序列到序列模型建模预测，最后将各模型的预测结果相加，即为最终的预测结果。从实验结果来看，相较于 (1) 中方法，此种方法具有更好的预测精度。

### 6.2 展望

锂离子电池剩余寿命预测涉及到多个学科，应结合电化学，深度学习等学科进行建模，充分考虑各方面影响因素，本文的不足包括以下：

- (1) NASA 电池数据集循环周期较少，数据集样本较少，不利于深度学习模型训练，通过增多数据集样本，可以提高模型泛化性和精度。可以通过选用其他循环周期较长的电池数据集进行建模，模型精度会得到相应的提升。
- (2) 本文仅使用深度学习的方法，将容量数据视为时间序列进行建模，然后对容量进行预测。可以结合电化学方面的知识，从多方面来考虑建模的因素，会使得模型效果更好。

## 中北大学 2022 届毕业设计说明书

- 
- (3) 可以选用效果更佳的信号分解算法和时间序列分析算法进行建模，例如信号分解算法选用自适应噪声完备集合经验模态分解(Complete Ensemble Empirical Mode Decomposition with Adaptive Noise, CEEMDAN)，时间序列分析算法选用 Transformer 等。

## 参 考 文 献

- [1] Xiong R, Zhang Y, Wang J, et al. Lithium-Ion Battery Health Prognosis Based on a Real Battery Management System Used in Electric Vehicles[J]. IEEE Transactions on Vehicular Technology, 2019, 68(5):4110-4121.
- [2] Gandoman F H, Jaguemont J, Goutam S, et al. Concept of reliability and safety assessment of lithium-ion batteries in electric vehicles: Basics, progress, and challenges[J]. Applied Energy, 2019, 251.
- [3] Li Y, Li K, Xie Y, et al. Optimized charging of lithium-ion battery for electric vehicles: Adaptive multistage constant current–constant voltage charging strategy[J]. Renewable Energy, 2020, 146.
- [4] Hla B, Lm B, Ch C, et al. Advanced rechargeable zinc-based batteries: Recent progress and future perspectives[J]. Nano Energy, 2019, 62:550-587.
- [5] He H, Zhang X, Xiong R, et al. Online model-based estimation of state-of-charge and open-circuit voltage of lithium-ion batteries in electric vehicles[J]. Energy, 2012, 39(1):310-318.
- [6] Wang H, Zhao D, Cai Y, et al. A trajectory-based energy consumption estimation method considering battery degradation for an urban electric vehicle network[J]. Transportation Research Part D Transport and Environment, 2019, 74:142-153.
- [7] Liu D, Song Y, Li L, et al. On-line life cycle health assessment for lithium-ion battery in electric vehicles[J]. Journal of Cleaner Production, 2018, 199:1050-1065.
- [8] Ali Ahmadian, Mahdi Sedghi, Ali Elkamel, et al. Plug-in electric vehicle batteries degradation modeling for smart grid studies: Review, assessment and conceptual framework[J]. Renewable and Sustainable Energy Reviews, 2018, 81:2609-2624.
- [9] A Barré, Deguilhem B, Grolleau S, et al. A review on lithium-ion battery ageing mechanisms and estimations for automotive applications[J]. Journal of Power Sources, 2013, 241:680-689.
- [10] Hannan M A, Lipu M, Hussain A, et al. A review of lithium-ion battery state of charge estimation and management system in electric vehicle applications: Challenges and

## 中北大学 2022 届毕业设计说明书

- recommendations[J]. Renewable & Sustainable Energy Reviews, 2017, 78:834-854.
- [11] Lu L, Han X, Li J, et al. A review on the key issues for lithium-ion battery management in electric vehicles[J]. Journal of Power Sources, 2013, 226:272-288.
- [12] Fan Y, Xiao F, Li C, et al. A novel deep learning framework for state of health estimation of lithium-ion battery[J]. Journal of Energy Storage, 2020, 32.
- [13] Vidal C, Malysz P, Kollmeyer P, et al. Machine Learning Applied to Electrified Vehicle Battery State of Charge and State of Health Estimation: State-of-the-Art[J]. IEEE Access, 2020, 99:52796-52814.
- [14] 刘大同,周建宝,郭力萌,彭宇.锂离子电池健康评估和寿命预测综述[J].仪器仪表学报,2015,36(1):1-16.
- [15] Doyle M, Fuller T F, Newman J. The importance of the lithium ion transference number in lithium/polymer cells[J]. Electrochimica Acta, 1994, 39(13):2073-2081.
- [16] Thomas E V, Bloom I, Christoffersen J P, et al. Rate-based degradation modeling of lithium-ion cells[J]. Journal of Power Sources, 2012, 206:378-382.
- [17] Hu X, Li S, Peng H. A comparative study of equivalent circuit models for Li-ion batteries[J]. Journal of Power Sources, 2012, 198:359-367.
- [18] Saha B, Kai G, Poll S, et al. An integrated approach to battery health monitoring using bayesian regression and state estimation[C]// 2007 IEEE Autotestcon. IEEE, 2007.
- [19] Remmlinger J, Buchholz M, Soczka-Guth T, et al. On-board state-of-health monitoring of lithium-ion batteries using linear parameter-varying models[J]. Journal of Power Sources, 2013, 239:689–695.
- [20] 严仁远. 考虑容量恢复效应的锂离子电池剩余寿命预测[D].杭州:浙江大学,2018.

## 致 谢

时光荏苒，岁月葱茏，四年的本科生活即将结束。这四年间在中北大学收获了很多，度过了一段充实的大学时光。在这半年的毕业设计期间，我学会了很多新知识，收到了很多人的帮助，在此我想对他们表达我诚挚的感谢。

首先，我要感谢我的父母，感谢他们对我学习的无条件支持，让我没有后顾之忧。感谢我的老朋友甄思琪，快乐与不快乐的事情都能互相分享，让我每天都能快乐的面对生活。感谢我的指导老师崔方舒老师，感谢你在毕设期间对我的详细指导，让我能够得以顺利完成毕业设计。感谢我的五个室友们，大学期间和你们度过了一段快乐的时光。感谢中北大学 ACM 实验室，如果当初没有加入这个实验室，就没有今天的我，想必我会在众多的选择中迷失了道路，谢谢实验室对我的支持和帮助，三年的竞赛生涯也十分地快乐。感谢我的队友裴端和李文深，和你们一起的比赛十分地紧张快乐，日常和你们一起学习也十分享受。

感谢本科期间遇到的一切，我会在研究生阶段继续努力，做一个更好的自己，为社会贡献出自己的一份力量。