

分 类 号 _____
学校代码 10487

学号 M202271780
密级 _____

华中科技大学
硕士学位论文

(学术型 专业型)

催化裂化反应再生系统的安全知识
图谱构建与智能安全应用研究

学位申请人： 孙琪

学科专业： 网络空间安全

指导教师： 周纯杰 教授

答辩日期： 2025 年 4 月 23 日

**A Thesis Submitted in Partial Fulfillment of the Requirements for
the Master Degree in Engineering**

**Safety Knowledge Graph Construction and Intelligent
Safety Applications in Fluid Catalytic Cracking
Reaction-Regeneration Systems**

Candidate : SUN Qi

Major : Cyberspace Security

Supervisor : Prof. ZHOU Chunjie

Huazhong University of Science and Technology

Wuhan 430074, P. R. China

April, 2025

独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：孙琪

日期：2025年5月8日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权华中科技大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保 密口，在_____年解密后适用本授权书。

本论文属于 不保密

(请在以上方框内打“√”)

学位论文作者签名：孙琪

日期：2025年5月8日

指导教师签名：

日期：2025年5月8日



摘要

催化裂化装置是石油炼化工业过程的核心生产单元，其运行稳定性直接影响工厂产品的质量和过程的安全性。然而，管道化的连续生产过程中，物质、能量以及控制等综合约束使得传感器捕获的大量过程监测数据通常具有高度复杂的时空依赖性。而现阶段高度依赖人工执行的安全监控调节过程往往面临信息过载、决策偏差等问题，导致系统安全风险事件的漏判甚至误判等情况时有发生，极易导致生产波动甚至重大安全事故的发生，而对于高温高压的反应再生系统来说决难容忍。人工智能技术的发展为智能化的安全监控提供了新方法。然而，纯数据驱动方法存在噪声敏感且可解释性不足等问题，难以有效应对复杂的工业场景。鉴于此，本文提出了基于安全知识图谱的催化裂化装置反应再生系统智能安全分析方法。具体而言，本文的主要研究内容如下：

针对领域安全知识的高效组织问题，提出了一种基于非结构化文本的安全知识图谱构建方法。该方法利用跨度分类的命名实体识别和基于大语言模型的关系三元组抽取，实现对催化操作规程中安全知识的自动化提取。此外，通过整合时间序列数据与文本信息，构建变量因果图，形成支持智能安全分析的综合性知识图谱。

针对工业生产环境中传感器数据噪声干扰和多变量耦合特性，提出了一种基于多任务变分自编码器的时间序列异常检测方法，结合图注意力网络和选择状态空间模型，实现高精度的变量级异常检测。在此基础上，基于安全知识图谱所提供的变量因果图与实时异常分数，通过概率寻优分析方法，实现了异常根本原因实时推断。

针对当前人工异常处置效率低且存在信息过载问题，基于安全知识图谱与大语言模型，通过检索增强生成方法构建安全知识辅助问答系统，实现了安全知识的快速检索和基于异常根本原因分析结果的自动化处置方案生成。

基于实际工业应用场景，开发了面向催化裂化装置反应再生系统的智能安全分析软件。通过可视化交互界面设计，以实际系统数据和知识为基础，验证了安全知识图谱构建及智能安全分析方法在异常监测与处置的有效性。

关键词：催化裂化装置；反应再生系统；知识图谱；异常诊断；知识库问答

Abstract

Fluid catalytic cracking (FCC) units serve as the core production units in the petroleum refining industry, and their operational stability plays a critical role in ensuring product quality and process safety. However, the continuous production process, characterized by pipelined material and energy flows along with control constraints, often results in process monitoring data that exhibits highly complex spatial-temporal dependencies. Currently, safety monitoring and adjustments, heavily reliant on manual execution, often face issues of information overload and decision biases, leading to frequent underestimations or misjudgments of system safety risks. It can easily lead to production fluctuations or even severe safety incidents, which are intolerable for the high-temperature, high-pressure reaction-regeneration systems. The development of artificial intelligence offers new methodologies for intelligent safety monitoring. However, purely data-driven approaches, sensitive to noise and lacking in interpretability, struggle to effectively address complex industrial scenarios. Given these challenges, this thesis proposes an intelligent safety analysis method for reaction-regeneration systems of fluid catalytic cracking units based on a safety knowledge graph. Specifically, the main research topics of this thesis include:

To efficiently organize domain-specific safety knowledge, a method for constructing a safety knowledge graph from unstructured text is proposed. The method utilizes span-based named entity recognition and relational triple extraction based on large language models to automate the extraction of safety knowledge from catalytic operation procedures. In addition, by integrating time series with textual information, a causal graph of variables is constructed to form a comprehensive knowledge graph that supports intelligent safety analysis.

To address the issues of noise interference and multivariate coupling characteristics of sensor data in industrial production environments, a time series anomaly detection method based on a multi-task variational autoencoder is proposed. The method combines graph attention networks and selective state space models to achieve high-precision variable-level

华中科技大学硕士学位论文

anomaly detection. Building on this, real-time inference of root causes of anomalies is realized through probability optimization analysis methods, leveraging the causal graph of variables provided by the safety knowledge graph and real-time anomaly scores.

In response to the low efficiency and information overload problems in manual anomaly handling, a safety knowledge-assisted question answering system is constructed using the safety knowledge graph and large language models through retrieval-augmented generation techniques. The system enables rapid retrieval of safety knowledge and automated generation of handling schemes based on analyzing anomaly root causes.

Based on real industrial application scenarios, an intelligent safety analysis software for the reaction-regeneration system of a fluid catalytic cracking unit was developed. With a design focused on a visual interactive interface and grounded in actual system data and knowledge, the effectiveness of the constructed safety knowledge graph and intelligent safety analysis methods in anomaly monitoring and handling has been validated.

Keywords: Fluid catalytic cracking unit, reaction-regeneration system, knowledge graph, anomaly diagnosis, knowledge base question answering

目 录

摘 要	I
Abstract	II
1 绪论	
1.1 研究背景与意义.....	(1)
1.2 国内外研究现状.....	(2)
1.3 论文结构与主要内容	(9)
2 需求分析及总体设计	
2.1 催化裂化反应再生系统概况	(12)
2.2 安全知识图谱构建与智能安全分析需求分析	(13)
2.3 安全知识图谱构建与智能安全分析总体设计	(15)
2.4 本章小结	(17)
3 催化裂化反应再生系统的安全知识图谱构建	
3.1 反应再生系统安全知识图谱构建框架	(18)
3.2 基于跨度分类的命名实体识别	(20)
3.3 基于大语言模型的关系三元组抽取	(31)
3.4 知识与数据驱动的变量因果图构建	(33)
3.5 安全知识图谱构建实验结果	(35)
3.6 本章小结	(36)
4 催化裂化反应再生系统的异常诊断	
4.1 反应再生系统异常诊断框架	(37)
4.2 基于图注意力网络和选择状态空间模型的异常检测	(38)
4.3 基于变量因果图和概率寻优的异常根本原因分析	(49)
4.4 本章小结	(52)

华中科技大学硕士学位论文

5 催化裂化反应再生系统的安全知识辅助问答

5.1	反应再生系统安全知识辅助问答框架	(53)
5.2	基于 Sentence-BERT 的知识文本嵌入	(54)
5.3	基于检索增强生成的检索与问答	(55)
5.4	安全知识辅助问答实验结果	(56)
5.5	本章小结	(59)

6 催化裂化反应再生系统的智能安全分析软件设计与实现

6.1	关键模块设计与实现	(60)
6.2	软件功能测试与分析	(70)
6.3	本章小结	(74)

7 总结与展望

7.1	工作总结	(75)
7.2	研究展望	(76)

致 谢	(77)
--------	------

参考文献	(78)
------	------

附录 1 攻读硕士学位期间取得的研究成果	(86)
----------------------	------

附录 2 攻读硕士学位期间参与的科研项目	(87)
----------------------	------

1 绪论

1.1 研究背景与意义

石油炼化行业是国民经济的重要支柱，与制造业、建筑业和国防军工等关键领域关联紧密^[1]，其生产过程涉及复杂的化学反应和高度耦合的工艺流程^[2]。随着数字化和信息化的快速发展，炼化装置的设备逐步连接至广域网，这在提升生产效率的同时，也带来了新的信息安全风险。近年来，该行业设备频繁遭受网络攻击，严重影响了生产的稳定性。在这一复杂的生产体系中，催化裂化装置作为核心设备，负责将重质油转化为轻质油，而其反应再生系统则是装置的核心系统^[3]。该系统在催化裂化过程中至关重要，一旦受到攻击，可能严重影响装置的稳定运行^[4,5]。因此，需要对反应再生系统的运行状态进行实时监测，以保障其安全性。

催化裂化装置反应再生系统在高温高压的复杂环境下运行，其过程变量之间存在高度复杂的耦合关系^[6]。一旦异常未能及时处理，可能引发设备故障，进而导致安全事故，造成严重的经济损失和人员伤亡^[7]。然而，该系统测点众多，依靠人工监控发现问题并制定有效措施的流程较为费时。此外，设备间物料与能量的连续稳定流动使过程变量呈现复杂的时空依赖性，而传感器测量过程中不可避免的噪声进一步干扰变量间的关联性^[8]。因此，实时异常检测对于反应再生系统的安全管理至关重要，但仅依靠异常检测难以帮助安全管理人员有效应对异常。准确识别异常的根本原因并提供合理的处理方案同样至关重要^[9,10]。然而，操作与维护知识主要以无结构文本形式存储，如何高效融合这些非结构化知识与传感器数据，实现精准且高效的安全分析，仍是亟待解决的关键问题^[11]。

在催化裂化装置反应再生系统的安全分析中，尽管已有多种方法应用，但在应对多变量耦合和非线性特征方面仍存在不足。传统方法通常仅依赖传感器数据这一单一数据源，忽视了过程中的知识性和经验性信息，从而限制了安全分析的全面性和准确性^[12]。尤其在复杂的催化裂化反应再生过程中，单纯依赖数据驱动的方法难以揭示异常的复杂特性和潜在因果关系^[13]。现有因果关系建模方法通常局限于单一数据源，缺乏对传感器数据与操作知识的有效整合^[14]。另外，若根本原因分析结果

华中科技大学硕士学位论文

的可解释性不足，会延迟异常的处理和干预^[15]。因此，反应再生系统需要融合多源数据的高可解释性安全分析方法。知识图谱作为一种结构化管理知识的工具，可以整合反应再生系统相关的安全知识，并与异常检测和根本原因分析结合，来提高安全分析方法的可解释性和实用性。

本文针对催化裂化装置反应再生系统的异常工况特性，提出了一种安全知识图谱构建与智能安全分析的方法。该方法可实现高精度的实时异常检测、精准的根本原因分析，并自动推荐异常处理方案，辅助安全管理人员快速应对异常。首先，通过构建催化裂化装置反应再生系统的安全知识图谱，对操作规程、历史异常及事故记录进行系统化整理，为安全分析提供结构化的语义支持。其次，结合多变量时间序列数据的动态特性，采用异常检测与根本原因分析技术，实现实时异常识别与根因分析。进一步，结合安全知识图谱与大语言模型，利用检索增强生成（Retrieval-Augmented Generation, RAG）方法自动推荐异常处理方案。所提方法融合数据驱动与知识驱动技术，在复杂环境下具备高精度和高可解释性的安全分析能力，可有效保障催化裂化装置反应再生系统的安全稳定运行。

1.2 国内外研究现状

近年来，随着信息安全事故的频发，工业领域的安全分析逐渐成为研究热点。国内外学者围绕安全知识图谱构建与安全分析等方面开展了大量研究，研究方法涵盖数据驱动、知识驱动以及二者结合的混合方法。为此，本节将依次介绍安全知识图谱构建的研究现状与安全分析的最新进展。

1.2.1 安全知识图谱构建领域研究现状

本节介绍安全知识图谱构建领域的研究现状，内容涵盖命名实体识别、关系三元组抽取以及工业安全知识图谱构建三个方面。其中，命名实体识别和关系三元组抽取是知识图谱构建的通用技术，而工业安全知识图谱构建则聚焦于面向工业场景的安全分析相关应用研究。

（1）命名实体识别研究现状

传统方法通常将命名实体识别（Named Entity Recognition, NER）任务视为一个

华中科技大学硕士学位论文

序列标注问题，即使用 BIO (Begin, Inside, Outside) 标注方案为文本中的每个词元分配相应的类别。许多学者采用循环神经网络 (Recurrent Neural Networks, RNN) 来处理该任务，并结合条件随机场 (Conditional Random Fields, CRF) 以提升模型性能^[16,17]。此外，卷积神经网络 (Convolutional Neural Networks, CNN) 在图像处理领域展现出了强大的能力。一些研究者将一维卷积应用于命名实体识别任务，并取得了较为优异的表现^[18,19]。近年来，预训练语言模型 (Pre-Trained Language Models, PLMs) 在表征学习方面取得了显著进展^[20]。越来越多的学者开始将其应用于文本序列表征，显著提升了命名实体识别模型的性能^[21]。然而，将 NER 任务视为序列标注问题的方式难以解析文本中存在的嵌套实体。因此，针对嵌套命名实体识别 (Nested Named Entity Recognition, NNER) 的研究逐渐受到学术界的广泛关注。

嵌套命名实体识别通常将一维的序列标注问题转换为二维的跨度分类问题。该方法首先利用预训练语言模型对文本序列进行表征，然后将其扩展至二维空间以进行跨度分类^[22,23]。此外，一些学者将嵌套命名实体识别转换为文本生成问题，从而解决序列标注方法难以识别嵌套实体的局限性^[24,25]。另有研究将命名实体识别任务进一步转化为更具体的问题。例如，Zhang 等人将其视为表征学习问题，通过最大化实体提及与其类型的向量表征之间的相似性来提升识别性能^[26]。这些方法不仅能够准确识别嵌套命名实体，同时在扁平命名实体的识别上也表现出较强的性能。然而，目前的研究尚未针对催化裂化装置反应再生系统的命名实体识别进行深入探讨，缺乏对特定领域特征的考虑。不过有一些学者在研究工业命名实体识别的通用方法。

工业命名实体识别的研究仍处于早期阶段，大多数研究仍采用传统的序列标注方法。Zhou 等人在工业机器人故障领域建立了一个名为 Fault-Data 的命名实体识别数据集，并基于 BERT-BiLSTM-CRF 进行命名实体识别^[27]。为了从工业表格数据中提取有价值的信息，一些学者采用基于 Transformer 的模型对表格进行表征，从而实现表格中的命名实体识别^[28]。构建工业命名实体识别模型通常需要大量数据，但由于商业竞争、安全性和隐私问题，行业相关方难以共享数据。然而，联邦学习为这一问题提供了一种可行的解决方案。Fu 等人提出了 FedDP 算法，该算法根据各参与方的数据质量分配权重，从而优化联邦学习在异构数据场景下的性能^[29]。但这些研究尚未考虑嵌套命名实体的影响，仅关注扁平命名实体的识别。

华中科技大学硕士学位论文

然而，工业领域的嵌套命名实体具有丰富的语义信息，未能有效识别这些实体将导致重要信息的丢失。因此，有必要结合催化裂化装置反应再生系统相关安全文本的特征，提出有针对性的嵌套命名实体识别方法。

(2) 关系三元组抽取研究现状

关系三元组抽取（Relational Triple Extraction, RTE）是知识图谱构建的关键步骤，旨在从文本中自动抽取头实体-关系-尾实体构成的三元组^[30]。关系三元组抽取方法大致可以分为三类：基于流水线的方法、联合学习方法和序列标注方法。

流水线方法将关系三元组抽取任务拆分为两个顺序执行的子任务：实体识别和关系分类。这种方法具有良好的模块化特点，但实体识别阶段的错误会直接影响后续关系抽取的准确性。早期的传统模型通常依赖结构化规则和依存句法分析，并结合简单分类器。这类方法在结构清晰、领域限定的场景中表现良好，但在面对开放领域文本时适应性较差^[31,32]。TME 模型对传统流水线方法进行了改进，引入翻译机制对候选三元组进行排序，从而提升了三元组的筛选效果^[33]。尽管经过了一系列改进，流水线方法在处理重叠三元组方面仍然存在明显不足，即同一个实体可能参与多种不同关系。这一问题推动了联合抽取模型的兴起。

联合抽取模型尝试同时识别实体和抽取关系，从而减少错误传播问题。PRGC 模型将 RTE 任务分解为关系判断、实体识别和主客体对齐三个子任务，并采用多任务学习框架来提升抽取的准确性^[34]。ROMGCJE 模型引入了关系感知的注意力机制，通过捕捉全局语义交互来增强实体与关系的对齐效果^[35]。双向翻译解码模型采用双向主客体对齐策略，突破了传统从左到右的顺序抽取模式^[36]。这些方法在整体抽取准确率上取得了显著提升，尤其是在重叠三元组的抽取任务中表现出色。

还有一些方法将关系三元组抽取视为一种结构化的序列标注问题，并设计了实体及关系联合标注方案。CasRel 模型是该方向上的一次重要突破，它将 RTE 任务转化为二元标注任务，大幅提升了重叠三元组的抽取性能^[30]。随后，层次化二元标注（Hierarchical Binary Tagging, HBT）^[37] 和双向树状标注（Bidirectional Tree Tagging, BiTT）^[38] 等框架在 CasRel 的基础上进一步优化了标注策略，从而提升了抽取结果的准确性。

然而，上述方法普遍依赖人工标注的数据集，并且模型训练过程往往较为复

华中科技大学硕士学位论文

杂，使用和迁移的便捷性仍然存在一定限制。近年来，大语言模型（Large Language Models, LLMs）在关系三元组抽取任务中展现出强大的潜力。依托其卓越的语言理解与推理能力，LLM 能够通过少样本提示或模板驱动的方式完成三元组的高效抽取^[39–41]。相较于传统监督学习方法，基于 LLM 的抽取方式对标注数据的依赖程度显著降低，且具备较好的开放域迁移能力。

（3）工业安全知识图谱构建研究现状

知识图谱作为一种基于图的知识存储与推理工具，最早由 Google 于 2012 年提出^[42]。近年来，知识图谱凭借其强大的知识关联与整合能力，逐渐受到学术界和工业界的广泛关注，尤其在工业过程安全领域展现出广阔的应用前景。

部分研究聚焦于从非结构化文本中自动抽取工业安全领域的实体与关系，从而构建安全知识图谱。例如，Pandithawatta 等人基于 METHONTOLOGY 方法论，开发了工作危害分析知识图谱（JHAKG），该图谱整合了来自领域专家与安全文档的结构化与隐性知识^[43]。Wu 等人采用 BERT-BiLSTM-CRF 模型，从事故报告中抽取建筑安全信息，实现了较高的抽取准确率与信息检索效果^[44]。除此之外，还有研究采用语义本体对安全知识进行形式化与标准化描述。Pedro 等人提出了一种基于链接数据的安全知识整合方法，能够有效融合建筑事故案例中存在的不一致安全信息，并支持基于 SPARQL 的灵活查询^[45]。

另一类研究更加关注构建完成的工业安全知识图谱在具体场景中的实际应用。例如，Mei 等人将计算机视觉与知识图谱推理相结合，利用 YOLOv5 目标检测算法识别工地不安全行为，并基于本体规则推理实现危险行为识别与告警^[46]。在实时监控之外，一些研究还探索了基于知识图谱的主动安全管理模式。Wen 等人提出一种混合主动安全模型，将基于知识的推理与预测性机器学习模型结合，实现工业危险的前置预警^[47]。Chen 等人开发了 Root-KGD 框架，将知识图谱与工业故障数据结合，提升了事故根因诊断能力^[48]。Liu 等人基于历史铁路事故数据构建了铁路事故知识图谱，并应用于危险源的量化风险评估^[49]。Mao 等人针对延迟焦化工艺构建了过程安全知识图谱，以支持工艺风险评估与安全管理^[50]。Wang 等人提出了一种面向工业设计的知识图谱构建方法，并以间接煤液化工艺为案例，构建了安全知识问答系统，提升了安全知识的检索与应用效率^[51]。此外，针对法规与安全标准的合规

性检查需求, Pandithawatta 等人展示了 JHAKG 如何从既往工作危害分析记录中挖掘合规信息, 助力安全文档的智能生成与更新^[43]。Pedro 等人构建了一个本体驱动的安全数据共享框架, 依托链接数据技术实现跨行业合规记录的标准化访问与灵活调用^[45]。Zhang 等人提出的煤矿安全知识图谱, 将安全检查记录与合规性要求关联存储在 Neo4j 图数据库中, 为事故分析与风险知识检索提供了有效支持^[52]。

现有研究普遍针对建筑、铁路、煤矿等行业领域展开, 较少关注化工过程安全, 尤其是面向催化裂化装置反应再生系统的专门研究。反应再生系统具有复杂的工艺流程以及多源异构的监测数据, 这对安全知识的结构化表示提出了更高要求。

1.2.2 安全分析领域研究现状

本节介绍安全分析领域的研究现状, 重点涵盖异常检测和根本原因分析两个方面。其中, 异常检测基于多变量时间序列数据, 旨在识别潜在的异常变化模式。根本原因分析则聚焦异常溯源, 目标是准确定位导致异常的根本原因。

(1) 异常检测研究现状

近年来, 多变量时间序列异常检测的研究逐渐从传统统计分析方法向深度学习方法转变, 形成了以深度学习为主的研究趋势。当前主流方法大致可分为三类: 基于预测的异常检测、基于重构的异常检测, 以及融合预测与重构的混合检测方法。

基于预测的异常检测方法通过历史时间序列预测未来, 并将预测值与实际值进行比较以识别异常。一些学者尝试使用时间序列预测模型进行异常检测。Chen 等人提出了一个新的多变量时间序列异常检测框架 GTA, 该方法结合图卷积网络和 Transformer 结构以建模时序依赖性^[53]。类似地, Hundman 等人提出 LSTM-NDT, 将长短期记忆 (Long Short-Term Memory, LSTM) 应用于航天器遥测数据的异常检测^[54]。此外, 一些研究还探索了将多种时间序列预测模型集成应用于异常检测。Wu 等人将 LSTM 与高斯贝叶斯模型相结合, 实现工业物联网的异常检测^[55]。Wang 等人通过回归模型预测电力负荷, 并集成多个回归模型以弥补对预测结果过度依赖所带来的不足^[56]。然而, 这类预测模型往往训练难度较高, 且对超参数设置较为敏感, 实用性受到一定限制。

基于重构的异常检测方法通过时间序列的重构误差来识别异常, 主要依赖自编

华中科技大学硕士学位论文

码器对时间序列模式的学习能力。Nguyen 等人在供应链管理领域应用了基于 LSTM 的自编码器进行异常检测^[57]。Shen 等人提出在循环自编码器中使用具有不同解码长度的解码器，并利用最高分辨率解码器的输出计算每个时间步的异常分数^[58]。此外，一些研究者在自编码器中加入卷积神经网络以提取空间依赖性。Zhang 等人提出了深度卷积自编码器，利用最大平均差异表征空间依赖性，并结合记忆网络以捕获时序依赖性^[59]。近年来，一些研究尝试对自编码器的编码空间进行约束，即变分自编码器（Variational Autoencoder, VAE）。Li 等人提出了平滑诱导序列变分自动编码器（Smooth Induced Sequential Variational Autoencoder, SISVAE）用于多变量时间序列的异常检测^[60]。Li 等人提出了一种结合主动学习和对比学习的多变量时间序列异常检测算法，并基于变分自编码器进行实现^[61]。此外，一些研究者引入图神经网络以学习多变量时间序列的空间依赖性^[62]。He 等人提出了一种基于图神经网络和长短记忆网络的变分自编码器，并应用于云系统的异常检测^[63]。Audibert 等人提出了一种逆向训练自编码器的快速稳定的方法，称为多变量时间序列无监督异常检测（USAD）^[64]。Su 等人提出 OmniAnomaly，将随机循环神经网络用于多变量时间序列异常检测，通过重构概率判断异常^[65]。Zong 等人提出了一种用于无监督异常检测的深度自编码高斯混合模型（DAGMM），并以端到端的方式同时联合优化深度自编码器和混合模型的参数^[66]。Tuli 等人提出了 TranAD，将深度 Transformer 网络用于异常检测和诊断，并应用重构误差来判断异常^[67]。然而，这些基于循环神经网络的重构方法普遍存在顺序解码带来的误差累积问题，影响了重构精度。

此外，部分研究尝试将预测与重构相结合，以提升异常检测的综合性能。Zhao 等人结合图注意力网络与一维卷积神经网络，对多变量时间序列进行表征，并联合执行预测和重构任务，融合两种误差识别异常^[68]。Chen 等人将重构模型深度卷积残差自编码器与预测模型 ConvLSTM 融合，有效提升了检测精度^[69]。

近年来，状态空间模型展现出其独特的优势，可解决传统循环神经网络结构顺序解码带来的误差累积问题。如选择状态空间模型 Mamba^[70]，借助其全局建模能力可避免顺序解码的局限，并有效捕捉时间序列中的长期依赖特性，使其更适合与自编码器结构结合。图神经网络的集成有助于变量的因果关联性的学习，从而增强模型学习能力。另外，结合多任务学习框架，同时进行预测与重构，可提升模型学习

华中科技大学硕士学位论文

时间序列模式的能力，进而提高异常检测能力。

(2) 根本原因分析研究现状

根本原因分析的目标是在异常发生时，能够高效准确构建变量间的因果模型并识别异常传播路径，从而快速找到异常的根本原因。根本原因分析方法可以分为两大类，分别是基于先验知识的方法和基于数据驱动的方法。

基于先验知识的方法能够利用工艺相关经验知识或是专家经验直接构建变量间的因果模型，常见的方法有符号有向图（Signed Directed Graph, SDG）与专家系统。Iri 等人首先将 SDG 图用于化工的故障根源诊断之中，通过化工过程变量之间相互关系形成 SDG 的边并以此构建变量间的因果模型，同时在异常工况下通过因果图中最大强连接部分来定位根本原因^[71]。Yang 等人使用 SDG 图来构建工业系统的过程变量间的因果关系模型来获取故障的传播路径，从而判断故障的根本原因，为了提高模型的搜索效率，将单层的 SDG 图模型转换为分层模型^[72]。孙秀茹等人基于复合数控机床液压系统结构，构建双主从式故障诊断因果模型结构，同时基于液压故障特征来设计故障诊断专家系统用于系统故障的根本原因分析^[73]。虽然基于先验知识的方法能够在控制结构较为简单的工业过程上进行可靠和准确的根本原因推理，但是随着现代过程工业的快速发展，工艺过程复杂化与异常来源多源化的发展使得先验知识难以全面覆盖日益增长的信息^[74]，由此基于数据驱动方法的研究得到了更加广泛的关注。

在工业控制过程领域基于数据驱动的根本原因分析方法主要包括格兰杰 (Granger) 因果分析，贝叶斯网络和传递熵。Deng 等人采用格兰杰因果分析方法构建工业控制系统的因果关系模型并进行根本原因分析，提出内核格兰杰因果分析，用于解决无法处理非线性数据的问题^[75]。Ma 等人提出一种新的非线性动态 Granger 因果关系分析方法，通过基于注意力的随机扰动门控循环单元进行非线性动态 Granger 因果关系分析，用于定位质量相关故障的根本原因和识别传播路径^[76]。由上述可知 Granger 因果分析用于捕捉变量间的线性因果关系，对于非线性关系需要结合其他方法。贝叶斯网络和传递熵本身可以用于分析非线性因果关系，因此成为了众多学者的研究热点。Yu 和 Rashid 提出一种动态贝叶斯网络用于工业过程中的根本原因诊断，该方法使用条件概率对因果关系进行建模，跟踪故障传播，并通过向后追溯确

定根本原因^[77]。Zope 等人提出具有动态离散化的贝叶斯网络在工业系统中进行根本原因分析，用于解决工业过程数据同时包含离散变量和连续变量的问题^[78]。贝叶斯网络方法主要局限在于现实工业过程难以满足方法的数据需求，因为网络的构建在任何异常模型下都需要足够的数据。传递熵将信息论中的概念引入因果分析之中，通过信息在变量之间的流动来度量变量间的因果关系。Zhao 等人提出了一种基于传递熵的工业根本原因分析方法，通过引入参数变量序列传递熵来实现快速可靠的因果模型构建^[79]。Chen 等人提出部分符号传递熵应用于检测非平稳工业时间序列中的因果关系，进而构建因果关系模型，解决工业系统中非平稳异常工况的根本原因分析问题^[80]。Duan 等人提出多尺度部分符号传递熵用于工业系统中的根本原因分析，在部分符号传递熵解决非平稳时间序列因果关系基础上，通过结合多尺度延时检测和非平稳符号映射，能够提高诊断准确性并消除虚假因果关系^[81]。

但现有的根本原因分析方法普遍缺乏对先验知识与数据驱动手段的综合考量。此外，仅提供异常的根本原因，实用价值仍显不足，亟需进一步补充异常的处理方案推荐。近年来，大语言模型发展迅速，可尝试结合其强大的推理能力，基于 RAG^[82]框架，将安全知识图谱与大语言模型深度融合，自动化推荐异常处理方案，从而进一步提升根本原因分析方法的实用性。

1.3 论文结构与主要内容

本文主要研究催化裂化装置反应再生系统的安全知识图谱构建与智能安全分析。鉴于现有方法缺乏对操作与维护文本知识的有效利用，而这对于安全分析的可解释性提升十分重要，本文首先构建安全知识图谱，涵盖历史异常和历史事故等信息，为后续智能安全分析提供知识支撑。随后，以催化裂化装置反应再生系统为研究对象，提出异常诊断方法，包括基于多任务变分自编码器的异常检测和基于因果图与概率寻优的根本原因分析。基于 RAG 框架，结合安全知识图谱与大语言模型，构建安全知识辅助问答系统，以结合诊断结果自动推荐异常处理方案。最终，整合上述方法，开发催化裂化装置反应再生系统的智能安全分析软件。本文共分为七个章节，各章节之间的关系如图 1-1 所示。

第一章为绪论，介绍催化裂化装置反应再生系统安全知识图谱构建与智能安全

华中科技大学硕士学位论文

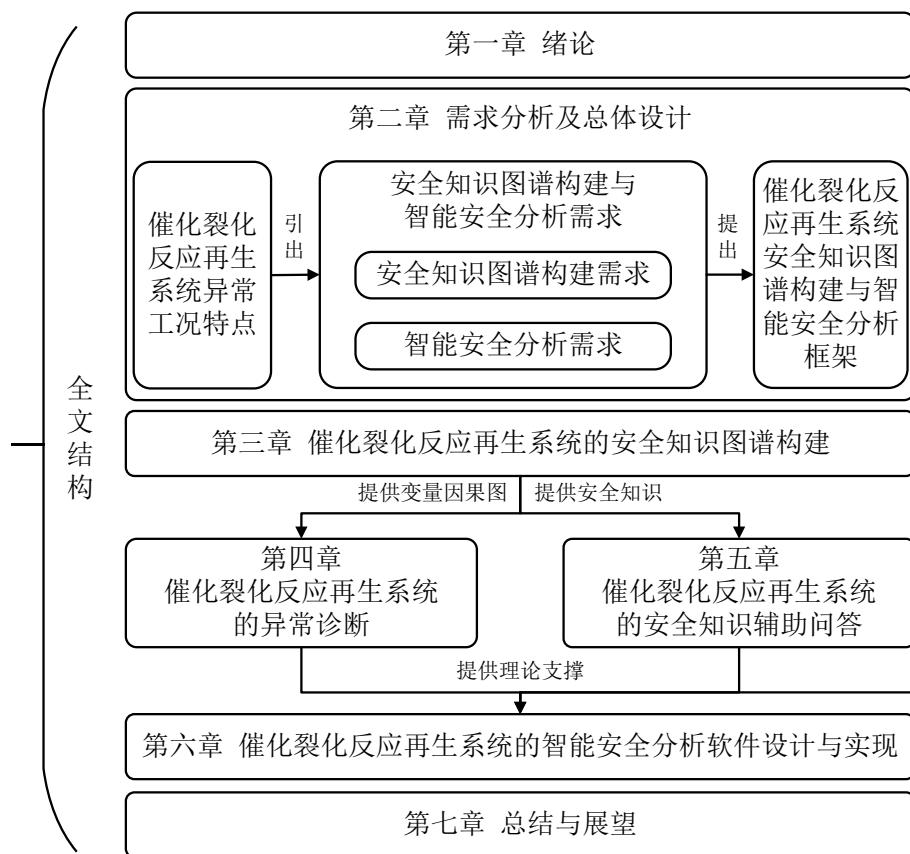


图 1-1 论文整体结构

分析的研究背景及其重要性。通过梳理相关研究现状，分析现有方法的优势与局限，明确研究目标和创新点，并概述本文的整体结构。

第二章首先介绍催化裂化装置反应再生系统的基本构成与工作原理，分析其异常工况的特征，并据此确定安全知识图谱构建与智能安全分析的需求。最后，提出安全知识图谱构建与智能安全分析框架，为后续研究提供理论基础。

第三章针对传统安全分析方法未能充分利用操作与维护知识等文本信息的局限性，提出了催化裂化装置反应再生系统安全知识图谱构建方法。首先，采用跨度分类方法，并结合双仿射注意力与卷积神经网络，提高嵌套命名实体识别的精度。针对工业命名实体识别中类别不平衡的问题，引入焦点损失以均衡不同类别的关注度。随后，利用大语言模型提取关系三元组，将非结构化文本转化为结构化数据，最终构建安全知识图谱。此外，考虑到智能安全分析对变量因果关系的需求，本文基于传递熵算法和变量因果描述相关文本建模变量间的因果关系，并将其存储至知识图

华中科技大学硕士学位论文

谱中，以支持后续的安全分析。

第四章针对催化裂化装置反应再生系统传感器数据中的噪声干扰与多变量复杂性，提出了一种基于多任务变分自编码器的时间序列异常诊断方法。该方法包括两个主要阶段：异常检测与根本原因分析。在异常检测阶段，结合多任务学习与变分自编码器结构，提高对噪声数据的鲁棒性。利用图注意力网络与选择状态空间模型，充分捕捉变量间的空间与时序依赖。在根本原因分析阶段，基于异常检测结果与变量因果图，通过概率推理确定异常的根本原因。

第五章针对异常诊断结果缺乏可解释性的问题，基于 RAG 框架，将安全知识图谱与大语言模型相结合，构建安全知识辅助问答系统。该系统不仅支持高效地查询安全知识图谱，还能够根据异常诊断结果自动生成异常处理方案。

第六章介绍了催化裂化装置反应再生系统智能安全分析软件的设计与实现。基于前述研究成果，本章构建了智能安全分析软件，并详细阐述其关键功能模块的设计与实现，以及功能测试与分析。

第七章总结了本文提出的催化裂化装置反应再生系统安全知识图谱构建与智能安全分析方法，分析了方法的局限性，并对未来的研究方向进行了展望。

2 需求分析及总体设计

本章将结合工艺流程图对催化裂化装置反应再生系统工艺流程进行简要介绍，并总结催化裂化装置反应再生系统的特。在此基础上，分析催化裂化装置反应再生系统异常工况的特点，进而总结智能安全分析的难点，接着针对研究难点引出催化裂化装置反应再生系统安全知识图谱构建与智能安全分析的需求，最后提出本文的安全知识图谱构建与智能安全分析方法的总体设计。

2.1 催化裂化反应再生系统概况

本文以某炼油厂 80 万吨/年催化裂化装置的反应再生系统为对象进行安全知识图谱构建与智能安全分析的研究，其工艺流程图如图 2-1 所示。催化裂化装置包括

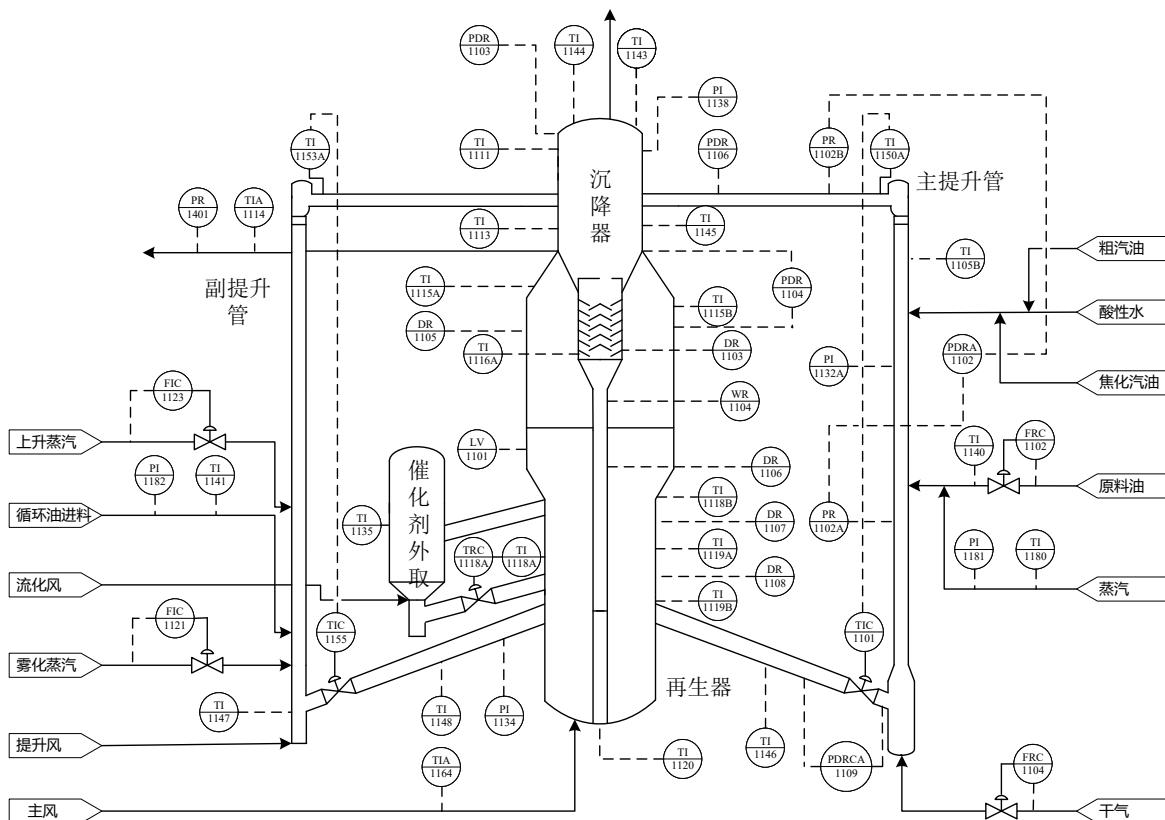


图 2-1 催化裂化装置反应再生系统工艺流程图

反应再生系统、分馏系统、吸收稳定系统和大型动力机组系统。其中，反应再生系统是其核心工艺环节，主要负责将重质油通过催化剂的作用裂解成更高价值的轻质油品。该系统由反应部分和再生部分组成，通过催化剂的循环使用连接。在反应部分，原料油被加热并与催化剂混合，在高温条件下完成裂解反应，生成轻质油和其他化学物质。反应过程中的催化剂由于积碳逐渐失活，需要在再生部分通过高温焚烧除去积碳，恢复活性，并重新循环到反应部分使用。整个反应再生系统的高温、自动化程度高，反应器和再生器之间的催化剂循环至关重要，因此在运行过程中需特别关注油气与空气的互窜问题，避免因异常情况导致的爆炸风险。网络攻击可能对传感器数据进行篡改，导致催化裂化过程不再稳定，从而引起异常，甚至导致安全事故。

2.2 安全知识图谱构建与智能安全分析需求分析

催化裂化装置反应再生系统在运行过程中可能会遇到多种异常情况，如设备温度或压力异常波动等。这些异常不仅会影响装置的效率，还可能导致设备故障或安全事故。本节在分析催化裂化装置反应再生系统异常工况特点的基础上，提出催化裂化装置反应再生系统的安全知识图谱构建与智能安全分析的需求。

2.2.1 催化裂化反应再生系统异常工况特点

由于催化裂化装置反应再生系统包含众多强耦合的过程变量，其测点数据存在复杂的时空依赖性。因此，在网络攻击引发的异常工况下，过程数据的表现形式也较为复杂。一般而言，异常工况下的过程数据具有以下特点：

- 1) 时序依赖性变化：异常发生时，某些测点的过程变量数据可能出现滞后、突变或趋势偏移，破坏正常状态下的时序依赖性。例如，攻击可能导致传感器数据失真，使某些温度或压力数据出现异常突变，与历史趋势明显不符。
- 2) 空间依赖性破坏：反应再生系统由多个耦合设备组成，各过程变量数据通常存在较强的空间依赖性。然而，在网络攻击或设备故障的影响下，原本关联紧密的变量数据可能表现出不一致的变化趋势。
- 3) 数据噪声增强：异常工况可能引入额外的噪声，使变量数据的波动幅度增大。例如，传感器受到干扰后，采集的变量数据可能呈现高频抖动或随机波动。

图 2-2 展示了同一场景下两个过程变量的正常与异常变化曲线。其中，图 2-2 (a)

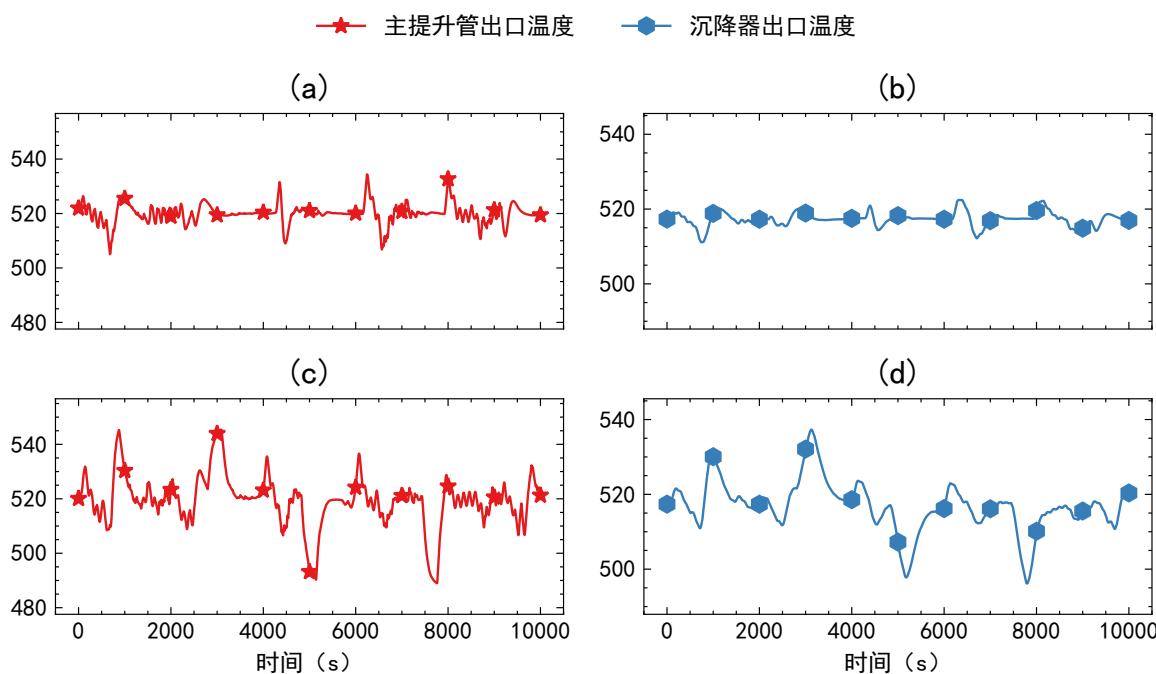


图 2-2 同一场景下的两个过程变量的正常与异常变化曲线

和 (b) 分别为两个变量的正常振荡曲线，二者表现出较强的相关性。而图 2-2 (c) 和 (d) 则分别展示了异常情况下的变量变化，可以观察到其时空依赖性和噪声特性均发生明显变化，增加了智能安全分析的难度。这一现象进一步说明了构建催化裂化装置反应再生系统安全知识图谱并结合异常诊断方法进行智能安全分析的重要性。

2.2.2 催化裂化反应再生系统安全知识图谱构建与智能安全分析需求

在 2.2.1 节中，对催化裂化装置反应再生系统在异常工况下的过程数据特点进行了分析。这些特点使数据表现出较高的不确定性和复杂性，增加了异常诊断的难度。此外，传统异常诊断方法通常只能识别异常的根本原因，但缺乏有效的处理方案建议。因此，将安全知识图谱结合异常诊断，不仅能提供结构化、可解释的智能安全分析框架，还能为运维人员提供合理的异常处理方案。为了更好地结合安全知识图谱开展智能安全分析，其构建应满足以下基本需求：

- 1) 历史异常与事故记录：安全知识图谱应涵盖催化裂化装置反应再生系统的历 史异常与事故信息，包括其发生原因、表现特征及相应的解决方案，以便在 异常发生时推荐合理的处理方案。

2) 过程变量因果图建模：由于反应再生系统的异常状态具有复杂的时空依赖性，且异常诊断需依赖过程变量因果图进行根本原因分析，安全知识图谱应建立测点间的关联关系，确保异常传播路径的可追溯性。

为了在异常早期及时采取干预措施，防止其升级为严重事故，在检测出催化裂化装置反应再生系统异常的基础上，还需进一步分析其根本原因，并结合安全知识图谱提供科学合理的处理方案。根据 2.2.1 节所述的异常工况特点，催化裂化装置反应再生系统的智能安全分析应满足以下需求：

- 1) 精准高效的异常检测：结合多变量时间序列异常检测算法，对过程变量的时间序列进行实时监测，判断其时空依赖性是否发生变化，以此识别异常并实现早期预警。
- 2) 高可解释性的异常根因分析：基于异常检测得到的变量异常分数和过程变量因果图，进行基于异常概率的根本原因分析，回溯异常传播路径，识别可能的异常根本原因。
- 3) 异常处理方案推荐：在确认异常根本原因后，结合安全知识图谱推荐最佳处理方案。例如，对于某些异常，可调整工艺参数进行修正，而另一些异常可能需要人工干预，安全知识图谱应提供相应的决策支持。

2.3 安全知识图谱构建与智能安全分析总体设计

基于 2.2 节的需求分析，本节提出催化裂化装置反应再生系统的安全知识图谱构建与智能安全分析方法，其框架如图 2-3 所示，主要可以分为催化裂化装置反应再生系统安全知识图谱构建、异常诊断和安全知识辅助问答三部分，最终基于这三部分方法实现了智能安全分析软件，以探索所提方法在真实场景下的实用性。

安全知识图谱的构建包括两个核心部分：一是对催化裂化装置反应再生系统的安全知识进行结构化管理，二是构建过程变量的因果关系图。针对安全知识，首先采用跨度分类进行命名实体识别，并利用大语言模型抽取关系三元组，生成结构化数据，以构建安全知识图谱。此外，由于异常诊断依赖过程变量的因果图，本文结合知识驱动和数据驱动的方法进行因果关系建模。在知识驱动方法中，利用大语言模型从催化操作规程中提取因果关系；在数据驱动方法中，采用传递熵从时间序列数据中挖掘因果关联。最终，通过预定义的融合规则，将两种方法构建的因果图合

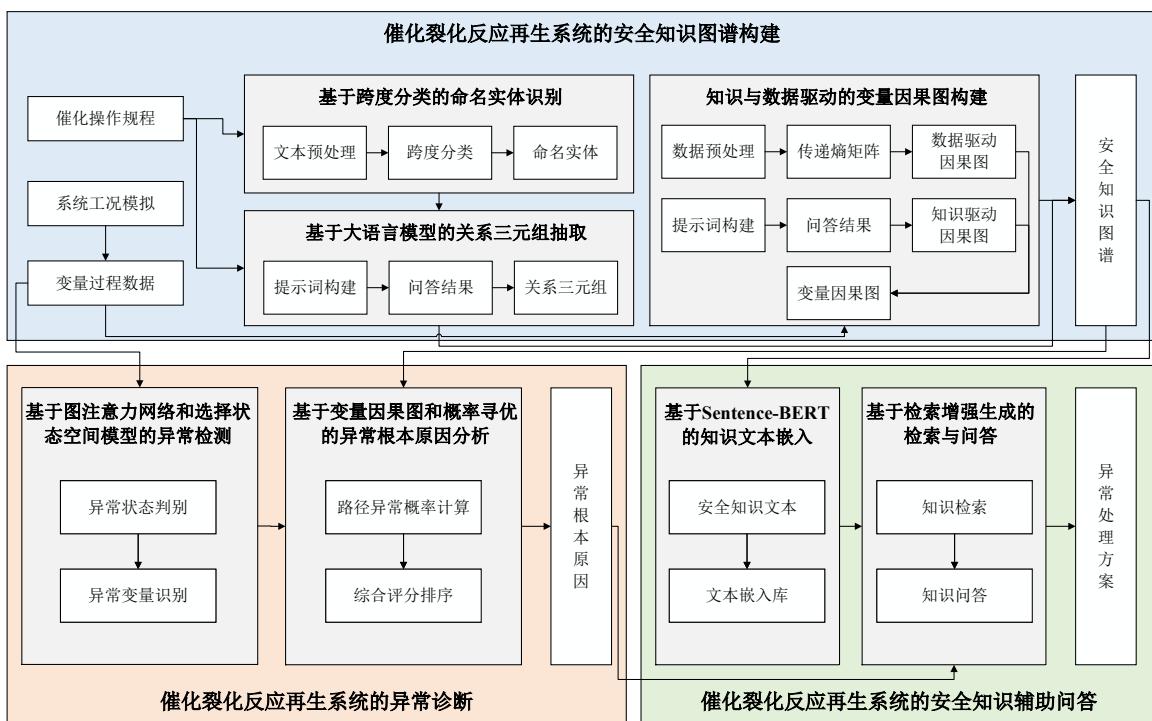


图 2-3 催化裂化反应再生系统的安全知识图谱构建与智能安全分析框架

并，并存入安全知识图谱，以增强其信息完整性和实用性。

异常诊断包括异常检测和根本原因分析两个部分。在异常检测方面，本文提出了一种多任务变分自编码器，用于捕捉时间序列中的时空依赖性。该模型结合多任务学习和变分自编码器架构，并融合选择状态空间模型、长短期记忆网络和图注意力网络，同时建模时序和空间依赖性。模型在正常数据上训练，以学习标准模式，并通过计算基于预测误差和重构误差的异常分数来识别异常，为每个变量计算异常分数，并实现精确的变量级异常检测。在根本原因分析阶段，检测出的异常变量将结合变量因果图进行溯源分析。首先，将异常分数转换为概率，以估计因果图中特定路径作为异常传播路径的可能性。然后，对每个异常变量，沿因果图递归追踪其传播路径。如果某条路径上的异常概率大于设定阈值，则路径中最后一个节点被识别为异常的根本原因。该方法不仅能够精准识别异常变量，还能有效确定其潜在根因，提高异常诊断的可解释性。

在识别到异常根本原因后，基于 RAG 框架，结合安全知识图谱与大语言模型，构建安全知识辅助问答系统，并基于异常诊断结果自动推荐可执行的异常处理方案。

华中科技大学硕士学位论文

针对诊断出的根本原因，系统从安全知识图谱中检索相关条目，并利用大语言模型生成针对性的异常处置建议。该方法提升了智能安全分析的实用性，帮助安全管理人人员高效、精准地应对异常情况。

2.4 本章小结

本章对催化裂化装置反应再生系统的工艺流程及其运行特点进行了介绍，并结合系统自身的特性，分析了异常工况下的安全分析需求。在此基础上，提出了一种综合的安全知识图谱构建与智能安全分析框架。该框架融合安全知识图谱、数据驱动的异常检测方法、基于过程变量因果图的根本原因分析方法与基于安全知识辅助问答的异常处理方案推荐，实现对催化裂化装置反应再生系统的实时监测和智能安全分析。该安全知识图谱构建与智能安全分析框架主要包括安全知识图谱构建、异常诊断和安全知识辅助问答三个核心部分。其中，安全知识图谱包括历史异常和事故信息，以提供后续异常处理方案推荐以知识支撑。异常诊断部分包括异常检测与根本原因分析。安全知识辅助问答基于安全知识图谱与大语言模型，可结合异常诊断结果为异常处理提供可解释的处理方案。本章提出的安全知识图谱构建与智能安全分析方法将在后续章节中进行详细介绍。

3 催化裂化反应再生系统的安全知识图谱构建

为了在诊断异常根本原因后提供可行的处理方案，需要对催化裂化装置反应再生系统的相关文本知识进行结构化管理。具体而言，需将非结构化的文本数据转化为结构化数据，如知识图谱，并基于该图谱提供异常处理方案所需的知识。催化裂化装置反应再生系统的安全相关知识包括历史异常、事故信息及相关设备和解决方案。本章首先采用跨度分类进行命名实体识别，然后利用大语言模型抽取关系三元组，获得结构化数据，构建安全知识图谱，为后续的异常处理方案推荐提供支持。此外，鉴于异常诊断过程中需要利用过程变量的因果图，本章将结合文本数据和过程数据，建模变量间的因果关系，并将其存储于安全知识图谱中。

3.1 反应再生系统安全知识图谱构建框架

本文以催化操作规程为文本数据源，构建安全知识图谱。催化操作规程包含大量与催化裂化装置反应再生系统相关的文本数据，如操作规程、历史异常和事故记录等。这些文本涵盖了装置操作的标准流程、设备工作原理、维护要求，以及在出现异常或故障时的应急处理措施。图 3-1 展示了催化裂化装置反应再生系统安全知识图谱的构建框架。该框架主要分为四步：首先，基于跨度分类对催化操作规程中的命名实体进行识别，提取设备、参数等关键实体。接下来，利用大语言模型结合已提取的命名实体进行关系三元组抽取，得到三元组形式的安全知识。然后，结合有关变量因果关系的文本数据和过程数据，进行因果建模，构建过程变量的因果图。最后，将所有这些结构化数据存储至 Neo4j 中，形成催化裂化装置反应再生系统的安全知识图谱。在构建安全知识图谱之前，需要设计本体。本体是某一特定领域内概念的结构化且明确的表示，通常包括一组类或概念及其属性，用于描述每个概念的特征和属性。同时，本体还表示类与属性之间的关系，并包含适用于这些关系的约束或限制。本文创建了催化裂化装置反应再生系统的安全知识图谱本体，包含八个类：异常、原因、现象、解决方案、事故、设备、变量与测点。在本体设计中，除了记录异常及其原因外，还包含了其他附加信息。这些信息有助于在后续的异常处理

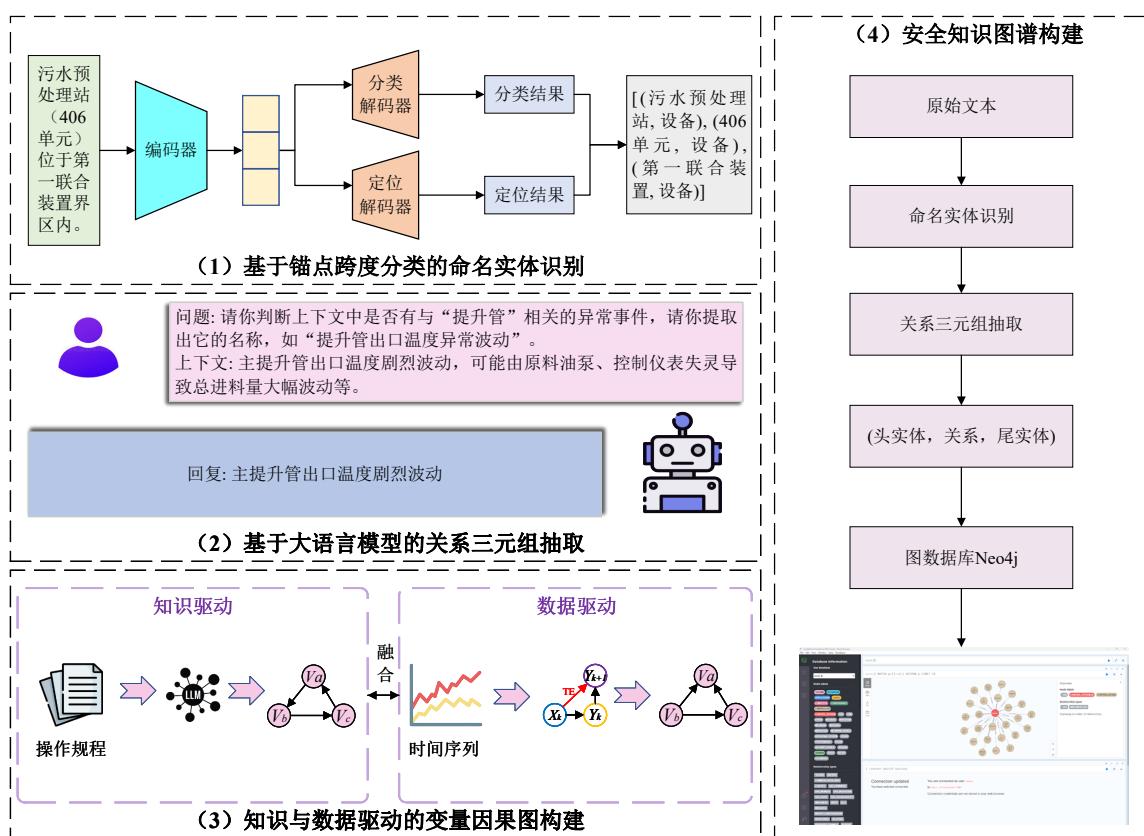


图 3-1 催化裂化装置反应再生系统安全知识图谱构建框架

方案推荐中提供更精准的结果。该本体围绕异常作为核心, 通过定位特定异常, 可以检索与该异常相关的所有信息。图 3-2 展示了催化裂化装置反应再生系统安全知识图谱本体的整体结构, 包含八个类和八个关系。后续将在此本体的基础上进行数据抽取, 从而构建一个能够支持异常处理方案推荐的安全知识图谱。

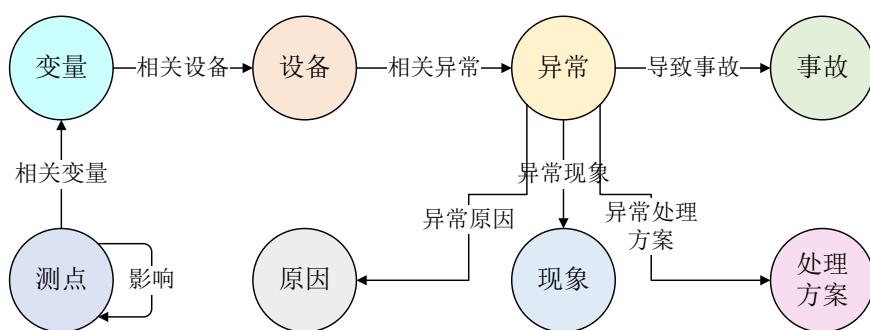


图 3-2 催化裂化装置反应再生系统安全知识图谱本体

3.2 基于跨度分类的命名实体识别

在催化裂化装置反应再生系统安全知识图谱的构建过程中，命名实体识别是关键环节，旨在从非结构化文本中提取设备、材料、变量、指标等命名实体。然而，催化操作规程中的命名实体往往存在嵌套现象。因此，所提方法需具备对嵌套命名实体的识别能力，以确保安全知识图谱的构建质量。本节首先介绍命名实体识别任务的基本定义，随后说明催化裂化装置反应再生系统命名实体识别数据集的构建流程。接着，详细描述基于跨度分类的命名实体识别模型的具体结构，并通过实验验证其效果，最后对实验结果进行分析与总结。

3.2.1 任务定义

给定一个文本序列 $\mathbf{X} = \{x_1, x_2, \dots, x_n\}$ ，其中 n 表示序列的长度。任务是识别 \mathbf{X} 中的每个命名实体，并为其分配一个标签 $y \in \mathbf{Y}$ ，其中 \mathbf{Y} 表示预定义的实体类型列表。在此过程中，文本中的每个单词或符号被称为“词元”。受到 Wei 等人^[30] 启发，本文不直接确定每个词元的类别，而是通过确定每个词元是否作为实体的起始或终止索引来进行处理。假设 i 是起始索引， j 是终止索引，且满足条件 $i \leq j$ ，需要判断从第 i 个词元到第 j 个词元的跨度是否能构成一个有效的命名实体。

3.2.2 命名实体识别数据集构建

数据来源是影响命名实体识别任务质量的关键因素。为确保数据集具备良好的代表性和行业适用性，本文从催化操作规程文档中收集语料，涵盖设备启动、停机、异常处置等关键操作步骤。所有文本均为中文，并包含部分带有英文缩写的行业术语。数据处理时，统一标注风格，确保标注的一致性和规范性。由于原始文本格式混乱，且存在大量冗余符号和无关信息，因此需对其进行标准化预处理。具体包括：删除非必要的特殊词元、表格结构信息及特殊符号；对文本进行分句处理；统一单位和缩写格式，如将“°C”转换为“摄氏度”；同时剔除非技术性描述与免责声明等无关内容，从而提升数据质量。在催化裂化这一化工领域，涉及多种重要的工业实体类型。结合智能安全分析的实际需求，本文定义了设备、材料、指标和变量四类命名实体。标注工作采用 Doccano 工具完成，该工具支持嵌套命名实体标注，并以划线标注的方式呈现。标注过程中，先由两名资深人员完成初步标注，再通过 ChatGPT

华中科技大学硕士学位论文

进行校对，以提高标注的准确性与一致性。在催化操作规程中，部分命名实体（如设备名称）经常存在嵌套现象。例如，“外取热器提升管”和“提升管”之间出现嵌套。为此，标注流程特别支持嵌套命名实体的标注。最终，通过 Doccano 的导出功能，生成 JSONL 格式文件。该数据集命名为 IndusNER，其标注示例如表 3-1 所示。

表 3-1 命名实体标注示例

文本	标签
装置的两个再生器重叠布置，一段再生器位于二段再生器之上。	[[0, 2, 设备], [5, 8, 设备], [13, 18, 设备], [20, 25, 设备]]
污水预处理站（406 单元）位于第一联合装置界区内。	[[0, 6, 设备], [7, 12, 设备], [15, 21, 设备]]
在硫含量较高时，则需用加氢脱硫装置进行处理，提供催化原料。	[[11, 17, 设备], [24, 28, 材料]]

本文还对 IndusNER 数据集中各类别实体的数量进行了统计，结果如表 3-2 所示。在训练集、测试集和验证集中，设备类实体的数量约为材料类实体的三倍。此

表 3-2 IndusNER 数据集中不同实体类型的数量统计

类别	训练集	测试集	验证集	总计
设备	3374	634	673	4681
材料	1255	268	272	1795
指标	427	107	89	623
变量	1721	349	389	2459

表 3-3 IndusNER 数据集的关键统计信息

统计项	训练集	测试集	验证集	总计
句数	1439	308	310	2057
词元数	48197	9945	10228	68370
实体数	4629	902	945	6476
句平均词元数	33.49	32.29	32.99	33.24
句最大词元数	233	212	131	233

外，本文还统计了其他关键信息，详见表 3-3。整体来看，IndusNER 仍是一个规模

较小的工业命名实体识别数据集，共包含 2057 个句子和 6476 个实体提及。数据集中词元总数为 68370 个，平均每句包含 33.24 个词元，单句最多包含 233 个词元。

3.2.3 命名实体识别框架

本文所提命名实体识别方法 BERT-Industry，整体包括实体定位和实体分类两个部分，并采用共享编码器的方式，与两个解码器进行端到端联合训练，如图 3-3 所示。具体而言，首先利用预训练语言模型 BERT 获取文本序列的嵌入表征。在实体定位网络中，分别通过两个独立的多层感知机提取词元的边界特征，并预测每个词元作为实体头部和尾部边界的概率。然后，将词元的头部和尾部边界概率向量通过外积操作生成跨度概率矩阵，并与设定阈值对比，从而解析得到命名实体的跨度列表。在实体分类网络中，先通过双仿射注意力机制将词元嵌入转换为二维矩阵，随后利用卷积神经网络提取空间特征。紧接着，通过多层感知机预测每个跨度属于特定类型实体的概率，并与阈值对比，解析出每个跨度对应的实体类别列表。最终，将实体定位和实体分类的结果融合，形成最终的命名实体识别结果。此外，考虑到基于跨度分类的这种方式，标签中 0 和 1 的数量差异明显，为平衡各类别的关注度，训练过程中引入焦点损失（Focal Loss，FL），以增强对少数类别的分类能力。

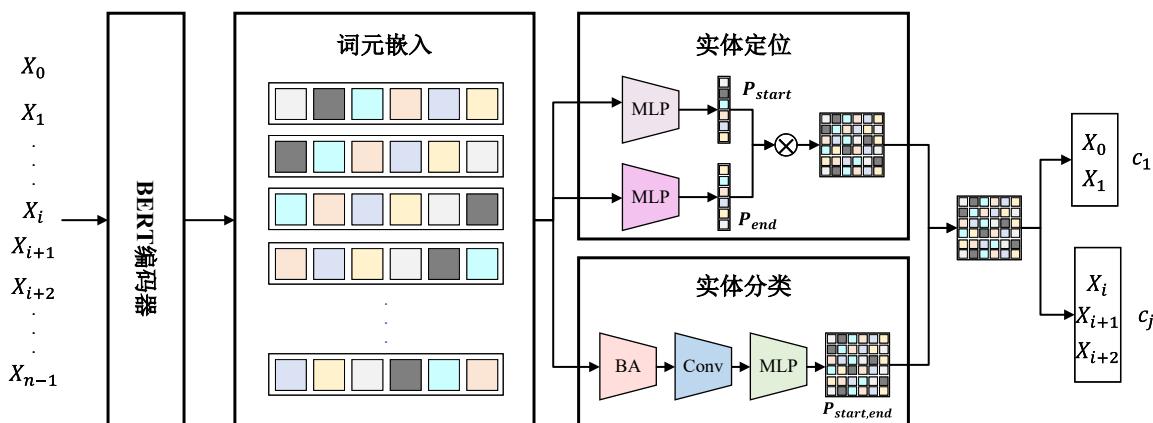


图 3-3 催化裂化装置反应再生系统命名实体识别方法的模型架构

3.2.4 模型详情

(1) 文本表征

给定文本序列 \mathbf{X} , 命名实体识别任务的目标是从中提取有效的实体跨度 $\mathbf{X}_{\text{start}, \text{end}}$, 其中 start 和 end 分别表示该实体的起始和终止位置。为此, 可以使用 BERT 作为骨干网络。BERT 作为一种预训练语言模型, 经过大规模语料的预训练, 能够有效捕捉文本的上下文信息, 并生成每个词元的高质量表征, 为命名实体识别提供有力支持。在模型输入端, 将 \mathbf{X} 输入 BERT, 经过多层 Transformer 编码器处理后, 得到文本的嵌入矩阵 $\mathbf{E} \in \mathbb{R}^{n \times d}$, 其中 n 为文本长度, d 为 BERT 最后一层输出向量的维度。每个词元对应的嵌入向量结合了上下文信息, 反映了其在句子中的语义特征。通过这种方式, BERT 为每个词元提供了语义丰富的表征, 为后续的命名实体识别奠定基础。

(2) 跨度选择

根据 Wei 等人^[30] 的方法, 可以使用两个分类器分别判断每个词元是否为实体的起始索引和终止索引。通过这种方式, 模型能够输出多个起始和终止索引, 从而实现对所有实体的提取。随后, 还需进一步判断哪些起始和终止索引能够组成有效实体。为此, 将一维词元序列转换为二维跨度矩阵, 枚举所有可能的起始和终止索引组合, 并从中筛选出有效的命名实体。

在实体定位网络中, 给定文本序列 \mathbf{X} , 经过 BERT 编码后得到嵌入矩阵 \mathbf{E} , 模型首先预测每个词元作为某一实体起始索引的概率, 如式 (3-1):

$$\mathbf{P}_{\text{start}} = \text{sigmoid}(\text{MLP}_{\text{start}}(\mathbf{E})) \in \mathbb{R}^{n \times 1} \quad (3-1)$$

$\text{MLP}_{\text{start}}$ 由两个全连接层组成, 激活函数为 \tanh , 具体如式 (3-2):

$$\text{MLP}_{\text{start}}(\mathbf{E}) = \tanh(\mathbf{E} \cdot \mathbf{W}_{\text{start}_1}) \cdot \mathbf{W}_{\text{start}_2} \quad (3-2)$$

$\mathbf{W}_{\text{start}_1} \in \mathbb{R}^{d \times m}$ 和 $\mathbf{W}_{\text{start}_2} \in \mathbb{R}^{m \times 1}$ 是需要学习的权重。作为非线性激活函数, sigmoid 可以将输入映射到 0 到 1 的范围内。 $\mathbf{P}_{\text{start}}$ 中索引 i 处的元素表示 i 作为实体起始索引的概率。终止索引预测与起始索引预测完全相同, 只不过有另外一组权重 $\mathbf{W}_{\text{end}_1}$ 和 $\mathbf{W}_{\text{end}_2}$ 来计算概率矩阵 $\mathbf{P}_{\text{end}} \in \mathbb{R}^{n \times 1}$ 。

在实体分类网络中, 给定文本序列 \mathbf{X} 经 BERT 输出的嵌入矩阵 \mathbf{E} , 模型首先利用双仿射注意力 (Biaffine Attention, BA) 将其扩展到二维空间, 其中每个元素表示

一个跨度的嵌入，如式 (3-3):

$$\mathbf{A} = \text{BiaffineAttention}(\mathbf{E}) \in \mathbb{R}^{n \times n \times e} \quad (3-3)$$

其中 e 是双仿射注意力的输出维度，即每个跨度的嵌入长度。然后应用卷积神经网络从 \mathbf{A} 中提取空间特征，如式 (3-4):

$$\mathbf{H} = \text{CNN}(\mathbf{A}) \in \mathbb{R}^{n \times n \times h} \quad (3-4)$$

最后，确定由其起始和终止索引表示的跨度是否匹配，如式 (3-5):

$$\mathbf{P}_{\text{start},\text{end}} = \text{sigmoid}(\text{MLP}_{\text{match}}(\mathbf{H})) \in \mathbb{R}^{n \times n \times c} \quad (3-5)$$

其中 c 是命名实体类别的数量。

最终，需要对两个子网络的结果进行解析，使用超参数 t 来解析结果，其中 t 表示阈值。所有大于阈值 t 的预测结果被认为是 1，这意味着如果 $\mathbf{P}_{\text{start}}^{(i)} > t$ ，则 i 可以作为起始索引。起始索引、终止索引以及匹配结果列表的计算如式 (3-6)、(3-7) 和 (3-8):

$$\hat{\mathbf{I}}_{\text{start}} = \{i | \mathbf{P}_{\text{start}}^{(i)} > t_{\text{start}}, i = 1, \dots, n\} \quad (3-6)$$

$$\hat{\mathbf{I}}_{\text{end}} = \{j | \mathbf{P}_{\text{end}}^{(j)} > t_{\text{end}}, j = 1, \dots, n\} \quad (3-7)$$

$$\hat{\mathbf{I}}_{\text{start},\text{end}} = \{(i, j, k) | \mathbf{P}_{\text{start},\text{end}}^{(i,j,k)} > t_{\text{match}}, i = 1, \dots, n, j = 1, \dots, n, k = 1, \dots, c\} \quad (3-8)$$

对于 $\hat{\mathbf{I}}_{\text{start},\text{end}}$ 中的元素 (i, j, k) ，确定 i 是否属于 $\hat{\mathbf{I}}_{\text{start}}$ 且 j 是否属于 $\hat{\mathbf{I}}_{\text{end}}$ 。如果条件满足，则表示从第 i 个词元到第 j 个词元的跨度是一个预测的实体，其类别为 k 。

3.2.5 训练与测试

在训练阶段，文本序列 \mathbf{X} 与两个标签序列 $\mathbf{Y}_{\text{start}}$ 和 \mathbf{Y}_{end} 相关联，长度为 n 。这些标签序列指示每个词元 x_i 是否对应一个实体的起始或终止索引。使用焦点损失来衡量 $\mathbf{P}_{\text{start}}$ 与 $\mathbf{Y}_{\text{start}}$ 之间的距离，以及 \mathbf{P}_{end} 与 \mathbf{Y}_{end} 之间的距离。因此，预测起始索引和终止索引有两个独立的损失函数，如式 (3-9) 和 (3-10):

$$\mathcal{L}_{\text{start}} = \text{FL}(\mathbf{P}_{\text{start}}, \mathbf{Y}_{\text{start}}), \quad \mathcal{L}_{\text{end}} = \text{FL}(\mathbf{P}_{\text{end}}, \mathbf{Y}_{\text{end}}) \quad (3-9)$$

$$\mathcal{L}_{\text{loc}} = \mathcal{L}_{\text{start}} + \mathcal{L}_{\text{end}} \quad (3-10)$$

令 $\mathbf{Y}_{\text{start},\text{end}}$ 表示真实标签，指示每个起始索引与终止索引构成特定类型实体的情况。起始-终止匹配损失如式 (3-11) 所示：

$$\mathcal{L}_{\text{cls}} = \text{FL}(\mathbf{P}_{\text{start},\text{end}}, \mathbf{Y}_{\text{start},\text{end}}) \quad (3-11)$$

焦点损失是一种用于解决类别不平衡分类问题的损失函数，其计算公式如式 (3-12)：

$$\text{FL}(p_i, y_i) = -y_i(1 - p_i)^\gamma \log p_i \quad (3-12)$$

其中 p_i 表示第 i 个元素被预测为 1 的概率， y_i 表示第 i 个元素的真实值， γ 是超参数。总体训练目标是最小化式 (3-13)：

$$\mathcal{L} = \alpha \mathcal{L}_{\text{loc}} + \beta \mathcal{L}_{\text{cls}} \quad (3-13)$$

α 和 β 属于 $[0, 1]$ 范围，是用来调节它们各自在总体训练目标中贡献的超参数。两项损失函数在端到端的方式下共同训练，并共享 BERT 编码器。

在测试阶段，首先基于 $\hat{\mathbf{I}}_{\text{start}}$ 和 $\hat{\mathbf{I}}_{\text{end}}$ 分别选取起始和终止索引。随后，利用索引匹配结果 $\hat{\mathbf{I}}_{\text{start},\text{end}}$ 对齐已提取的起始与终止索引，最终获得命名实体列表。

3.2.6 实验结果

(1) 评价指标

在命名实体识别任务中，为了全面评估模型的性能，常使用三项评价指标：精确率 (Precision)，召回率 (Recall) 和 F1 分数。精确率衡量模型预测出的命名实体中有多少比例是真正的实体，可以定义为：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3-14)$$

其中，TP (True Positive) 表示正确识别的命名实体的数量，FP (False Positive) 表示错误识别为命名实体的数量。精确率越高，表示模型的预测结果越准确，错误识别的实体越少。召回率衡量的是模型能够识别出多少实际存在的命名实体，其定义为：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3-15)$$

其中，FN (False Negative) 表示遗漏的命名实体的数量。召回率越高，意味着模型能覆盖更多的真实实体，漏检的实体越少。F1 分数是精确率和召回率的调和平均数，

华中科技大学硕士学位论文

用于综合评价命名实体识别模型的性能。它特别适用于精确率和召回率之间存在权衡的情况。F1 分数的计算公式如式 (3-16):

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3-16)$$

F1 分数的值越高，表示模型在精确率和召回率之间取得了更好的平衡，能够有效地识别命名实体，同时避免误识别和漏识别。

(2) 基准模型

为了评价所提模型的有效性，选取了一些基准模型进行对比实验，如下所示：

- 1) BERT-Tagger: Devlin 等人^[20] 提出了一种命名实体识别方法 BERT-Tagger，使用 BERT 作为文本序列的编码器来表征序列，并将命名实体识别视为一个序列标注问题。
- 2) BERT-BiLSTM-CRF: Dai 等人^[83] 提出了 BERT-BiLSTM-CRF，使用 BERT 作为编码器来表征文本序列。然后，采用双向长短时记忆网络（Bidirectional Long Short-Term Memory, BiLSTM）提取时间特征，并使用条件随机场来约束分类结果。
- 3) BERT-Span: 首先，使用 BERT 作为编码器表征输入文本序列。然后，将一维的词元序列嵌入扩展为二维的跨度嵌入。对于由第 i 个词元到第 j 个词元组成的跨度，其跨度嵌入通过计算第 i 个词元和第 j 个词元嵌入的平均值来获得。最后，使用多层感知机对每个跨度进行分类。此外，该方法还确定每个词元是否可以作为实体的起始或终止索引。

(3) 数据集

本文除工业命名实体识别数据集 IndusNER，还在一些公共数据集上进行了测评实验，如表 3-4 所示。对于扁平命名实体识别，实验在英语数据集（CoNLL2003）和中文数据集（OntoNotes4、People's Daily 和 MSRA）上进行。对于嵌套命名实体识别，实验在英语数据集（ACE2004 和 ACE2005）和中文数据集（CMeEE）上进行。模型均在相应验证集上进行调参，并选取验证集上表现最佳的参数进行记录。

华中科技大学硕士学位论文

表 3-4 公共数据集介绍

数据集	语言	类型	描述
ACE2004	英语	嵌套	包含七种类型的命名实体：地理政治实体、组织、人物、设施、车辆、位置和武器。
ACE2005	英语	嵌套	ACE2004 数据集的更新版本，包含相同的七种命名实体类别。
CMeEE	中文	嵌套	是一个中文医学文本的嵌套命名实体识别数据集，包含 9 种不同类别的命名实体。
MSRA	中文	扁平	是一个中文扁平命名实体识别数据集，数据来自新闻领域。该数据集包含三种类型的命名实体：位置、人物和组织。
CoNLL2003	英语	扁平	是一个英语扁平命名实体识别数据集，包含四种类别的命名实体：组织、人物、杂项和位置。
OntoNotes4	中文	扁平	是一个中文扁平命名实体识别数据集，包含四种类别的命名实体：地理政治实体、位置、人物和组织。
People's Daily	中文	扁平	是一个中文命名实体识别数据集，由北京大学于 1998 年发布，包含三种类别的命名实体：人物、组织和位置。

(4) 私有数据集模型测评

所有模型都使用焦点损失进行训练，并根据在验证集上的表现选择了最合适的超参数。本研究中使用的 BERT 模型均基于 `huggingface` 预训练模型 `bert-base-chinese`。在评估方面，使用了跨度级别的精确率、召回率和 F1 分数。表 3-5 显示了在 IndusNER 数据集上的实验结果。显然，所提 BERT-Industry 模型优于其他三个基线模型，在 F1 分数上达到了 90.658% 的最佳表现。尤其是与序列标注方法如 BERT-Tagger 和 BERT-BiLSTM-CRF 相比，F1 分数分别提高了 5.981% 和 5.364%。这表明基于跨度的分类有效解决了嵌套命名实体的问题，而这些问题时序列标注方法无法正确识别的。与另一个基于跨度的分类模型 BERT-Span 相比，BERT-Industry 在 F1 分数上提高了 1.071%。这是因为 BERT-Span 仅通过起始和终止索引处的词元嵌入的平均来表征跨度，而中间的词元也应当在嵌入中考虑。双反射注意力机制能够实现这种跨度嵌入，卷积神经网络学习到了跨度嵌入的空间特征，并对预测结果施加约束，从而提高了模型的表现。

华中科技大学硕士学位论文

表 3-5 不同模型在 IndusNER 数据集上的表现

模型	精确率 (%)	召回率 (%)	F1 分数 (%)
BERT-Tagger	91.570	78.750	84.677
BERT-BiLSTM-CRF	91.667	79.750	85.294
BERT-Span	88.335	90.875	89.587
BERT-Industry	90.943	90.375	90.658

为了进一步验证 BERT-Industry 中每个模块的有效性，进行了消融实验，测试了在去除不同模块的情况下模型的表现。表 3-6 展示了消融实验的结果。从中可以观察到，所有三个模块都是至关重要的，特别是焦点损失函数，凸显了其在解决类别不平衡问题上的强大能力。焦点损失加速了模型的收敛速度，并使其能够实现更好的表现。在没有使用卷积神经网络和双仿射注意力机制的情况下，仅使用焦点损失就能带来 F1 分数提高 6.46%。与不使用卷积神经网络的情况相比，使用卷积神经网络分别带来了 F1 分数提高 5.387%、0.727%、0.678% 和 0.715%。这表明卷积神经网络能够学习空间特征，对相邻跨度之间的分类结果施加限制，从而确保更准确的命名实体识别。此外，仅使用卷积神经网络模块时，相较于三个模块都不使用的情况，F1 分数提高了 5.387%。可以看出，卷积神经网络通过对相邻跨度施加约束，有助于加速模型训练并提高模型表现。使用双仿射注意力机制使得 F1 分数分别提高了 6.054%、0.356%、1.345% 和 0.344%。实验结果表明，双仿射注意力也能加速模型训练，并引导模型收敛到更好的局部最优解，从而提升模型性能。在三个模块中，焦

表 3-6 IndusNER 数据集上的消融实验

FL	CNN	Biaffine	精确率 (%)	召回率 (%)	F1 分数 (%)
×	×	×	86.803	79.750	83.127
✓	×	×	88.335	90.875	89.587
×	✓	×	88.404	88.625	88.514
×	×	✓	89.237	89.125	89.181
✓	✓	×	90.886	89.750	90.314
✓	×	✓	91.037	88.875	89.943
×	✓	✓	88.392	91.375	89.859
✓	✓	✓	90.943	90.375	90.658

华中科技大学硕士学位论文

点损失是最关键的，其次是卷积神经网络和双仿射注意力。所提方法有效地将三个部分结合到一起，从而提高模型对于嵌套命名实体识别的能力。

(5) 公共数据集模型测评

为了进一步验证所提方法的有效性，在公共数据集上也进行了实验，如表 3-4 所示。超参数在相应的验证集上进行调优。报告了基于跨度的精确率、召回率和 F1 分数作为评估指标。表 3-7 展示了不同模型在公共嵌套命名实体识别数据集和扁平命名实体识别数据集上的性能表现。在嵌套命名实体识别任务中，相较于基于序列标注的 BERT-BiLSTM-CRF 模型，BERT-Industry 的 F1 分数分别提高了 14.252%、12.868% 和 7.138%。结果表明，所提方法在公共嵌套命名实体识别数据集上表现优

表 3-7 不同模型在公共命名实体识别数据集上的表现

English ACE2004			Chinese MSRA			
模型	精确率 (%)	召回率 (%)	F1 分数 (%)	精确率 (%)	召回率 (%)	F1 分数 (%)
BERT-Tagger	83.427	60.272	69.984	95.656	91.893	93.737
BERT-BiLSTM-CRF	84.382	60.646	70.572	95.034	93.231	94.124
BERT-Span	87.096	75.986	81.163	95.640	91.993	93.781
BERT-Industry	86.333	83.367	84.824	95.357	93.510	94.425

English ACE2005			English CoNLL2003			
模型	精确率 (%)	召回率 (%)	F1 分数 (%)	精确率 (%)	召回率 (%)	F1 分数 (%)
BERT-Tagger	81.186	63.111	71.016	92.039	91.990	92.015
BERT-BiLSTM-CRF	79.446	64.109	70.958	92.528	92.132	92.330
BERT-Span	84.633	78.458	81.429	93.223	91.581	92.395
BERT-Industry	84.740	82.932	83.826	92.987	92.043	92.513

Chinese CMeEE			Chinese OntoNotes4			
模型	精确率 (%)	召回率 (%)	F1 分数 (%)	精确率 (%)	召回率 (%)	F1 分数 (%)
BERT-Tagger	74.683	61.758	67.609	81.579	79.334	80.441
BERT-BiLSTM-CRF	74.964	62.451	68.138	79.029	83.893	81.389
BERT-Span	77.727	71.885	74.692	80.352	81.917	81.127
BERT-Industry	76.798	73.813	75.276	83.412	80.138	81.742

Chinese People's Daily			
模型	精确率 (%)	召回率 (%)	F1 分数 (%)
BERT-Tagger	95.648	92.764	94.184
BERT-BiLSTM-CRF	94.917	93.227	94.064
BERT-Span	95.723	91.642	93.638
BERT-Industry	95.124	92.750	93.922

异，充分证明其较强的泛化能力，可作为嵌套命名实体识别任务的重要基准模型。此外，在四个公共的扁平命名实体识别数据集上，所提方法同样优于其他基准模型，进一步说明其在不同命名实体识别任务中的优越性能。值得注意的是，所提方法无论在中文还是英文命名实体识别数据集上均取得了优异效果，进一步展现了其良好的鲁棒性和广泛的适用性。这几个数据集涉及到不同的领域，借由预训练语言模型 BERT，可以理解不同领域文本的语义，从而提高了命名实体识别的准确性。

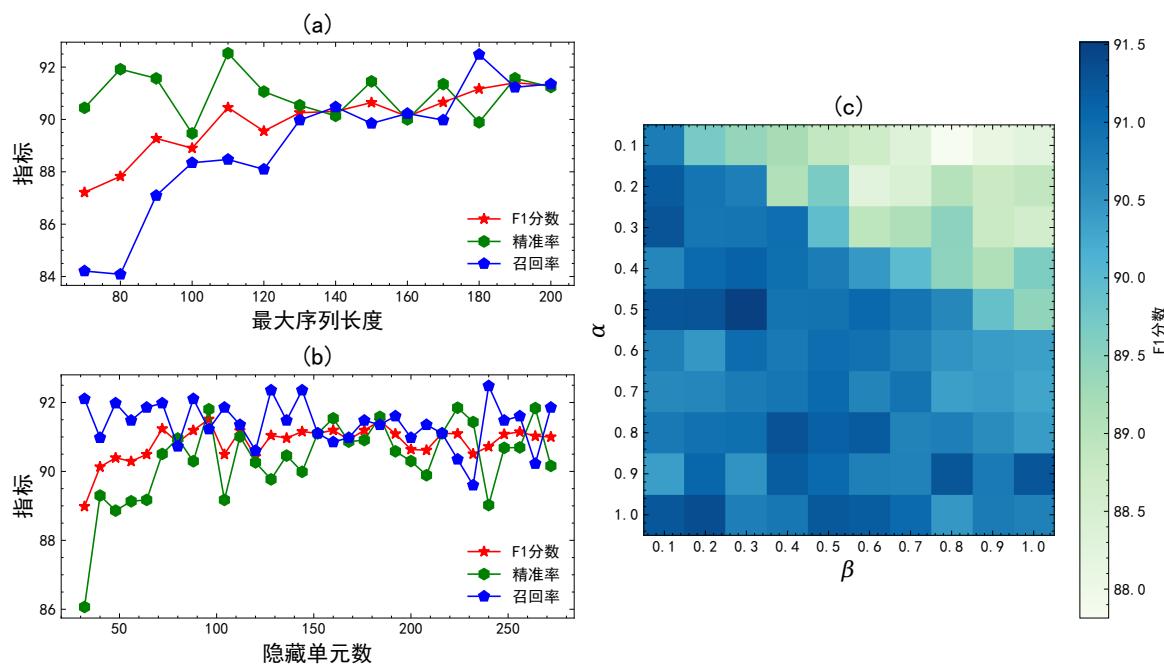


图 3-4 BERT-Industry 模型超参数敏感性研究

(6) 超参数选择

本节通过大量实验，系统分析了超参数对模型性能的影响，重点探讨序列最大长度、隐藏单元数量和损失权重等关键超参数在模型构建过程中的作用。图 3-4 (a) 展示了输入文本序列最大长度对模型性能的影响趋势。可以看出，当序列长度较短时，适当增加长度有助于提升模型性能。然而，当序列长度接近 180 时，过多与词元识别无关的噪声信息被引入，反而导致模型性能下降。图 3-4 (b) 展示了 MLP 隐藏单元数量对模型性能的影响。随着神经元数量增加，模型的特征提取能力逐步增强，但也更容易发生过拟合，导致部分非实体词元被错误识别为实体。结果显示，精确

率先上升后下降，而召回率则呈现相反趋势，F1 分数整体变化不明显。在分析损失权重对实体定位与分类的影响时，实验发现，实体定位和分类权重相等时，模型性能并未达到最优。图 3-4 (c) 表明，当 $\alpha = 0.5$ 、 $\beta = 0.3$ 时，F1 分数最高。这也说明，由于实体分类在整体损失中的占比相对较小，准确的实体定位对提升嵌套命名实体识别的效果尤为关键。

3.3 基于大语言模型的关系三元组抽取

在完成催化裂化装置反应再生系统的命名实体识别后，可进一步进行关系三元组抽取，将非结构化文本转化为结构化知识，从而构建安全知识图谱。本节首先介绍关系三元组抽取任务的定义，随后阐述基于大语言模型的关系三元组抽取方法，并通过实验验证其效果，最后对结果进行分析。

3.3.1 任务定义

关系三元组抽取的目标是从自然语言文本中识别并提取符合特定语义的三元组结构，通常表示为 (h, r, e) ，即头实体 h 和尾实体 e 之间构成关系 r 。该任务以命名实体识别为基础，重点识别文本中的头实体与尾实体，并结合上下文语义与文本结构，判断二者之间的具体关系，最终形成完整的三元组。基于大语言模型，并结合 3.2 节提出的命名实体识别方法，该任务可进一步转换为提示词生成任务。通过构建有效的提示词，并与大语言模型进行交互式对话，自动完成关系三元组的抽取过程。

3.3.2 关系三元组抽取方法

基于大语言模型的关系三元组抽取，其核心在于提示词的构建。具体而言，需要清晰描述待执行的任务，并提供待抽取的文本，引导大语言模型识别并提取安全相关知识。模型根据预设格式输出结果，系统再对输出内容进行解析，最终生成结构化的关系三元组。图 3-5 展示了催化裂化装置反应再生系统的关系三元组抽取流程。

首先，对输入文本进行预处理，如去除特殊符号等，确保模型准确理解文本的核心内容。接下来，设计清晰有效的提示词是关键环节。提示词需准确描述任务目标，并引导大语言模型执行文本推理，抽取实体及其关系。基于提示词与大语言模型的对话交互，逐步完成三元组的抽取。大语言模型结合文本上下文和内置知识库，

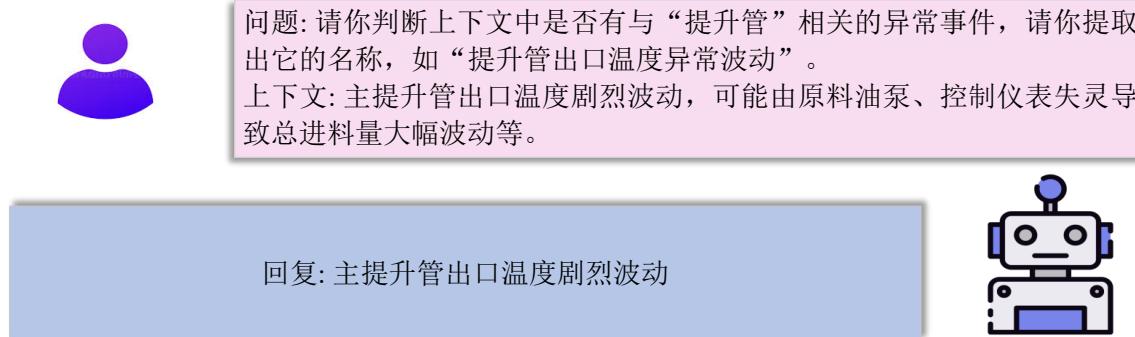


图 3-5 催化裂化装置反应再生系统关系三元组抽取流程

识别相关实体并判断它们之间的关系。同时,为确保结果格式规范,需明确约定输出格式,以便后续解析与存储。提取完成后,还需对三元组进行验证与筛选,确保结果的准确性。

3.3.3 实验结果

为验证基于大语言模型的关系三元组抽取方法的有效性,本节开展了相关实验。图 3-6 展示了关系三元组抽取的实验结果,包括不同关系类型的三元组数量分布。在抽取的关系三元组中,以相关异常最多,共 364 项,占比总体的 38.6%。图 3-7 展示了抽取的关系三元组的示例。如“主提升管”的“相关异常”是“主提升管出口温度大幅度波动”。结果表明,所提方法能够根据提供的头实体和关系类型,准确识别对应的尾实体,进而完整生成关系三元组。

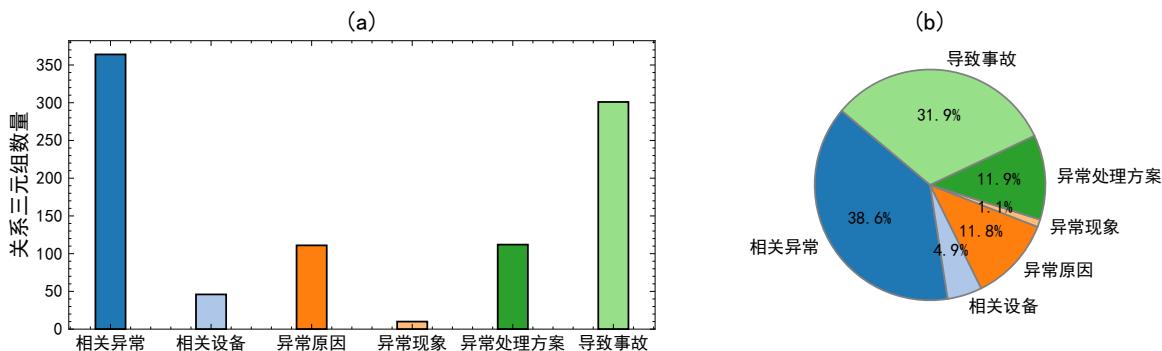


图 3-6 关系三元组抽取实验结果



图 3-7 关系三元组抽取示例

3.4 知识与数据驱动的变量因果图构建

本节综合知识驱动与数据驱动方法，构建完整的变量因果图。首先，利用大语言模型从催化操作规程中抽取变量间的因果关系。其次，基于传递熵算法，从多变量时间序列数据中挖掘过程变量的因果关联。最后，将两部分生成的因果图融合，形成最终的变量因果图。

3.4.1 知识驱动方法

催化操作规程中蕴含变量间的因果关系，但这些信息多以非结构化文本的形式存在，难以直接转换为结构化数据。利用大语言模型的文本推理能力，可以从催化操作规程中自动抽取描述性因果关系，并用于构建结构化的变量因果图。如图 3-8 所示，“主提升管出口温度”与“沉降器出口温度”之间存在因果关联，因此可在变量因果图中添加一条从“沉降器出口温度”指向“主提升管出口温度”的有向边。通过重复上述过程，逐步提取催化操作规程中涉及的所有因果描述，最终构建知识驱动的变量因果图。



问题: 请根据以下上下文判断状态变量之间是否存在因果关系, 并将结果以三元组列表的形式返回, 例如[(外取热器温度, 影响, 主提升管出口温度)]。
上下文: 主提升管出口温度升高, 导致沉降器出口温度升高。

回复: [(主提升管出口温度, 影响, 沉降器出口温度)]

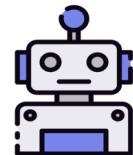


图 3-8 知识驱动的变量因果图构建

3.4.2 数据驱动方法

除了基于知识的方法, 数据驱动技术同样广泛应用于变量因果图的构建中。本文采用传递熵算法, 分析催化裂化装置反应再生系统的过程变量时间序列数据, 并基于观测到的依赖关系识别变量间的因果关联。如图 3-9 所示, 首先获取过程变量的多变量时间序列, 并计算任意两变量之间的传递熵, 构建传递熵矩阵。随后, 依据预设阈值筛选因果图中的有向边, 最终生成数据驱动的变量因果图。

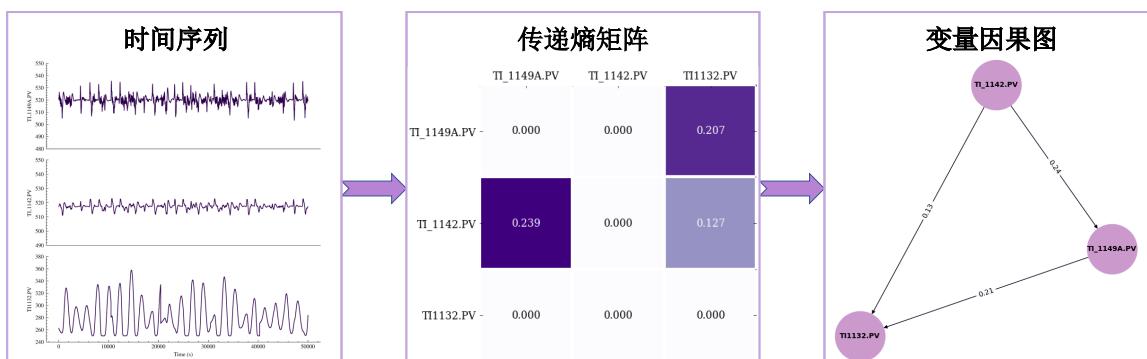


图 3-9 数据驱动的变量因果图构建

3.4.3 变量因果图融合

本文提出的变量因果图构建方法中, 最后一步是融合知识驱动与数据驱动方法生成的因果图。知识驱动方法反映了催化操作规程中记录的专家经验, 因此在融合过程中优先保留其因果关系。为保证融合质量, 融合过程遵循预设规则, 在保留专家验证关系的同时, 补充数据驱动方法识别出的有效因果连接, 最终形成综合变

量因果图。最终构建的因果图共包含 84 个节点和 311 条有向边。图 3-10 展示了以 TI_1149A.PV 和 TI1105A.PV 为中心的子图，可发现变量间具有很强的因果关联性。

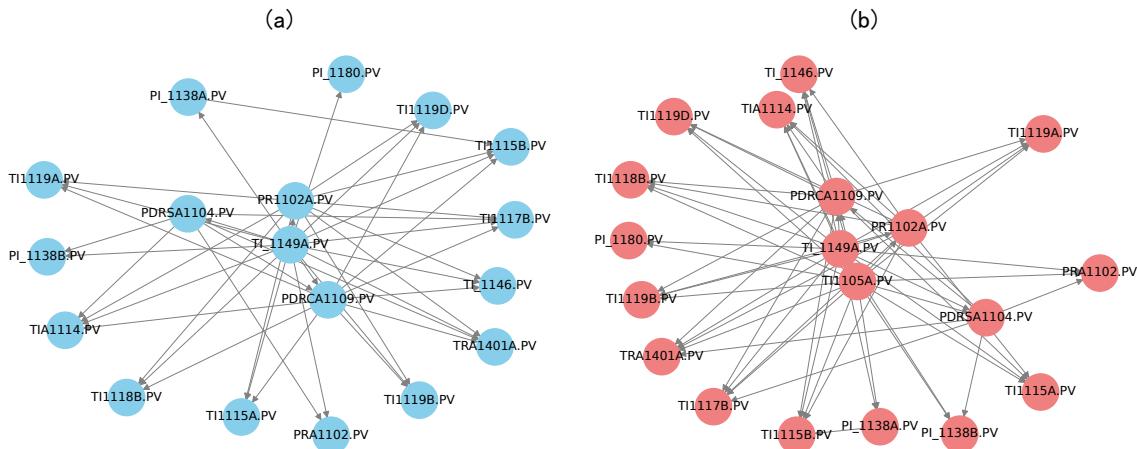


图 3-10 融合后的变量因果图

3.5 安全知识图谱构建实验结果

最终，将命名实体识别、关系三元组抽取与变量因果图构建的结果融合，形成结构化三元组数据，从而构建催化裂化装置反应再生系统的安全知识图谱。然而，此时本体仍缺少变量与测点之间的映射关系，例如变量“主提升管出口温度”对应的

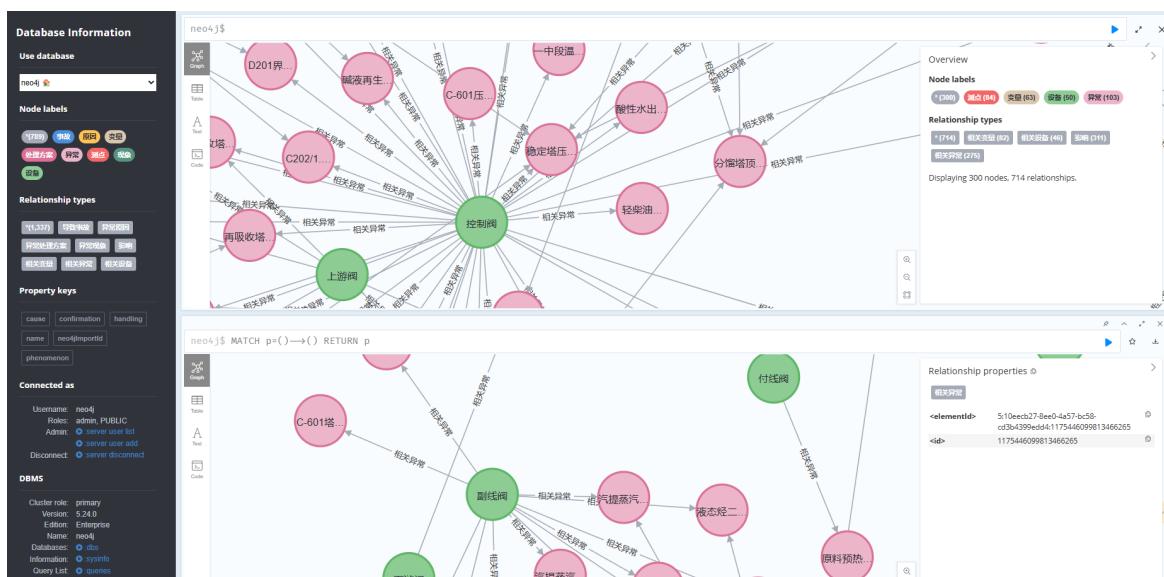


图 3-11 催化裂化装置反应再生系统安全知识图谱构建结果

测点为“TI_1149A.PV”。这部分映射数据可从仿真系统导出，并整合至三元组数据中，以完善安全知识图谱的构建。最终构建的安全知识图谱如图 3-11 所示，共包含 789 个节点和 1337 条边。其中，设备节点数量最多，达到 251 个；“相关异常”关系数量最多，共 364 条。基于安全知识图谱，可通过某个测点追溯对应的变量，进而定位相关设备，识别可能发生的异常，并查询异常现象及解决方案等信息。

3.6 本章小结

本章介绍了面向催化裂化装置反应再生系统的安全知识图谱构建方法。通过对催化裂化装置反应再生系统的安全相关文本数据进行处理，结合跨度分类进行命名实体识别，并利用大语言模型抽取关系三元组，最终构建了安全知识图谱。此外，本研究还融合了知识驱动和数据驱动的方法，构建了包含变量因果关系的因果图，并将变量与测点之间的联系纳入到安全知识图谱中。该安全知识图谱能够结构化地表示设备、异常等关键信息，为安全管理人员提供高效的查询和决策支持。实验结果表明，所提方法能够有效地从催化操作规程中提取安全相关知识，并构建高质量的安全知识图谱，进而为后续的智能安全分析提供坚实的知识支撑。所构建的安全知识图谱以历史异常为核心，能够提供大量关于异常的信息。这些信息能够支撑后续为异常根本原因提供可行的处理方案。

4 催化裂化反应再生系统的异常诊断

为了实时监控催化裂化装置反应再生系统的运行状况，需要进行异常诊断，识别异常变量，并追溯异常的根本原因。具体而言，首先需要获取由过程变量实时数据形成的多变量时间序列。然后，利用多任务变分自编码器，通过时间序列重构与预测计算异常分数，从而检测出异常变量。最终，基于异常分数和安全知识图谱中的变量因果图，在因果图上完成异常根本原因的溯源。

4.1 反应再生系统异常诊断框架

本文以催化裂化装置反应再生系统为研究对象，基于操作员训练模拟器（Operator Training Simulator, OTS）进行异常诊断研究。OTS 系统通过仿真催化裂化装置的实际运行过程，支持实时过程变量数据的采集与监控。该系统能够模拟反应再生过程中的不同工况，并实时反馈设备状态，为后续的异常诊断提供宝贵的数据支持。反应再生系统是催化裂化装置中的关键部分，其稳定性直接影响整个装置的

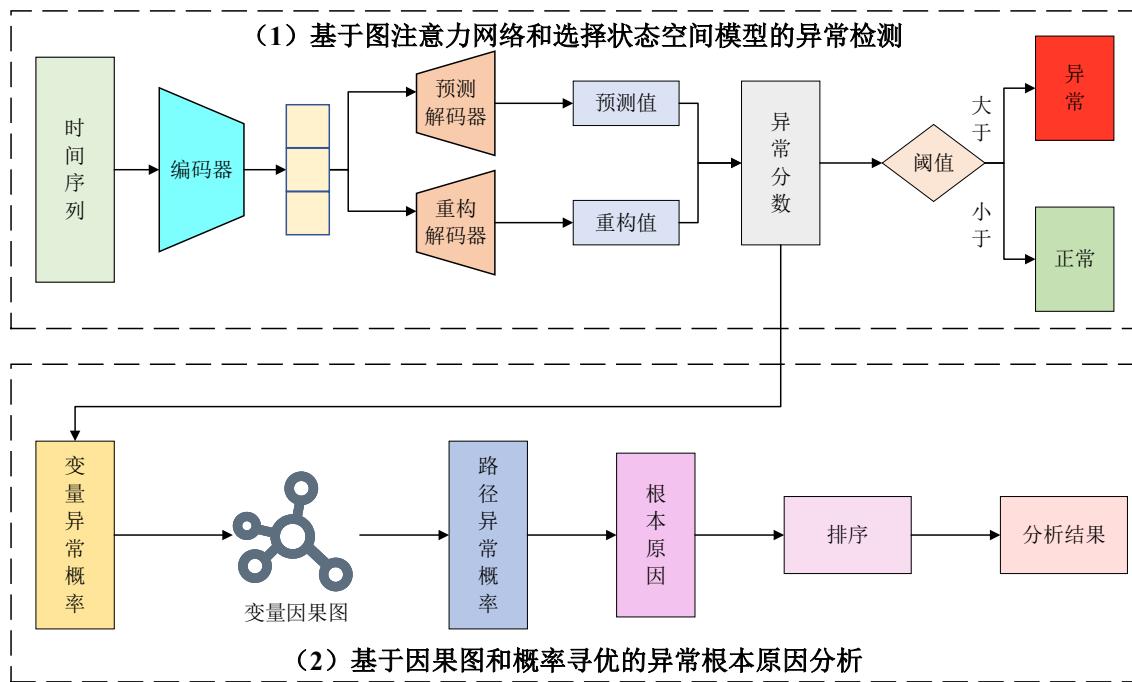


图 4-1 催化裂化装置反应再生系统异常诊断框架

运行效率和安全性。因此，为了有效实现对反应再生系统的异常诊断，必须建立一个全面的异常诊断框架，如图 4-1 所示。该框架主要分为两步：首先，利用基于图注意力网络（Graph Attention Networks，GAT）和选择状态空间模型 Mamba 的多任务变分自编码器对多变量时间序列进行异常检测，识别出异常变量。然后，基于异常检测所得的异常分数和安全知识图谱中的变量因果图，进行异常根本原因分析。

4.2 基于图注意力网络和选择状态空间模型的异常检测

本节首先介绍异常检测任务的定义，并说明异常检测数据集的构建流程与相关背景知识。随后，介绍异常检测框架，详细解析异常检测模型 MTVAE-GM 的结构与推理过程。最后，结合实验验证与结果分析，评估模型的实际效果。

4.2.1 任务定义

本研究主要关注反应再生系统中的多变量异常检测任务。令 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 表示传感器监测变量的时间序列，其中 n 是序列的长度，表示传感器观测序列的长度。 $\mathbf{x}_t \in \mathbb{R}^m$ 是时间 t ($t \leq n$) 时长度为 m 的向量： $\mathbf{x}_t = [x_t^1, x_t^2, \dots, x_t^m]$ ，其中 m 是传感器监测变量的数量。为了检测异常状态，通过重构误差和预测误差，在每个时间 t 计算异常分数 $\mathbf{s} = \{s_1, s_2, \dots, s_n\}$ 。一旦异常分数 s_t 在时间 t 超过特定阈值 γ ，则视为发生异常。反应再生系统中多变量时间序列的异常检测任务的目标是确定时间序列 \mathbf{X} 内每个时间步是否存在异常。

4.2.2 异常检测数据集构建

以 OTS 系统为基础，本文对反应再生系统进行异常检测数据集构建。催化裂化装置反应再生系统工艺流程图中的部分关键测点如表 4-1 所示，其中包括温度、流量和压力相关测点。部分变量存在多个冗余的传感器进行测量，以保证数据的高可信度和准确性。后续将基于 OTS 系统，采集共 84 个关键测点的实时过程数据，得到多变量时间序列，从而进行后续的异常诊断研究。图 4-2 展示了 12 个关键测点的数据曲线，其中红色区域表示当前过程变量处于异常状态。可以发现一些测点的数据曲线十分相似，具有类似的变化规律，这说明了提取其时空依赖性的重要性。

表 4-1 催化裂化装置反应再生系统部分关键测点

测点	变量	测点	变量
TI_1149A.PV	主提升管出口温度	TI_1153A.PV	副提升管出口温度
TI1113.PV	沉降器上部温度	TI_1145.PV	沉降器中部温度
TI_1142.PV	沉降器出口温度	PI_1138A.PV	主提升管入口压力
FIC_1123.PV	副提升管喷嘴上方蒸汽流量	TI1133.PV	外取热器温度
TI1119A.PV	再生器密相北温度	TI1118B.PV	再生器密相西温度
TI1119B.PV	再生器密相东温度	TI_1144.PV	沉降器顶温度

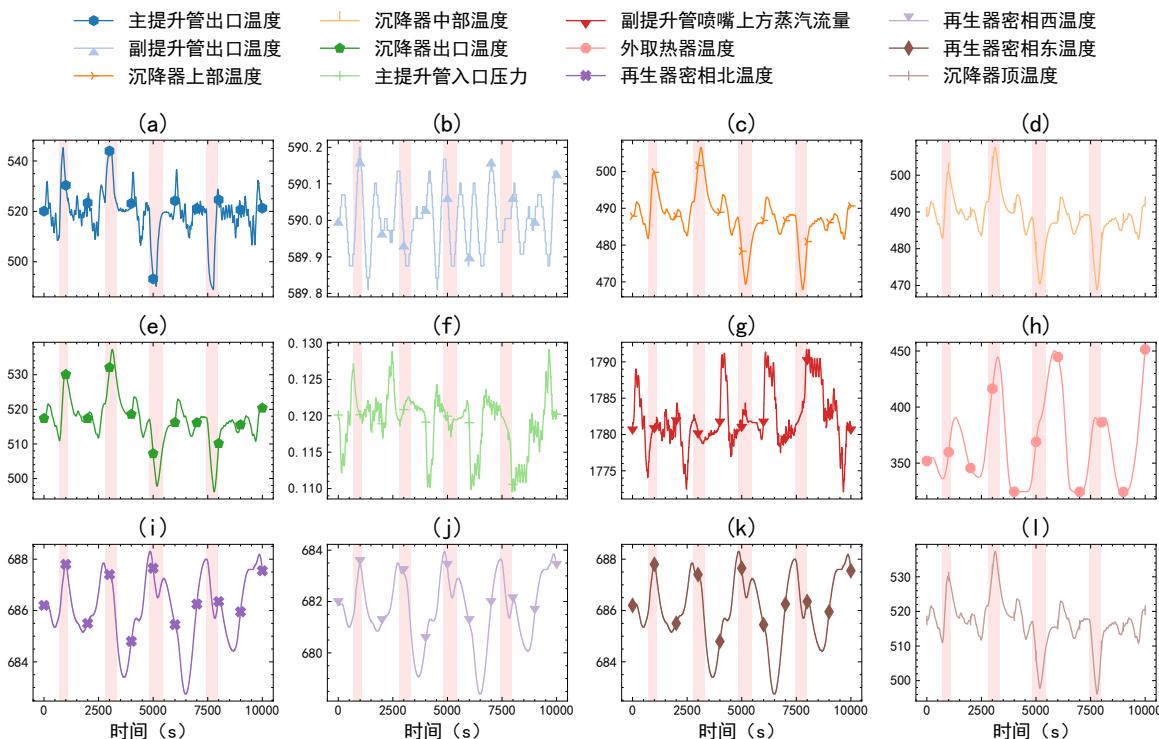


图 4-2 过程变量的实时数据曲线

4.2.3 背景知识

(1) 图注意力网络

图注意力网络可以建模图中任意节点之间的关系，并通过边的权重提供可解释性。给定一个图 $\mathbf{G} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ ，其中 n 是节点的数量， \mathbf{v}_i 是每个节点的特征

向量，图注意力网络计算节点 i 的嵌入 \mathbf{h}_i 如式 (4-1) 所示：

$$\mathbf{h}_i = \sigma \left(\sum_{j=1}^L \alpha_{ij} \mathbf{v}_j \right) \quad (4-1)$$

其中， α_{ij} 是注意力分数，表示节点 j 对节点 i 的贡献， σ 是一个非线性激活函数，例如 sigmoid 函数。 j 表示节点 i 的邻接节点， L 表示节点 i 的邻接节点总数。注意力分数 α_{ij} 的计算如式 (4-2) 和 (4-3) 所示：

$$e_{ij} = \text{LeakyReLU}(\mathbf{w}^T \cdot (\mathbf{v}_i \oplus \mathbf{v}_j)) \quad (4-2)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^L \exp(e_{ik})} \quad (4-3)$$

其中， \oplus 表示节点 i 和节点 j 嵌入的连接， $\mathbf{w} \in \mathbb{R}^{2n}$ 是一个列向量，包含可学习的参数，用于对连接特征进行线性变换。LeakyReLU 是一个非线性激活函数，用于进一步的非线性变换。

(2) 选择状态空间模型

选择状态空间模型 Mamba 是一种状态空间模型 (State Space Model, SSM)，它将一维序列 $\mathbf{x}(t) \in \mathbb{R}^N$ 映射到 $\mathbf{y}(t) \in \mathbb{R}^N$ 。状态空间模型的计算过程如式 (4-4) 和 (4-5) 所示：

$$\mathbf{h}'(t) = \mathbf{A}\mathbf{h}(t) + \mathbf{B}\mathbf{x}(t) \quad (4-4)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{h}(t) \quad (4-5)$$

其中， $\mathbf{A} \in \mathbb{R}^{N \times N}$, $\mathbf{B} \in \mathbb{R}^N$, $\mathbf{C} \in \mathbb{R}^N$ 是状态矩阵， $\mathbf{h}(t) \in \mathbb{R}^N$ 表示隐状态。近些年来，结构化状态空间序列模型在各种关系挖掘的任务中，作为一类序列建模架构被众多学者重视。它可以被视为循环神经网络和卷积神经网络的结合。结构化状态空间序列模型的优势之一是其捕捉长程依赖的能力，这使得它们成为序列建模任务中的有价值工具。然而，在模型学习过程中，大量无关信息可能会降低此类模型的性能。Gu 等人设计了一种简单的选择机制，使得 Mamba 模型能够过滤掉无关信息，并长期记住相关信息^[70]。为了使自编码器更好地捕获时序依赖性，本研究将 Mamba 应用于其中。

4.2.4 异常检测框架

为了在反应再生系统中准确地进行异常检测，本研究提出了一种多任务变分自编码器 MTVAE-GM。图 4-3 展示了 MTVAE-GM 的框架，它共享编码器，并同时执行时间序列重构和预测。具体来说，为了捕捉多变量时间序列的时序和空间依赖性，本研究使用选择状态空间模型 Mamba 和图注意力网络 GAT 来获得低维表征。然后，应用多层次 LSTM 进一步捕捉时序依赖性。此外，本研究结合变分自编码器的架构，以增强模型对噪声的容忍性。通过多任务学习，MTVAE-GM 可以学习更强大的时间序列表征。最后，本研究提出了一个带权重系数的复合目标函数，以指导模型进行端到端训练。MTVAE-GM 能够为正常数据生成与原始时间序列相似的重构和预测。然而，当处理异常数据时，生成的重构和预测通常会有显著的变化。这意味着在推理过程中，可以通过计算预测误差和重构误差来判定系统和变量的异常状态。

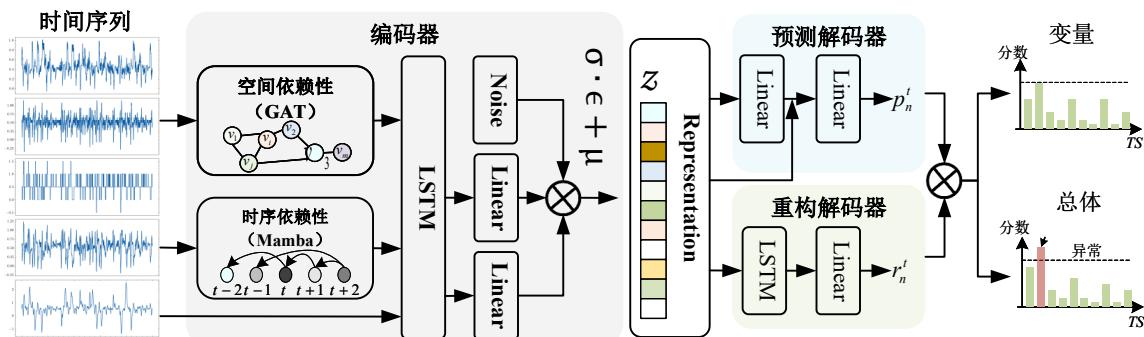


图 4-3 多任务变分自编码器 MTVAE-GM 的框架

4.2.5 模型结构

在本研究的多任务变分自编码器中，编码器和解码器是主要组件。通过 Mamba 和 GAT 捕捉多变量时间序列的时序和空间依赖性，并通过多层次 LSTM 将其压缩成低维表征。此外，通过变分自编码器的结构，通过执行线性变换并添加噪声，获得了时间序列的低维表征。相应地，两个解码器利用低维表征进行精确的重构和预测。共享的编码器可以通过重构和预测两个解码任务学习更丰富的特征，从而提高在噪声条件下异常检测的鲁棒性。接下来，本研究将介绍所提异常检测模型 MTVAE-GM 的详细结构。

华中科技大学硕士学位论文

(1) 编码器

在编码器中，Mamba 和 GAT 用于捕捉多变量时间序列的时序和空间依赖性。设 $\mathbf{X} \in \mathbb{R}^{n \times m}$ 表示输入时间序列，输出计算公式如式 (4-6) 和 (4-7) 所示：

$$\mathbf{h}_{\text{temporal}} = \text{Mamba}(\mathbf{X}) \quad (4-6)$$

$$\mathbf{h}_{\text{spatial}} = \text{GAT}(\mathbf{X}) \quad (4-7)$$

其中 n 表示时间序列的长度， m 表示变量的数量。在通过 Mamba 和 GAT 捕捉时序和空间依赖性之后， $\mathbf{h}_{\text{temporal}} \in \mathbb{R}^{n \times m}$ 和 $\mathbf{h}_{\text{spatial}} \in \mathbb{R}^{n \times m}$ 的维度保持一致。然后，将特征与原始输入 \mathbf{X} 结合，以获得更丰富的特征来表征时间序列，如式 (4-8)：

$$\mathbf{h} = \mathbf{X} \oplus \mathbf{h}_{\text{temporal}} \oplus \mathbf{h}_{\text{spatial}} \quad (4-8)$$

其中 \oplus 表示嵌入的连接，且 $\mathbf{h} \in \mathbb{R}^{n \times 3m}$ 。与 LSTM 等循环神经网络相比，Mamba 类似于卷积神经网络，在捕捉局部时序依赖性方面表现优越。接下来，使用多层 LSTM 进一步捕捉时序依赖性，并逐步压缩输入，最终获得 LSTM 的最后一个隐藏状态作为时间序列的低维表征，如式 (4-9)：

$$\mathbf{h}_{\text{last}} = \text{LSTM}(\mathbf{h}) \quad (4-9)$$

其中 $\mathbf{h}_{\text{last}} \in \mathbb{R}^c$ ， c 是 \mathbf{h}_{last} 的长度。为了提高模型对噪声的容忍度，并真正学习时间序列的模式，本研究将变分自编码器的架构应用于模型。通过两个线性层模拟均值和标准差的计算，公式如式 (4-10)、(4-11) 和 (4-12) 所示：

$$\mu = \mathbf{h}_{\text{last}} \mathbf{W}_\mu^T + \mathbf{b}_\mu \quad (4-10)$$

$$\sigma = \mathbf{h}_{\text{last}} \mathbf{W}_\sigma^T + \mathbf{b}_\sigma \quad (4-11)$$

$$\mathbf{z} = \sigma \cdot \epsilon + \mu \quad (4-12)$$

其中 $\mathbf{W}_\mu \in \mathbb{R}^{d \times c}$ ， $\mathbf{b}_\mu \in \mathbb{R}^d$ ， $\mathbf{W}_\sigma \in \mathbb{R}^{d \times c}$ ， $\mathbf{b}_\sigma \in \mathbb{R}^d$ 分别表示两个线性层的权重和偏置， $\epsilon \in \mathbb{R}^d$ 表示均值为 0、标准差为 1 的随机噪声。最后，编码器的输出 $\mathbf{z} \in \mathbb{R}^d$ 被传递给解码器，作为时间序列的表征。

(2) 解码器

解码器分为预测解码器和重构解码器。通过多任务学习，模型可以学习更稳健和高度泛化的时间序列表征，从而提高异常检测的性能。预测解码器是一个带有残差连接的多层感知机。它由多个线性层串联组成，并通过残差连接加速模型收敛并防止过拟合。激活函数 GELU 设置在线性层之间，实现非线性变换。此外，为了防止过拟合，还加入了 Dropout。最终，预测解码器预测每个变量的下一时间步的值，如式 (4-13)、(4-14) 和 (4-15) 所示：

$$\mathbf{y} = \mathbf{z}\mathbf{W}_1^T + \mathbf{b}_1 \quad (4-13)$$

$$\mathbf{a} = \text{Dropout}(\text{GELU}(\mathbf{y})) \quad (4-14)$$

$$\mathbf{p} = \mathbf{a}\mathbf{W}_2^T + \mathbf{b}_2 + \mathbf{z}\mathbf{W}_3^T + \mathbf{b}_3 \quad (4-15)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{e \times d}$, $\mathbf{b}_1 \in \mathbb{R}^e$, $\mathbf{W}_2 \in \mathbb{R}^{m \times e}$, $\mathbf{b}_2 \in \mathbb{R}^m$, $\mathbf{W}_3 \in \mathbb{R}^{m \times d}$, $\mathbf{b}_3 \in \mathbb{R}^m$ 分别表示两个线性层的权重和偏置。在本研究中仅预测时间序列的下一步，即 $\mathbf{p} \in \mathbb{R}^m$ 。重构解码器由串联的多层 LSTM 组成，最终通过一个线性层进行维度转换。首先，将 \mathbf{z} 在时间维度上重复 n 次，以得到 $\mathbf{z}' \in \mathbb{R}^{n \times d}$ 。计算过程如式 (4-16) 和 (4-17)：

$$\mathbf{o} = \text{LSTM}(\mathbf{z}') \quad (4-16)$$

$$\mathbf{r} = \mathbf{o}\mathbf{W}_o^T + \mathbf{b}_o \quad (4-17)$$

其中 $\mathbf{o} \in \mathbb{R}^{n \times f}$, $\mathbf{W}_o \in \mathbb{R}^{m \times f}$, $\mathbf{b}_o \in \mathbb{R}^m$, $\mathbf{r} \in \mathbb{R}^{n \times m}$ 。类似地，为了防止过拟合，在 LSTM 中加入了 Dropout。尽管解码器部分采用了相对常规的架构，得益于强大的时间序列表征，MTVAE-GM 展现出了强大的预测和重构能力。它可以学习时间序列中的模式，并表现出强大的异常检测能力。

4.2.6 联合优化

为了使异常检测模型 MTVAE-GM 能够学习到多变量时间序列的鲁棒表征，本研究提出了一个复合目标函数，适用于端到端训练。该目标函数包括三个组成部分：重构损失、预测损失和 KL (Kullback-Leibler) 散度损失。设原始时间序列为 $\mathbf{V} = \{\mathbf{v}_0, \mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ ，预测值为 $\mathbf{P} = \{\mathbf{p}_n\}$ ，重构值为 $\mathbf{R} = \{\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_n\}$ 。目标函

数的构造如式 (4-18)、(4-19)、(4-20) 和 (4-21):

$$\mathcal{L}_{rec} = \frac{1}{nm} \sum_{i=1}^n \sum_{j=1}^m |v_i^j - r_i^j| \quad (4-18)$$

$$\mathcal{L}_{pre} = \frac{1}{m} \sum_{j=1}^m |v_n^j - p_n^j| \quad (4-19)$$

$$\mathcal{L}_{kld} = -\frac{1}{2} \sum_{i=1}^d (1 + \log(\sigma_i) - \mu_i^2 - \sigma_i) \quad (4-20)$$

$$\mathcal{L}_{all} = \alpha \cdot \mathcal{L}_{rec} + \beta \cdot \mathcal{L}_{pre} + \gamma \cdot \mathcal{L}_{kld} \quad (4-21)$$

其中 α , β 和 γ 分别为三项损失的权重, 前两项侧重于正常数据与异常数据在时空依赖性的差异。当模型输入正常数据时, 重构损失 \mathcal{L}_{rec} 和预测损失 \mathcal{L}_{pre} 将较小。相反, 当模型输入异常数据时, 重构和预测将出现显著误差, 因为时空依赖性不符合正常模式。此外, KL 散度损失直接影响模型对噪声的适应能力。MTVAE-GM 的目标函数通过加权系数将三个损失项进行加和, 从而优化预测和重构任务, 并确定模型对特定任务的关注度。

4.2.7 模型推理

(1) 异常分数计算

在多变量时间序列异常检测的背景下, 常见的方法是通过自编码器计算时间序列重构的异常分数。在这种方法中, 异常分数超过阈值的时间序列被视为异常。另一种异常检测方法是基于时间序列预测模型, 它计算预测值与实际值之间的误差, 并通过预测误差来检测异常。与此不同, 所提出的 MTVAE-GM 同时执行时间序列重构和时间序列预测两个任务, 因此在计算异常分数时, 同时考虑时间序列的重构和预测。设 $\mathbf{V} = \{\mathbf{v}_0, \mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ 为原始时间序列, $\mathbf{P} = \{\mathbf{p}_n\}$ 为预测值, $\mathbf{R} = \{\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_n\}$ 为重构值, 则异常分数 S 的计算公式如式 (4-22)、(4-23) 和 (4-24):

$$S_{rec} = \frac{1}{m} \sum_{i=1}^m |v_n^i - r_n^i| \quad (4-22)$$

$$S_{pre} = \frac{1}{m} \sum_{i=1}^m |v_n^i - p_n^i| \quad (4-23)$$

$$S = S_{rec} + S_{pre} \quad (4-24)$$

(2) 异常检测

在进行多变量时间序列异常检测时，传统方法使用滑动窗口将时间序列划分为多个片段，然后计算每个片段的异常分数。自编码器学习在正常条件下变量变化的模式。因此，异常输入将导致更高的重构误差，从而识别异常。通过识别所有异常分数大于给定阈值的点，可以识别所有可能的异常。设 $\text{SEG} = \{\text{seg}_1, \text{seg}_2, \dots, \text{seg}_n\}$ 为所有时间序列片段， $\mathbf{s} = \{s_1, s_2, \dots, s_n\}$ 为每个片段对应的异常分数， γ 为检测阈值，则异常检测过程如式 (4-25):

$$r(s_i) = \begin{cases} 0, & s_i < \gamma \\ 1, & s_i \geq \gamma \end{cases} \quad (4-25)$$

如果 $r(s_i)$ 的值为 1，则时间序列片段 seg_i 被识别为异常。另一方面，如果 $r(s_i)$ 的值为 0，则时间序列 seg_i 被认为是正常的。此外，异常分数可以为多变量时间序列中的异常检测提供可解释性。异常分数在异常事件的初期阶段通常较小，并且随着异常事件的持续，异常分数逐渐增大。在异常事件的初期阶段，由于异常分数较小，检测异常较为困难。这可能是由于多个因素，例如，异常事件的初期变化模式与正常时间序列的变化模式相似，或是模型发生了过拟合。因此，实际的异常检测算法应尽可能早地检测到异常事件的初期阶段。总体而言，异常分数仍然缺乏可解释性，因此可以为每个变量计算异常分数，以提供更高的可解释性。变量级的异常分数可以帮助理解哪些变量在此次异常事件中受到主要影响。通过变量之间的因果图，还可以进一步推导出导致异常事件发生的根本原因。

4.2.8 实验结果

(1) 数据集

本研究使用三个数据集来评估模型在异常检测任务中的性能，分别是 CCPAD (催化裂化过程异常检测)、MSL 和 SWaT。其中，CCPAD 是一个多变量时间序列异常检测数据集，基于 SUPCON VxOTS 催化裂化过程仿真系统构建。

(2) 评价指标

本研究将异常检测视为一个逐点的二分类问题。精确率、召回率和 F1 分数作为

华中科技大学硕士学位论文

评估不同模型性能的指标。这三个评估指标的取值范围为 0 到 1，值越高表示模型性能越好。其中，F1 分数表示模型的整体性能。

(3) 实验设置

为了评估所提 MTVAE-GM 模型的性能，本研究选择 LSTM-NDT^[54]、MTAD-GAT^[68]、USAD^[64]、OmniAnomaly^[65]、DAGMM^[66] 和 TranAD^[67] 作为多变量时间序列异常检测的基准模型。本研究使用 AdamW 优化器， $\text{betas} = (0.9, 0.98)$ ，训练模型 20 个 epochs，初始学习率为 0.001，并采用学习率衰减策略， $lr_decay = 0.99$ 。对于所有模型，本研究将滑动窗口大小设置为 50。本研究采用 POT (Peaks-Over-Threshold) 阈值选择方法^[84]，用于选择计算三个评估指标的异常检测阈值。

(4) 表现对比

如表 4-2 所示，MTVAE-GM 在三个数据集上优于六个基准模型，分别达到了最高的 F1 分数 0.9389、0.8151 和 0.9524，在 CCPAD、SWaT 和 MSL 数据集上的最佳表现分别提高了 2.80%、0.08% 和 0.29%。可以观察到，MTVAE-GM 在所有三个数据集上展现了较高的召回率，这表明该模型尽可能地检测到所有真实的异常事件。此外，MTVAE-GM 还表现出较高的精确率，这表明只有很小一部分正常数据被错误识别为异常。这些特性与反应再生系统异常检测的需求非常吻合，确保了每个异常事件都能被检测到。值得注意的是，SWaT 和 MSL 数据集是多变量异常检测数据集，

表 4-2 不同模型在三个数据集上的表现

模型	CCPAD			SWaT			MSL		
	精确率	召回率	F1 分数	精确率	召回率	F1 分数	精确率	召回率	F1 分数
LSTM-NDT	0.7429	0.7891	0.7653	0.9655	0.6957	0.8087	0.6288	1.0000	0.7721
USAD	0.8712	0.9042	0.8874	0.9977	0.6879	0.8143	0.7949	1.0000	0.8857
OmniAnomaly	0.8853	0.8973	0.8912	0.9782	0.6957	0.8131	0.7848	1.0000	0.8794
DAGMM	0.8809	0.8328	0.8562	0.9955	0.6879	0.8136	0.7029	1.0000	0.8256
TranAD	0.7019	1.0000	0.8248	0.9977	0.6879	0.8143	0.9038	1.0000	0.9495
MTAD-GAT	0.8367	1.0000	0.9109	0.9888	0.6879	0.8114	0.9931	0.7024	0.8228
MTVAE-GM	0.8848	1.0000	0.9389	1.0000	0.6879	0.8151	0.9091	1.0000	0.9524

但异常通常由单一变量主导。这些变量之间没有复杂的空间依赖性。在这种情况下，只需要考虑时序依赖性。因此，MTAD-GAT 之前的方法在这两个数据集上表现较好。

然而，空间依赖性对于多变量时间序列异常检测同样至关重要，这导致在具有复杂时空依赖性的数据集（如 CCPAD）上表现不佳。因此，后两种模型考虑了时序依赖性和空间依赖性。从而，MTAD-GAT 在 CCPAD 数据集上的表现也较好，仅次于 MTVAE-GM。具体而言，MTVAE-GM 在所有三个数据集上始终优于 OmniAnomaly，在 CCPAD 和 MSL 数据集上的 F1 分数分别提高了 4.77% 和 7.30%。此外，在针对时间和空间特征提取的方法中，图注意力网络被用于捕捉空间依赖性。与 MTAD-GAT 相比，本研究采用了新颖的选择状态空间模型 Mamba 和变分自编码器架构，以实现更强大的时间序列表征，从而获得了更优的结果。相比之下，F1 分数在三个数据集上分别提高了 2.70%、0.37% 和 12.96%，显示出显著的提升。同时，多任务学习也为模型带来了显著的好处。

表 4-3 在 CCPAD 数据集上的消融实验

Mamba	GAT	VAE	精确率	召回率	F1 分数
×	×	×	0.8278	1.0000	0.9058
×	✓	×	0.8389	1.0000	0.9124
✓	×	×	0.8367	1.0000	0.9111
✓	✓	×	0.8589	1.0000	0.9241
×	×	✓	0.8362	1.0000	0.9108
×	✓	✓	0.8547	1.0000	0.9217
✓	×	✓	0.8376	1.0000	0.9116
✓	✓	✓	0.8848	1.0000	0.9389

（5）消融实验

为了进一步探索 MTVAE-GM 中各模块的有效性，本研究在 CCPAD 数据集上进行了消融实验，如表 4-3 所示。从结果可以看出，所有三个模块都发挥了重要作用。与未使用 Mamba 的模型相比，采用 Mamba 的模型在 F1 分数上分别提高了 0.53%、1.17% 和 1.72%。此外，通过 GAT 捕捉空间依赖性的模型在 F1 分数上分别提高了 0.66%、1.30% 和 2.73%。另外，采用 VAE 架构使得模型的 F1 分数平均提高了 0.74%。本研究的模型无缝整合了这些模块，最终在异常检测中表现出了卓越的性能。

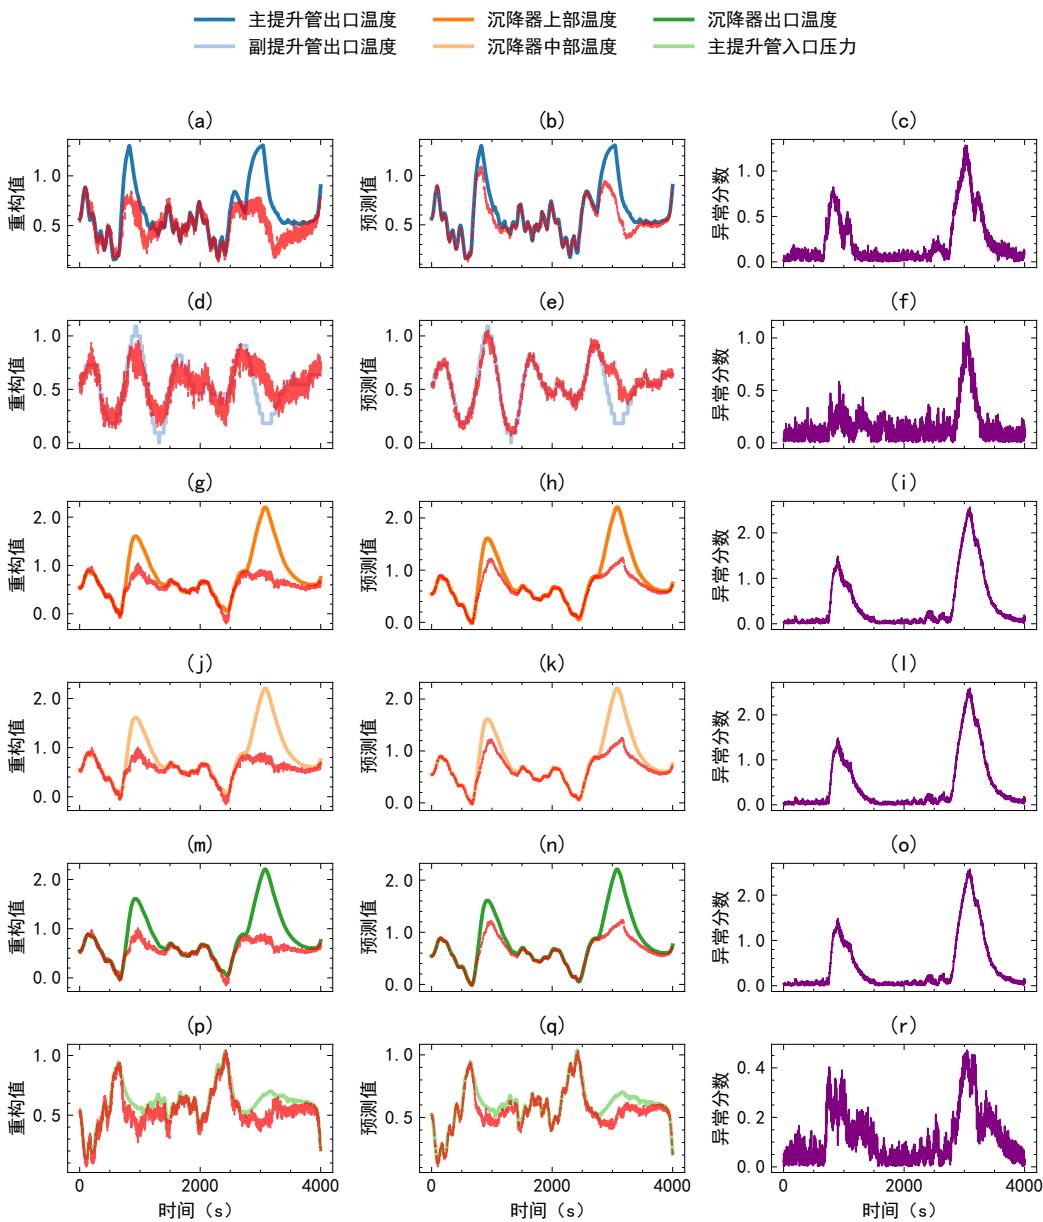


图 4-4 异常检测结果的可解释性分析

(6) 案例研究

异常检测结果的可解释性分析对反应再生系统至关重要，有助于安全管理人员及时应对异常情况。因此，本研究进一步评估所提出模型在可解释性分析方面的能力，以验证其实际应用价值。如图 4-4 所示，本文选取六个关键变量作为案例，展示异常检测结果的可解释性分析。从结果可以观察到，模型能够有效学习正常数据的变化模式，并在异常情况下生成显著误差的预测与重构。异常事件发生时，异常分

数显著升高，表明数据偏离正常模式。此外，为各变量设定合适的阈值，可进一步实现变量级的异常检测。另外，可以发现预测和重构结果可以互相协助，以增强异常分数的准确性，从而鉴别出异常发生。

4.3 基于变量因果图和概率寻优的异常根本原因分析

本文提出一种基于概率的异常传播溯源算法，通过追踪因果图中异常影响的最可能传播路径进行根本原因分析。该方法假设异常沿因果链传播，以识别最可能触发异常传播链的变量。本方法整合异常检测输出的异常分数与变量因果图，以对反应再生系统进行异常根本原因分析。

4.3.1 节点异常概率计算

如 4.2 节所述，本研究中异常分数用于判定变量异常状态。通过将异常分数转换为概率值，可更直观地量化异常严重程度并反映其不确定性，为后续根本原因分析提供概率化依据。给定变量 x_i 的异常分数 s_i ，其数值与变量偏离正常模式的程度呈正相关。基于阈值 τ 构建 sigmoid 概率映射函数，如式 (4-26) 所示：

$$p_i = \sigma(s_i - \tau) \quad (4-26)$$

其中 σ 为 sigmoid 函数，其定义如式 (4-27)：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (4-27)$$

该函数将差值 $s_i - \tau$ 映射至 $[0, 1]$ 概率空间。当 $p_i \rightarrow 1$ 时表征变量异常置信度高， $p_i \rightarrow 0$ 则指示正常状态。阈值 τ 作为判别基准，实现了异常状态的软分类。

4.3.2 路径异常概率计算

本算法通过逆向回溯因果图中的传播路径实现异常溯源。针对检测到的异常变量节点，自底向上遍历因果图，计算传播路径的累计异常概率以确定潜在根源。因果图中节点表征系统变量，有向边表征变量间因果依赖关系。当节点被标记为异常时，定义其上游传播路径的异常置信度为路径节点异常概率的累积，如式 (4-28)：

$$p_{path} = p(A) \times p(C_1) \times p(C_2) \times \cdots \times p(C_n) \quad (4-28)$$

华中科技大学硕士学位论文

其中 $\mathbf{V} = \{A, C_1, C_2, \dots, C_n\}$ 为上游路径节点集合。算法执行过程包含四个阶段：

- 1) 初始化阶段选定异常节点并设定路径阈值 τ_{path} ;
- 2) 逆向回溯计算路径置信度，沿因果边逐层向上游扩展；
- 3) 动态剪枝低置信度路径 ($p_{path} < \tau_{path}$)，保留高置信度路径继续回溯；
- 4) 输出满足阈值的最长有效路径，其起始节点作为候选根源。

阈值 τ_{path} 调控灵敏度和特异性平衡：较低阈值增加溯源广度但引入噪声，较高阈值提升准确性但可能遗漏弱信号。路径长度反映传播深度与系统性风险，优先保留较长的高置信路径。该概率回溯机制通过量化传播链可信度，为运维人员提供关键节点定位依据，有效预防异常事件升级。

表 4-4 过程变量编号和名称

编号	变量	编号	变量
X_5	沉降器顶旋分出口 A 温度	X_{35}	再生器一级入口东温度
X_6	再生器稀相南温度	X_{39}	再生器密相东温度
X_7	再生器密相西温度	X_{40}	沉降器顶旋分出口 B 温度
X_8	沉降器上部温度	X_{43}	沉降器顶温度
X_9	沉降器汽提段温度	X_{44}	再生滑阀差压
X_{12}	再生器密相北温度	X_{47}	主提升管进料盘管压力
X_{14}	沉降器出口温度	X_{50}	主提升管顶部压力
X_{16}	主提升管出口温度	X_{57}	沉降器顶部压力
X_{18}	再生器密相西温度	X_{66}	主提升管催化剂入口温度
X_{19}	沉降器中部温度	X_{67}	主提升管提升段温度
X_{23}	沉降器和再生器的差压	X_{69}	主提升管底部压力
X_{26}	提升管提升段温度	X_{72}	沉降器汽提段温度
X_{28}	三级旋风分离器温度	X_{77}	沉降器顶旋分出口 C 温度
X_{30}	烟气集合管温度	X_{82}	沉降器顶旋分出口 D 温度
X_{32}	提升管入口压力	X_{84}	再生器一级入口西温度

4.3.3 异常根本原因排名

当系统存在多个潜在根本原因时，需构建多维度评估指标进行优先级排序。本方法融合节点异常概率和路径传播效应，提出综合影响评分机制。对于候选根源节点 i ，其综合评分 s_i 由以下要素构成：

- 1) 节点异常概率 p_i : 反映节点自身异常可能性, 直接影响系统稳定性;
- 2) 路径传播效应 $\sum p_{path_j}$: 表征该节点通过因果链引发系统性风险的能力, 计算方式为所有下游传播路径异常概率之和。

综合评分公式如式(4-29):

$$s_i = \alpha p_i + \beta \sum_{j \in P_i} p_{path_j} \quad (4-29)$$

其中 P_i 为节点 i 的所有下游传播路径集合, 权重系数 α , β 调控局部异常与全局传播的贡献度。

4.3.4 实验结果

为了便于后续结果的讨论与分析, 本文从 84 个过程变量中筛选出 30 个关键变量, 具体如表 4-4 所示。这些变量涵盖了催化裂化装置反应再生系统的多个关键部位, 包括沉降器、再生器、提升管及相关压力、温度、差压等参数, 对系统运行状态的监测和异常诊断至关重要。

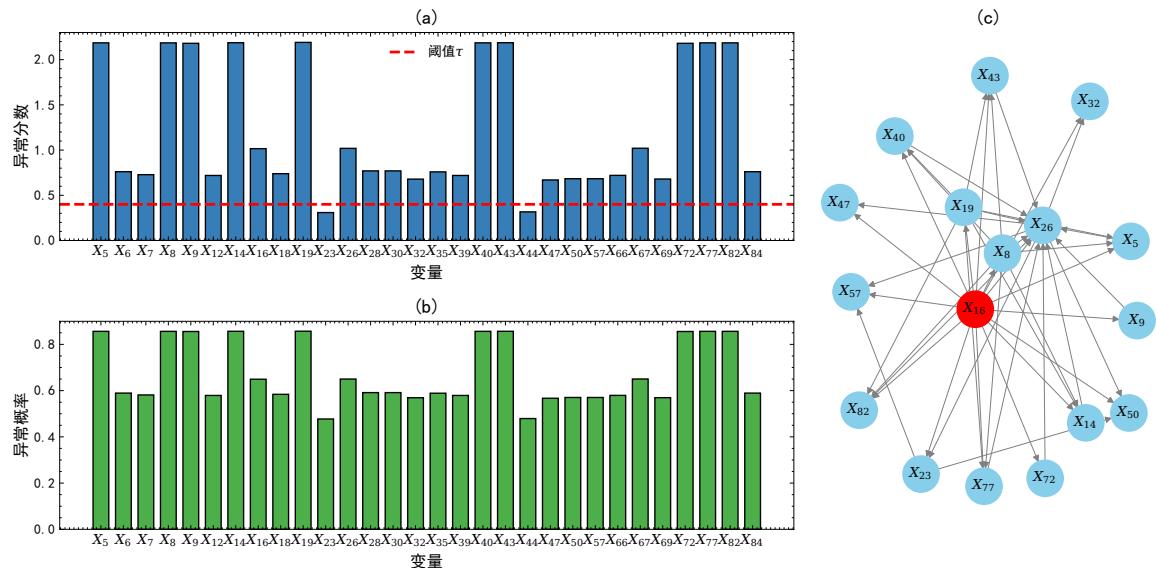


图 4-5 异常根本原因分析结果

为了进一步分析异常检测模型的性能, 本文选取某一异常场景进行示例分析。如图 4-5 所示, 该时刻各过程变量的异常分数及异常概率分布情况较为显著。假设异常检测阈值 τ 设定为 0.4, 则异常概率高于该阈值的变量被视为异常点。从图中可

华中科技大学硕士学位论文

以观察到，在该时刻，多个变量的异常概率均较高，说明系统存在大范围异常。这一现象不仅反映了反应再生系统的复杂性，同时也表明异常可能具有较强的关联性，即多个变量可能受同一异常源的影响。为了进一步探究异常的根本原因，本文结合所提出的根本原因分析方法，对异常进行了溯源，根本原因为 TI_1149A.PV（主提升管出口温度）。更详细的溯源结果如表 4-5 所示。在此次分析中， α 和 β 均被设置为 1。共识别出 144 条潜在的异常传播路径，表中展示了综合评分最高的 3 条路径。其中，综合评分最高的异常传播路径为路径 1，其异常根源变量为 X_{16} （主提升管出口温度）。该变量可能受到外部扰动或系统异常因素的影响，并进一步传播至下游变量，最终导致多变量异常现象的发生。

表 4-5 异常传播路径

路径编号	异常传播路径	异常根源变量	综合评分
1	$X_{16} \rightarrow X_{19} \rightarrow X_{14} \rightarrow X_{26} \rightarrow X_{23} \rightarrow X_{50}$	X_{16}	4.060547
2	$X_{16} \rightarrow X_{19} \rightarrow X_{43} \rightarrow X_{26} \rightarrow X_{23} \rightarrow X_{50}$	X_{16}	4.060546
3	$X_{16} \rightarrow X_{19} \rightarrow X_{14} \rightarrow X_{26} \rightarrow X_{23} \rightarrow X_{57}$	X_{16}	4.060526

4.4 本章小结

本章介绍了针对催化裂化装置反应再生系统的异常诊断方法。通过采集反应再生系统过程变量的实时数据，获得多变量时间序列，并基于多任务变分自编码器进行异常检测，识别异常变量。随后，结合安全知识图谱中的变量因果图，完成异常的根本原因分析。实验结果表明，所提方法能够有效地实时监控催化裂化装置反应再生系统的运行状况，准确检测异常变量，并进行精确、高效的根本原因分析。

5 催化裂化反应再生系统的安全知识辅助问答

在确定异常的根本原因后，可以结合安全知识图谱，为催化裂化装置反应再生系统推荐相应的异常处理方案。本章基于 RAG 框架，构建了一个结合安全知识图谱和大语言模型的安全知识辅助问答系统。该系统一方面为安全管理人员提供一种通过自然语言快速查询安全知识图谱的方式；另一方面，结合异常诊断结果，推荐可行的异常处理方案，从而提高异常诊断结果的可解释性和异常处理效率。

5.1 反应再生系统安全知识辅助问答框架

本章基于第 3 节构建的安全知识图谱，结合大语言模型 ChatGLM3，在 RAG 框架下开发了催化裂化装置反应再生系统的安全知识辅助问答系统。该系统旨在利用安全知识图谱增强对催化裂化装置反应再生系统的智能诊断与决策支持能力。本章主要介绍该问答系统的构建流程，其框架如图 5-1 所示。首先，利用大语言模型将安

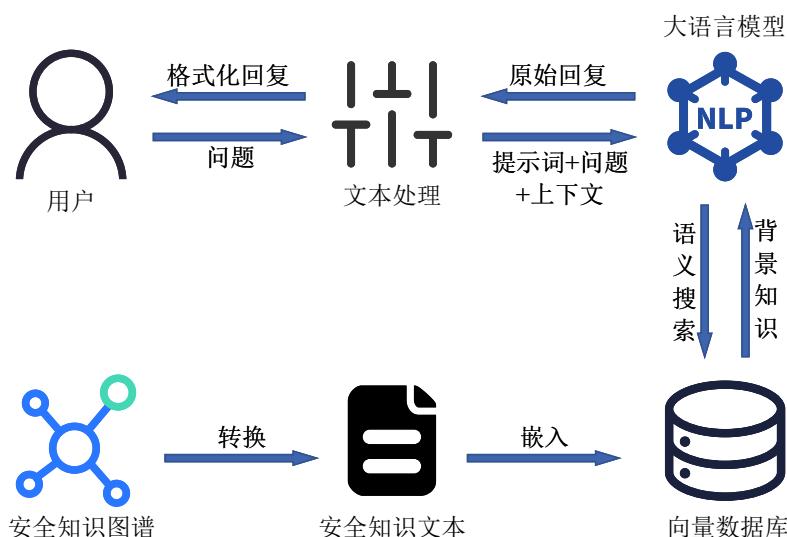


图 5-1 催化裂化装置反应再生系统安全知识辅助问答框架

全知识图谱中的节点及关系转换为可读文本。例如，“提升管出口温度”的“相关异常”为“提升管出口温度剧烈波动”。接着，将这些文本片段嵌入向量数据库，其中每个文本片段通过文本嵌入模型转换为向量表征。最后，当用户提问时，系统使用

相同的文本嵌入模型计算问题的向量表征，并在向量数据库中检索相关上下文内容，将其作为背景知识提供给大语言模型，以进行推理与答案生成。该方法使用户能够快速获取催化裂化装置反应再生系统的安全相关信息，从而有效应对生产过程中可能出现的安全隐患与故障。

5.2 基于 Sentence-BERT 的知识文本嵌入

在催化裂化装置反应再生系统的安全知识辅助问答系统中，知识图谱用于组织和存储系统的安全相关知识。为了更高效地利用知识图谱中的信息，本研究首先将知识图谱转换为结构化文本，并进一步使用 Sentence-BERT 进行向量化嵌入，并存入向量数据库 FAISS 中，以实现快速检索与推理支持。

5.2.1 背景知识

(1) Sentence-BERT

Sentence-BERT (SBERT) 是一种针对句子嵌入优化的 BERT 变体，能够计算句子的高维向量表征，并在语义相似性任务中表现优异。相比于传统的 BERT，SBERT 通过 Siamese 网络结构和对比学习损失函数，显著提高了嵌入计算的效率。其核心目标是将语义相似的文本映射到相似的向量空间，以支持高效的相似性检索。在 SBERT 模型中，每个输入句子 s_i 通过 BERT 编码器转换为固定维度的向量 \mathbf{h}_i :

$$\mathbf{h}_i = \text{SBERT}(\mathbf{s}_i) \quad (5-1)$$

其中， $\mathbf{h}_i \in \mathbb{R}^d$ ， d 为嵌入维度。SBERT 采用余弦相似度或欧氏距离度量文本间的相似性，使得相似文本的嵌入向量彼此接近，而不相关文本的向量相距较远。

(2) FAISS

FAISS (Facebook AI Similarity Search) 是由 Meta AI 开发的高效向量检索库，专为大规模高维向量搜索优化。其采用优化的数据结构与索引算法，在超高维空间中执行近似最近邻搜索，可显著提高检索速度。FAISS 提供多种索引方式，包括平坦索引、分层聚类索引和层次可导航小世界索引，以适应不同规模和精度需求的向量检索任务。同时，FAISS 支持多种相似性计算方法，如欧氏距离、内积和余弦相似

华中科技大学硕士学位论文

度，可根据具体应用选择合适的度量方式。为提升存储效率，FAISS 提供量化技术，在保证检索精度的同时减少向量存储占用。在本研究中，FAISS 通过高效的向量检索显著提升了知识检索的速度，使系统能够在大规模知识库中快速定位最相关文本，为后续的问答生成提供高质量的语义信息支持。

5.2.2 知识文本嵌入方法

在 RAG 框架下进行检索和问答时，需要将知识图谱转换为文本，以适配文本嵌入和向量检索机制。本研究采用大语言模型对知识图谱中的关系信息和节点属性进行自然语言转换，使其更易于检索和推理。知识图谱中的三元组 (h, r, t) 代表实体之间的关系，大语言模型可将其转换为自然语言描述，如图 5-2 所示。除实体关系外，节点的属性信息同样需要转换为可读文本，其转换过程与关系信息转换相同。然后，

请根据提供的知识三元组 (h, r, t) 生成简洁、流畅的自然语言描述，使其更易阅读和理解。请确保以下几点：

1. 以完整的语句表达实体 h 与实体 t 之间的关系 r ，使其符合自然语言习惯。
 2. 保持描述简明扼要，同时尽量补充必要的背景信息，以增强可读性。
 3. 避免重复表述，确保内容通顺、专业，适用于学术场景。
- 三元组：（提升管出口温度，相关异常，提升管出口温度剧烈波动）

提升管出口温度的相关异常表现为剧烈波动，这可能影响系统的稳定运行并导致反应条件的不稳定。

图 5-2 关系信息文本转换示例

使用预训练的 SBERT 模型将每条知识文本 s_i 映射为固定维度的向量 \mathbf{h}_i 。最后，将所有知识文本的向量表示存入向量数据库 FAISS，以支持高效相似性检索。

5.3 基于检索增强生成的检索与问答

基于检索增强生成的安全知识辅助问答包括知识检索和知识问答两个部分。首先，将用户问题转换为嵌入向量，并在向量数据库中检索相关上下文。随后，检索到的内容作为背景知识输入大语言模型，辅助其推理并生成答案。

5.3.1 知识检索

当用户提出问题 \mathbf{q} 时，系统首先使用 SBERT 计算其向量表示，如式 (5-2):

$$\mathbf{h}_q = \text{SBERT}(\mathbf{q}) \quad (5-2)$$

然后，在 FAISS 向量数据库中检索与问题最相关的知识文本。假设知识文本 \mathbf{s}_i 的嵌入向量为 \mathbf{h}_i ，则其相似度计算采用余弦相似度，如式 (5-3):

$$\text{similarity}(\mathbf{h}_q, \mathbf{h}_i) = \frac{\mathbf{h}_q^T \mathbf{h}_i}{\|\mathbf{h}_q\| \|\mathbf{h}_i\|} \quad (5-3)$$

其中，余弦相似度的取值范围为 $[-1, 1]$ ，值越接近 1 表示两个向量的方向越相近，即语义相似度越高。系统基于相似度得分选取前 k 个最相关文本，并将其作为背景知识输入大语言模型，以提升问答的准确性。

5.3.2 知识问答

检索到的相关知识文本被作为上下文信息输入到 ChatGLM3，以生成高质量的回答。为提高模型的推理能力，系统采用格式化输入的方式，将问题与检索到的知识文本组织为结构化提示，示例如下：

问题：用户问题

相关知识：检索文本 1，检索文本 2，...

请基于以上知识回答问题，并提供合理解释。

ChatGLM3 在接收到格式化输入后，结合检索到的相关知识与自身的语言理解能力进行推理，并生成准确、上下文一致的答案。

5.4 安全知识辅助问答实验结果

(1) 数据集

本研究构建了一个包括 127 条问答对的测试查询集。问题的答案均为人工检索并撰写，并使用大语言模型 ChatGLM3 润色，以贴合其生成的文本风格。后续将以此数据集为基础，检验所提安全知识辅助问答方法的有效性。

华中科技大学硕士学位论文

(2) 评价指标

本研究从知识检索和知识问答两个方面评估系统的性能。首先，针对知识检索的准确性，采用平均倒数排名（Mean Reciprocal Rank, MRR）和 Hits@k 作为评估指标，计算公式如式(5-4)和(5-5)：

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (5-4)$$

$$\text{Hits}@k = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \mathbb{I}(\text{rank}_i \leq k) \quad (5-5)$$

其中， Q 表示测试查询集的大小， rank_i 为第 i 个查询的正确答案在排序列表中的排名， $\mathbb{I}(\cdot)$ 为指示函数，当条件满足时取值为 1，否则为 0。MRR 衡量正确答案在检索结果中的平均排名，值越高表示检索精度越高；Hits@k 反映正确答案是否出现在前 k 个检索结果中，体现模型的召回能力。其次，为评估知识问答的准确性，计算大语言模型生成答案的 Sentence-BERT 嵌入向量与真实答案嵌入向量之间的余弦相似度，计算公式如式(5-6)：

$$\text{similarity}(\mathbf{h}_{\text{pred}}, \mathbf{h}_{\text{true}}) = \frac{\mathbf{h}_{\text{pred}}^T \mathbf{h}_{\text{true}}}{\|\mathbf{h}_{\text{pred}}\| \|\mathbf{h}_{\text{true}}\|} \quad (5-6)$$

其中， \mathbf{h}_{pred} 和 \mathbf{h}_{true} 分别为生成答案和真实答案的向量表征，余弦相似度取值范围为 $[-1, 1]$ ，值越接近 1 表示两个答案在语义上越接近。上述评价指标用于衡量检索与问答系统的整体性能，MRR 和 Hits@k 主要反映知识检索阶段的效果，而余弦相似度则用于评估最终生成的答案质量。

(3) 实验设置

为了评估安全知识辅助问答方法的有效性，本研究分别检验检索的准确性和整体问答系统的性能。本研究采用 Sentence-BERT 进行嵌入计算，嵌入维度设定为 768。为评估知识检索的准确性，以 TF-IDF 和 SimCSE 作为基准模型，并在相同数据集上进行对比实验。

(4) 方法验证

表 5-1 展示了不同模型在知识检索任务中的准确性。整体来看，本方法在检索准确性方面优于这些传统方法。这表明 Sentence-BERT 能够有效捕捉知识文本的深层语义信息，从而提升问答系统的知识检索性能。此外，为进一步分析知识文本嵌

表 5-1 不同模型的知识检索准确性对比

方法	MRR	Hits@5	Hits@10
TF-IDF	0.2216	0.3543	0.7402
SimCSE	0.2866	0.5197	1.0000
Sentence-BERT	0.4022	0.8504	1.0000

入的分布特性，采用 t-SNE 算法对嵌入向量进行降维可视化。图 5-3 展示了不同类型知识文本在 Sentence-BERT 生成的嵌入向量空间中的分布情况。从图中可以看出，一些类别的文本在嵌入空间中形成明显的聚类特征。说明 Sentence-BERT 生成的向量能够有效区分不同类型的知识信息，并保持良好的语义一致性。

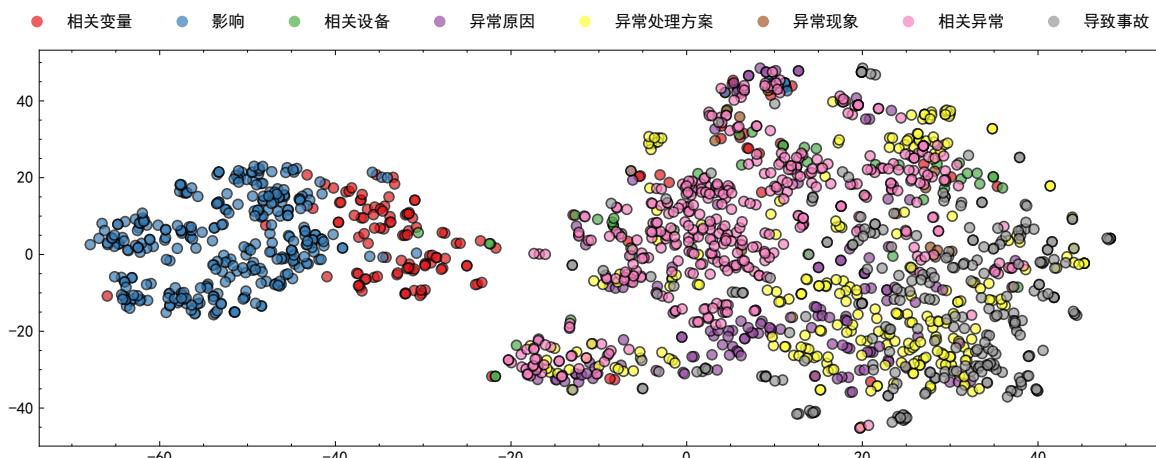


图 5-3 基于 Sentence-BERT 的知识文本嵌入可视化

在知识问答阶段，系统将检索到的相关节点信息与测试问题共同构建为上下文输入，传递给 ChatGLM3 生成答案。RAG 生成的答案与真实答案的余弦相似度达到 89.3%，并且在异常处置建议等场景下表现尤为突出。与传统基于检索的问答系统相比，RAG 能够结合结构化知识和大语言模型推理能力，生成更加连贯且信息全面的答案。图 5-4 展示了 RAG 生成答案的部分示例。综上，实验结果充分验证了 RAG

华中科技大学硕士学位论文

在催化裂化装置反应再生系统的安全知识辅助问答中的有效性和实用价值。其良好的检索与问答效果，为后续自动化异常处理方案推荐提供了支撑。

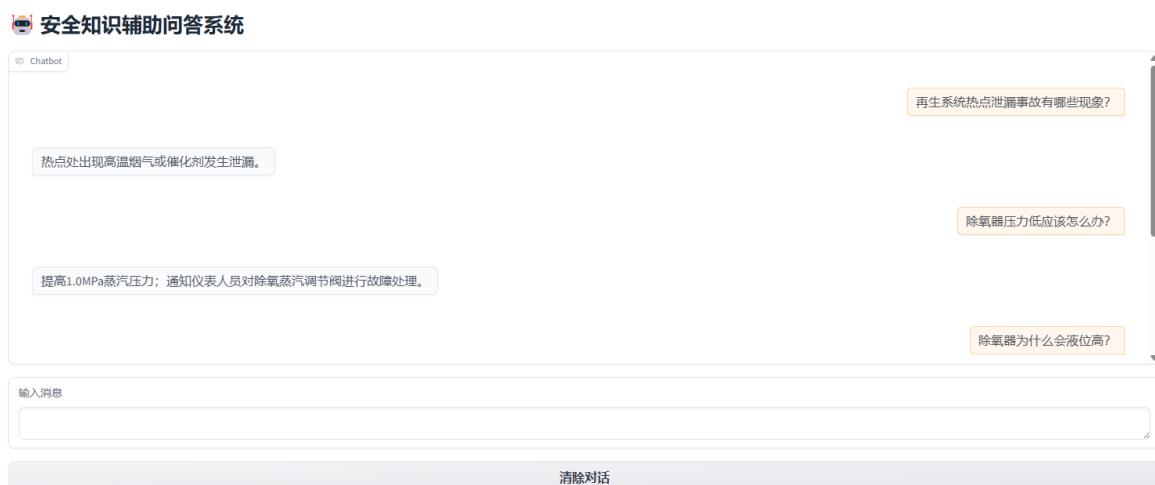


图 5-4 RAG 生成答案示例

5.5 本章小结

本章介绍了催化裂化装置反应再生系统的安全知识辅助问答方法。首先，构建了基于安全知识图谱的问答框架，并结合 RAG 和 ChatGLM3，实现了对催化裂化装置反应再生系统中安全问题的高效检索与答案生成。通过 ChatGLM3 将安全知识图谱进行文本化，并利用 Sentence-BERT 对其进行嵌入，系统能够高效提取安全相关信息，并通过大语言模型将其转化为准确、自然的回答。该系统一方面能够帮助安全管理人員快速检索信息，另一方面还可提供异常处理方案，从而提升异常诊断结果的可解释性和异常的处置效率。此方法为催化裂化装置反应再生系统的安全管理提供了智能化的决策支持。

6 催化裂化反应再生系统的智能安全分析软件设计与实现

为了探究所提催化裂化装置反应再生系统安全知识图谱构建、异常诊断与安全知识辅助问答方法的实用性，本章基于 OTS 系统，使用 Django 和 Vue 等前后端技术完成了催化裂化装置反应再生系统的智能安全分析软件的实现。该软件能够实时监控系统的运行状态，识别和诊断各种异常，提供科学的决策支持和异常处理方案。

6.1 关键模块设计与实现

本节首先对催化裂化装置反应再生系统的智能安全分析软件进行总体设计，然后详细介绍各模块的设计与实现，分别说明其设计思路、实现方法及核心功能。

6.1.1 总体设计

图 6-1 展示了催化裂化装置反应再生系统的智能安全分析软件的总体设计。该软件主要包括安全知识图谱管理模块、异常诊断模块、安全知识辅助问答模块以及可视化交互模块。本软件采用 Django 作为后端框架，Vue 作为前端框架，基于前后端分离的架构进行开发。开发环境以携带 Python 环境的常规计算机为基础，前端和后端均实现模块化设计，以提升开发效率和代码可维护性。软件最终以 Web 应用形式部署，用户可通过浏览器访问。软件开发及部署环境的具体要求如表 6-1 所示。

表 6-1 软件开发环境软硬件需求

硬件要求	软件要求
处理器主频：2GHZ 及以上 内存：2GB 及以上	操作系统：Windows10 64 位 软件依赖：Python 3.9.9

其中，安全知识图谱管理模块支持对安全知识图谱的检索和更新操作，从而后续能够对安全知识图谱进行查询和更新。异常诊断模块是软件的核心部分，负责对催化裂化装置反应再生系统运行过程中传感器采集的数据进行分析，精准识别设备运行中的异常状态，并对异常发生的根本原因进行分析。安全知识辅助问答模块基于安全知识图谱和大语言模型 ChatGLM3，支持通过自然语言对安全知识图谱中的

华中科技大学硕士学位论文

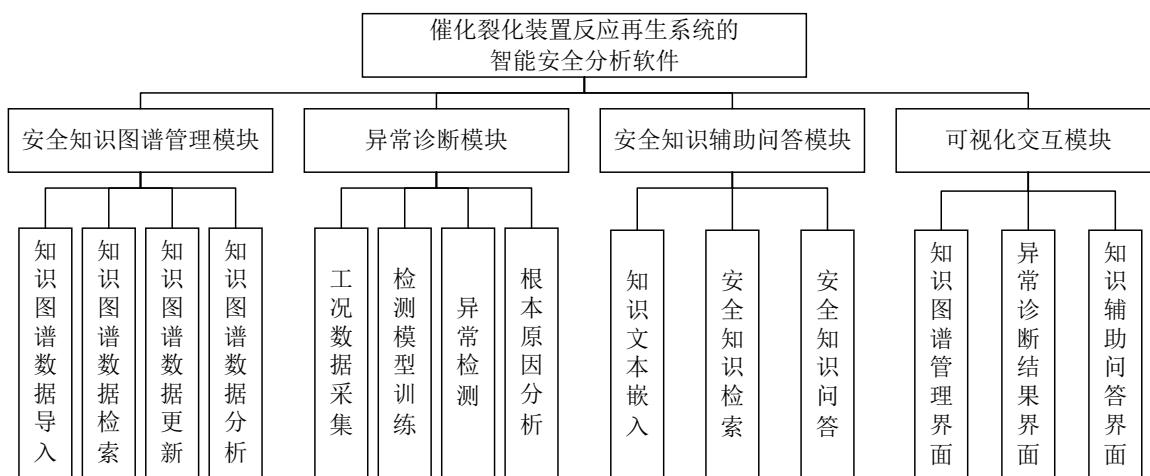


图 6-1 智能安全分析软件总体设计

信息进行检索和问答，从而协助用户进行知识检索。另外，还可以与异常诊断联合起来，实现自动化的异常处理方案推荐。可视化交互模块通过直观友好的界面将安全知识图谱管理、异常诊断和安全知识辅助问答的结果呈现给用户。各模块提供多种数据展示方式，包括折线图和柱状图等，使用户能够轻松掌握催化裂化装置反应再生系统运行状态和异常情况。

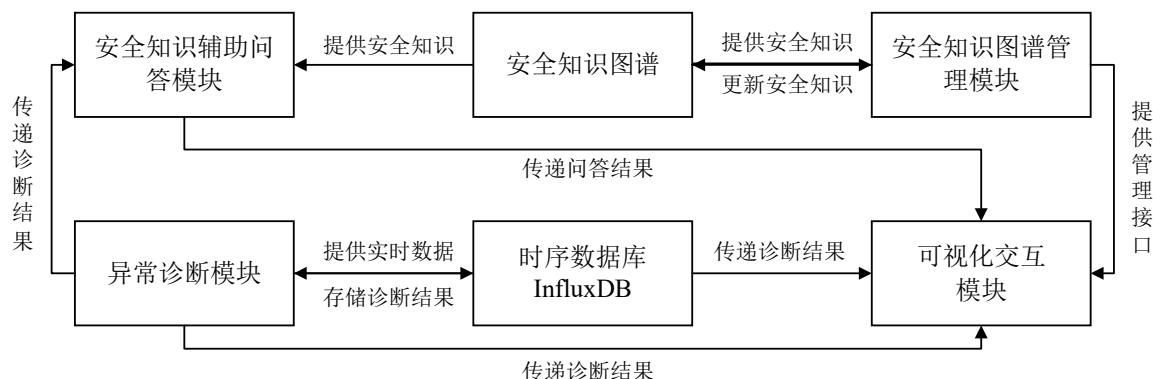


图 6-2 智能安全分析软件各模块间数据传递关系

为了确保各模块间的高效协作，系统设计了标准化的数据交互逻辑，实现安全知识图谱管理、异常诊断和安全知识辅助问答的数据无缝传递。详细的模块间数据交互流程图如图 6-2 所示。不同模块之间的数据流向均进行了展示，例如安全知识图谱为安全知识辅助问答模块提供安全知识，异常诊断模块将诊断结果传递给安全

知识辅助问答模块等。

6.1.2 安全知识图谱管理模块

本节详细介绍安全知识图谱管理模块，涵盖数据导入、检索、更新与分析四个部分。首先，实现安全知识图谱的自动导入，将 JSON 数据格式化并导入 Neo4j。然后，开发数据检索与更新接口，支持知识图谱的查询与修改。最后，对知识图谱数据进行统计分析，包括节点与边的统计等。

(1) 知识图谱数据导入

待导入的知识图谱数据需经过预处理，并转换为标准化的 JSON 格式，便于加载和处理。数据预处理的核心包括节点与边的构建，其中节点表示知识点，边用于描述节点之间的关联关系。每个节点包含名称、类型及相关属性，每条边则标注关系类型及其关联节点。通过规范化节点与边的连接，形成完整的知识图谱结构。为确保数据的规范性，本软件要求知识图谱数据遵循统一格式标准。

基于预处理后的知识图谱数据，需生成对应的 Schema，定义节点类型、节点属性、边类型和边属性等。这一步对于确保数据结构的规范性至关重要，同时为后续知识图谱的管理提供清晰的结构标准。在 Schema 设计中，节点表示知识点，类型包括“设备”、“异常”、“事故”等，属性则涵盖“名称”、“描述”、“所属类别”等详细信息。边用于描述节点之间的关联关系，类型如“相关设备”、“相关异常”、“导致事故”等。通过明确的 Schema 定义，软件能够实现规范化的结构管理，提升数据查询与分析效率。所有节点和边的类型及属性在数据导入时均需经过严格验证，确保符合 Schema 要求，保证知识图谱的一致性。

在生成知识图谱的 Schema 后，需使用 Neomodel 代码对节点和边进行管理。Neomodel 是基于 Neo4j 的 Python 库，提供了简洁高效的工具来组织和操作知识图谱数据。在 Neomodel 中，节点管理通过定义 Schema 生成对应的节点模型类。每个节点类继承自 StructuredNode，包含节点类型和属性定义，属性映射为 Neo4j 数据库中的字段，方便数据存储与操作。边的管理则通过 StructuredRel 类实现，每个关系类定义关系类型及其属性，使边不仅是简单的节点连接，更是带有丰富信息的关系描述，从而增强知识图谱的表达能力。Neomodel 的使用简化了节点和边的定义流程，

华中科技大学硕士学位论文

并支持便捷的增删查改操作，确保数据结构的一致性。同时，Neomodel 还提供高效的数据操作接口，满足复杂查询与分析需求。

接下来，利用 Neomodel 可将整理后的 JSON 数据导入 Neo4j 数据库。导入过程包括读取 JSON 文件中的节点和边数据，并依据预定义的 Schema，通过 Neomodel 接口将其转换为 Neo4j 数据库中的节点和关系。具体而言，首先逐一读取 JSON 文件中的节点及其属性，创建对应的节点实例。随后，根据节点之间的关系信息生成边，并存入数据库。Neomodel 在此过程中自动完成数据存储，确保所有节点和边按照预设模型结构插入数据库，保证数据完整性和一致性。此外，Neomodel 支持批量导入操作，显著提升大规模知识图谱数据的导入效率。通过这一流程，知识图谱数据能够快速、准确地导入 Neo4j，为后续查询与分析奠定基础。数据导入完成后，用户可直接利用 Neo4j 强大的查询功能对知识图谱进行探索与可视化展示。

(2) 知识图谱数据检索

知识图谱数据检索通过 Django REST API 实现，每个接口对应特定操作，如节点查询等。用户可通过调用 API 灵活访问和操作知识图谱。系统共设计了 5 个知识图谱数据检索接口，表 6-2 列出了各接口的参数及说明，包括参数名称、是否必选、参数类型以及参数描述。

表 6-2 知识图谱数据检索接口参数与说明

接口	参数名	必选	类型	说明
节点检索	node_id	是	String	节点的唯一标识符
	node_type	是	String	节点的类型
节点列表检索	node_type	是	String	节点的类型
	page	是	Int	当前的页码
	max_items	否	Int/None	每页最多返回的节点数
节点类型检索	-	否	-	-
节点属性检索	node_type	是	String	节点的类型
节点条件检索	node_type	是	String	节点的类型
	args	否	Dict	检索条件

华中科技大学硕士学位论文

首先，介绍节点检索接口。该接口支持用户根据节点类型和 Neomodel 生成的节点 ID 查询特定节点信息，并快速获取节点的详细属性。用户仅需提供节点的唯一标识符节点 ID 和类型，即可精准定位目标节点。知识图谱节点列表检索接口支持分页查询，便于用户在大规模知识图谱中快速获取特定类型的节点信息。用户可指定节点类型、当前页码及每页返回的节点数量，系统根据参数返回对应页的数据。分页机制有效避免一次性返回过多数据，从而提升查询效率。知识图谱节点类型检索接口用于获取系统中已定义的所有节点类型，帮助用户了解可管理和可查询的节点类别。该接口适合系统初始化或用户查看现有节点类型时使用，无需额外请求参数。接口返回当前知识图谱中所有可用节点类型的名称，便于用户开展数据查询、节点管理和数据分析。知识图谱节点属性检索接口支持用户根据节点类型批量查询该类别的所有节点及其详细信息。通过此接口，用户可获取指定类型节点的属性，便于快速处理大规模数据。该接口适用于需要一次性查询特定类别节点详细数据的场景。知识图谱节点条件检索接口支持用户根据节点类型和指定属性值精准筛选节点。用户可通过设定特定属性条件，查询符合要求的节点，从而灵活控制查询结果，快速定位目标节点。该接口特别适用于需要基于多个属性筛选节点的场景。

(3) 知识图谱数据更新

知识图谱数据更新部分提供节点更新接口，依然通过 Django REST API 实现。知识图谱节点更新接口支持用户基于节点 ID、节点类型及待更新的属性，对知识图谱中的节点信息进行修改。用户可灵活更新节点的名称、描述等属性，确保知识图谱数据随业务需求和实际情况的变化得到及时调整，从而提升数据管理的准确性和灵活性。表 6-3 列出了该接口的请求参数及说明。

表 6-3 知识图谱节点更新接口参数列表

参数名	必选	类型/参数值	说明
node_type	是	String	节点的类型
node_id	是	String	节点的唯一标识符
properties	是	Dict	待更新的节点属性

(4) 知识图谱数据分析

知识图谱数据分析部分对知识图谱中的关键信息进行统计，包括节点数量、关系数量和节点度分布。所有数据分析功能均通过 Django REST API 接口实现，每个接口对应特定的统计任务。知识图谱节点数量统计接口用于统计各类节点的数量，帮助用户快速了解不同节点类型的分布情况。此接口无需额外的 Body 参数，返回结果包括各节点类型及其对应数量，并以键值对形式表示。知识图谱关系数量统计接口用于统计知识图谱中各类关系的数量，帮助用户了解节点之间的连接情况。该接口无需额外的 Body 参数，返回结果为包含所有关系类型及其数量的列表。每种关系类型以键值对形式表示，其中键为关系名称，值为该关系的数量。知识图谱节点度分布统计接口用于分析图谱中节点的连接情况，即统计各节点的度分布。节点度指某个节点所连接的边的数量，该分布可用于评估图谱的连接密度，识别关键节点或潜在的结构性问题。该接口无需额外的 Body 参数，返回结果包括不同度值对应的节点数量。通过度分布分析，用户可以了解高连接度节点的占比，识别知识图谱中的核心节点或孤立节点。

6.1.3 异常诊断模块

本节详细介绍异常诊断模块的设计思路与实现方法。该模块首先采集 OTS 系统仿真的催化裂化装置反应再生系统实时数据，并基于这些数据训练异常检测模型。随后，利用该模型监测实时数据，识别异常发生的时刻及受影响的过程变量。最后，结合根本原因分析方法，对异常源头进行追溯。

(1) 反应再生系统数据采集

反应再生系统数据采集对训练异常检测模型至关重要。该系统的过程数据，包括温度、压力和流量等，均通过数据采集系统实时采集。为有效训练模型，需对这些数据进行预处理，步骤包括清洗无效数据、填补缺失值以及进行标准化，确保数据的一致性和准确性。基于 OTS 系统，本研究构建了一个异常检测数据集，该数据集涵盖了 84 个变量和 50000 个时间点。数据存储于 CSV 文件中，文件结构如图 6-3 所示。在此文件中，每一列代表一个测点，而每一行记录了特定时刻的传感器采样值。

华中科技大学硕士学位论文

	FIC_1123.PV	V	: PRCA1101B.PV	V	: TIA1160A.PV	V	: PI_1136.PV	V	: TI_1143A.PV	V	: TI1117B.PV	V	: TI1118B.PV	V	: TI1113.PV	V	: TI1116A.PV	V	: DR1110.PV	V	: TIA116A.PV	V	
1	1783.97998	0.15	184.014999	0.24396	517.320007	679.450012	681.200012	487.754974	517.299988	571.25	184.01												
2	1783.97998	0.15	184.014999	0.24396	517.320007	679.450012	681.200012	487.754974	517.299988	571.799988	184.01												
3	1783.799927	0.15	184.014999	0.24396	517.320007	679.450012	681.200012	487.754974	517.299988	571.75	184.01												
4	1783.799927	0.15	184.014999	0.24396	517.320007	679.450012	681.25	487.799988	517.349976	571.549988	184.01												
5	1783.619995	0.15	184.014999	0.24396	517.35498	679.450012	681.25	487.799988	517.349976	571.200012	184.01												
6	1783.619995	0.15	184.014999	0.24396	517.35498	679.450012	681.25	487.799988	517.349976	571.349976	184.01												
7	1783.619995	0.15	184.014999	0.24396	517.35498	679.450012	681.25	487.799988	517.349976	571.149963	184.01												
8	1783.619995	0.15	184.014999	0.24396	517.35498	679.450012	681.25	487.799988	517.349976	571.75	184.01												
9	1783.439941	0.15	184.014999	0.24396	517.35498	679.450012	681.25	487.799988	517.349976	571.0	184.01												
10	1783.439941	0.15	184.014999	0.24396	517.35498	679.450012	681.25	487.799988	517.349976	571.75	184.01												
11	1783.439941	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.349976	571.849976	184.01												
12	1783.439941	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.349976	571.25	184.01												
13	1783.439941	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.399963	571.75	184.01												
14	1783.439941	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.399963	571.849976	184.01												
15	1783.439941	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.399963	571.75	184.01												
16	1783.439941	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.349976	571.349976	184.01												
17	1783.619995	0.15	184.014999	0.24396	517.390015	679.450012	681.25	487.845001	517.399963	571.149963	184.01												
18	1783.619995	0.15	184.014999	0.24394	517.390015	679.450012	681.25	487.845001	517.399963	571.099976	184.01												
19	1783.619995	0.15	184.014999	0.24394	517.390015	679.450012	681.25	487.845001	517.399963	572.0	184.01												
20	1783.619995	0.15	184.014999	0.24394	517.390015	679.450012	681.25	487.845001	517.399963	571.399963	184.01												
21	1783.619995	0.15	184.014999	0.24394	517.390015	679.450012	681.25	487.845001	517.399963	571.75	184.01												
22	1783.619995	0.15	184.014999	0.24394	517.390015	679.450012	681.25	487.845001	517.399963	571.799988	184.01												
23	1783.619995	0.14997	184.014999	0.24394	517.390015	679.450012	681.25	487.845001	517.399963	571.25	184.01												
24	1783.619995	0.14997	184.014999	0.24392	517.390015	679.450012	681.25	487.845001	517.399963	571.549988	184.01												
25	1783.619995	0.14997	184.014999	0.24392	517.390015	679.450012	681.25	487.845001	517.399963	571.25	184.01												
26	1783.619995	0.14997	184.014999	0.24392	517.390015	679.450012	681.25	487.845001	517.399963	571.450012	184.01												
27	1783.619995	0.15	184.014999	0.24392	517.424988	679.450012	681.25	487.845001	517.399963	571.899963	184.01												

图 6-3 异常检测数据集示例

(2) 异常检测模型训练

在异常检测模型的训练过程中，需要使用很多辅助函数，包括数据处理、模型训练和保证训练过程可复现性等。本模块实现了多种辅助函数，包括日志记录、随机数种子设置和模型参数初始化等。日志记录函数用于跟踪模型训练和数据处理的关键信息，例如训练进度、损失值和评估结果，便于开发人员和操作人员监控训练状态和模型表现。该功能通常通过 Python 的 logging 库实现。为保证训练过程的可复现性，需要固定随机数种子。这在调试和性能对比中尤为重要，因为机器学习中的许多操作依赖随机性。通过设定相同的随机数种子，可以确保每次训练的结果一致。此外，神经网络模型的权重初始化对训练效果至关重要。合理的初始化可以避免梯度消失或梯度爆炸，并加速模型收敛。常见的初始化方法包括 Xavier 初始化和 He 初始化等。详细的函数接口如表 6-4 所示。在模型定义阶段，参数初始化对加速收敛并避免梯度消失或爆炸至关重要。为提高训练效率，本软件采用 He 初始化方法，该方法适用于使用 ReLU 激活函数的神经网络，有助于提升收敛速度和稳定性。训练过程中，持续监控误差的分布，正常数据的误差较小，而异常数据的误差显著增大。基于这一特性，合理设定阈值对于异常检测的准确性至关重要。因此，训练完成后，需要评估模型性能，分析误差的分布，并结合实际应用需求确定合适的阈值。

表 6-4 辅助函数示例表

函数或类名	所需参数	功能
Logger	无需参数	管理日志
calculate_f1_score	异常分数和标签、阈值	计算异常检测的 F1 分数
set_seed	随机数种子	设置随机数种子
init_weights	模型权重	初始化模型权重
get_segments	数据异常与否的标签	获取异常数据时间段
get_anomaly_scores	预测值与真实值	获取异常分数
get_best_threshold	标签和异常分数	计算最佳的阈值

(3) 实时异常检测

在催化裂化装置反应再生系统的运行过程中，各传感器数据持续变化。通过训练自编码器，可将原始高维数据映射到低维表征，并进行重构和预测。当自编码器接收实时传感器数据时，编码器首先对数据进行非线性变换，提取低维表征；随后，解码器对其重构和预测，并计算异常分数。对于正常数据，异常分数较小，而异常数据由于与训练集中学习的正常模式存在较大差异，导致异常分数显著增大。因此，通过异常分数与检测阈值的对比，可快速识别潜在异常。图 6-4 展示了整体异常分

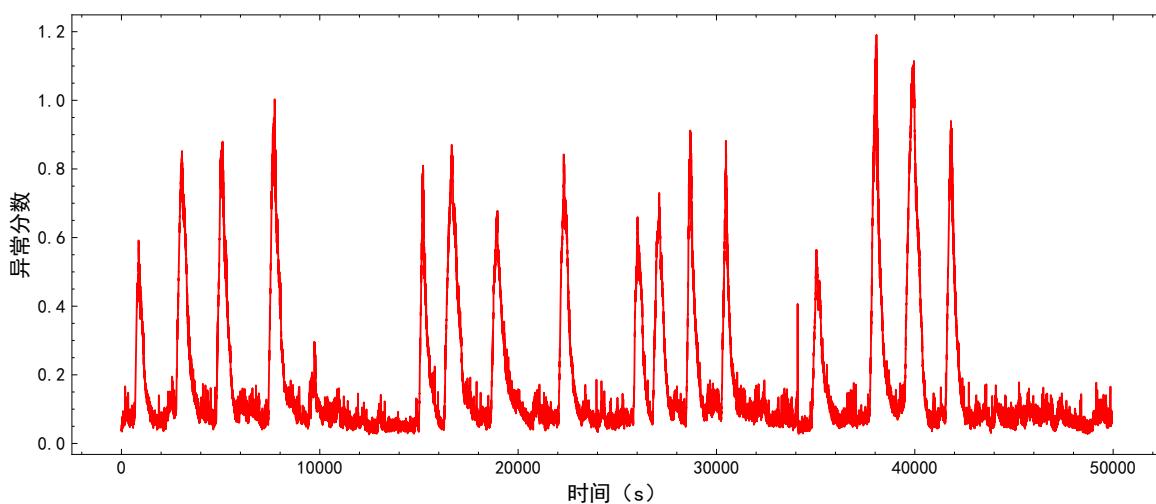


图 6-4 整体异常分数曲线

数的曲线示例，从图中可见，共发生 16 次异常事件。在异常检测过程中，除了识别整体异常状态，精准定位具体的异常变量同样至关重要。分析对异常分数贡献最

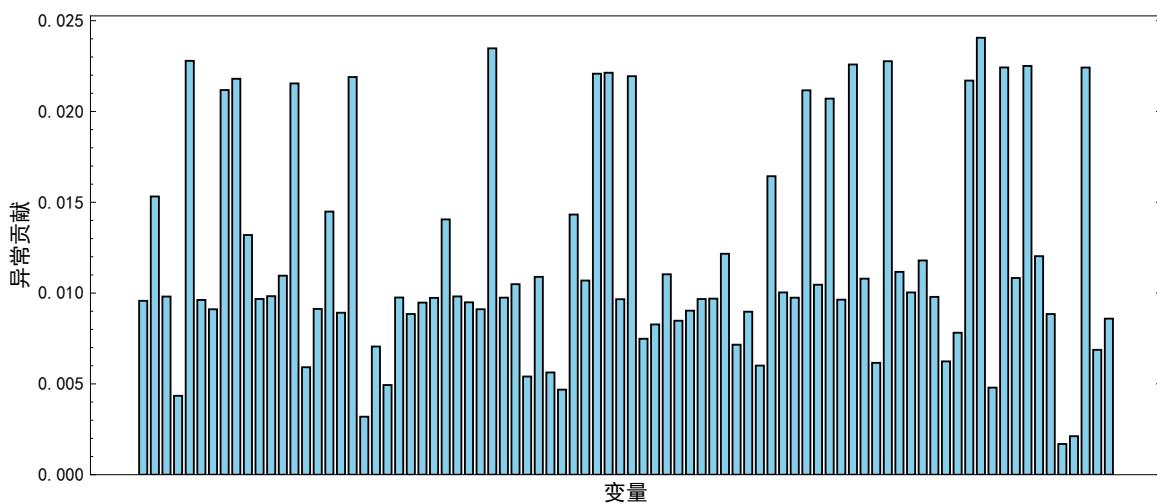


图 6-5 不同变量对于整体异常分数的贡献

大的传感器数据，可帮助操作人员明确异常影响。本模块通过评估各输入传感器数据对异常分数的敏感性来识别异常变量。具体而言，计算每个输入传感器数据对异常分数的贡献度，以确定异常状态下影响最显著的变量。异常变量识别有助于精准定位异常根本原因，从而进一步提升反应再生系统的运行安全性。图 6-5 展示了不同变量对整体异常分数的贡献情况。从图中可见，一些变量对异常分数的贡献超过 2%。通过设定贡献阈值，可识别对整体异常影响较大的变量，并将其作为异常变量。

(4) 根本原因分析

在异常检测后，可以将异常分数转化为异常概率，然后再进行如 4.3 节介绍的异常根本原因分析。根据安全知识图谱中的因果图和传递熵值，可分析异常如何在节点间传播。传递熵值越大，表示信息流动强度越高，异常传播的可能性也越大。因此，首先需分析异常节点与其他节点的关系，识别可能的异常传播路径。为进一步确定传播路径，需要设定概率阈值。当异常节点的异常概率超过该阈值，即可认为其对异常事件的发生具有较大影响，并可能为根本原因。合理设定阈值有助于筛选不重要的传播路径，聚焦关键变量。最终，结合传递熵与异常概率，确定异常的根本原因。根本原因分析采用反向追踪方式，从异常概率较高的节点出发，沿传递熵较大的路径逐步回溯，最终锁定异常源头。

6.1.4 安全知识辅助问答模块

本节详细介绍安全知识辅助问答模块的设计思路与实现方法。该模块首先将安全知识图谱数据转化为知识文本，并使用 Sentence-BERT 对其进行嵌入。然后，对于查询的问题进行嵌入，并检索最相关的文本，基于大语言模型进行答案生成。最后，将安全知识辅助问答与异常诊断进行结合，自动化推荐异常处理方案。

(1) 知识文本嵌入

知识文本嵌入是 RAG 框架在安全知识辅助问答中的核心环节，其主要目标是将安全知识图谱中的节点及关系信息转换为密集向量表征，以支持高效检索与语义推理。该过程不仅提高了知识的可访问性，还增强了知识图谱与大语言模型的语义空间对齐能力。具体而言，首先对安全知识图谱进行结构化处理，将每个节点的属性信息及关联关系转换为自然语言描述。例如，对于“提升管出口温度”节点，生成的文本可能为“提升管出口温度的相关异常包括提升管出口温度剧烈波动”。随后，利用预训练的 Sentence-BERT 对这些文本片段进行向量化嵌入，并存入 FAISS 向量数据库，形成知识图谱的向量索引库。这一过程实现了从结构化知识到语义向量空间的转换，使知识检索与问答生成能够基于语义相关性进行高效匹配。

(2) 检索与答案生成

在用户输入自然语言问题后，系统首先使用 Sentence-BERT 计算问题的语义向量表征。然后，在 FAISS 向量数据库中计算查询向量与所有文本嵌入向量的余弦相似度，检索出最相关的知识片段。不同于传统文本检索方法，RAG 框架依赖语义匹配，以确保检索到的结果符合语义相似性。例如，针对用户问题“提升管出口温度异常如何处理？”，系统不仅返回与“提升管出口温度”相关的异常描述，还检索该异常的潜在原因及可行的处理方案，以形成完整的知识背景。在检索完成后，系统将用户问题及检索到的知识片段组合为结构化提示词，并发送给 ChatGLM3 进行推理与答案生成。模型综合外部知识和自身语言理解能力，生成最终回答，并将答案返回前端界面。

(3) 异常处理方案推荐

以某异常工况为例，图 6-6 展示了其总体异常分数及根本原因测点 TI_1149A.PV（主提升管出口温度）的数据变化曲线，以及相应的预测与重构结果曲线。可以观察到，异常分数持续处于较高水平，表明当前反应再生系统存在异常状态。同时，预测与重构结果均低于真实值，说明主提升管出口温度异常偏高。因此，可利用安全知识辅助问答系统查询“主提升管出口温度偏高如何处理？”。系统通过检索安全知识图谱相关文本知识，结合大语言模型的推理能力，建议处理方案，从而实现异常处理方案的自动化推荐。

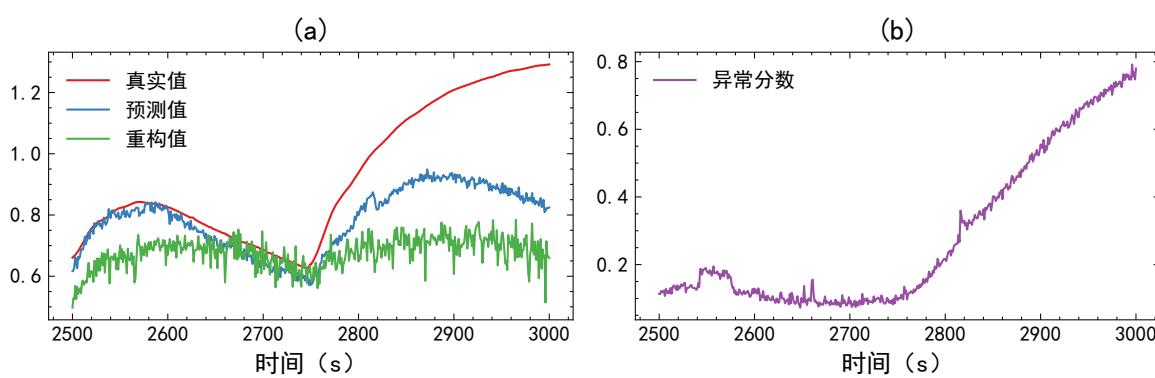


图 6-6 异常场景示例

6.2 软件功能测试与分析

本节对智能安全分析软件的功能进行了测试与分析，涵盖安全知识图谱管理、异常诊断和安全知识辅助问答三个模块。各模块均通过可视化界面为操作人员提供便捷功能，帮助其高效识别系统潜在问题并及时采取相应措施。

6.2.1 安全知识图谱管理模块

安全知识图谱管理模块包括知识图谱检索界面和知识图谱更新界面，两者共同构成安全知识图谱管理的可视化展示。该模块支持对安全知识图谱的快速检索和修改，并提供对知识图谱数据的统计分析。知识图谱检索界面允许用户根据节点类型和属性进行查询。用户在界面上选择节点类型，或输入 Cypher 语句后，前端通过 Axios 向后端发送请求，检索符合条件的节点数据。后端返回的数据将在界面上动态渲染，用户可以查看到所有符合条件的节点信息。该界面的实现使得用户可以轻

华中科技大学硕士学位论文

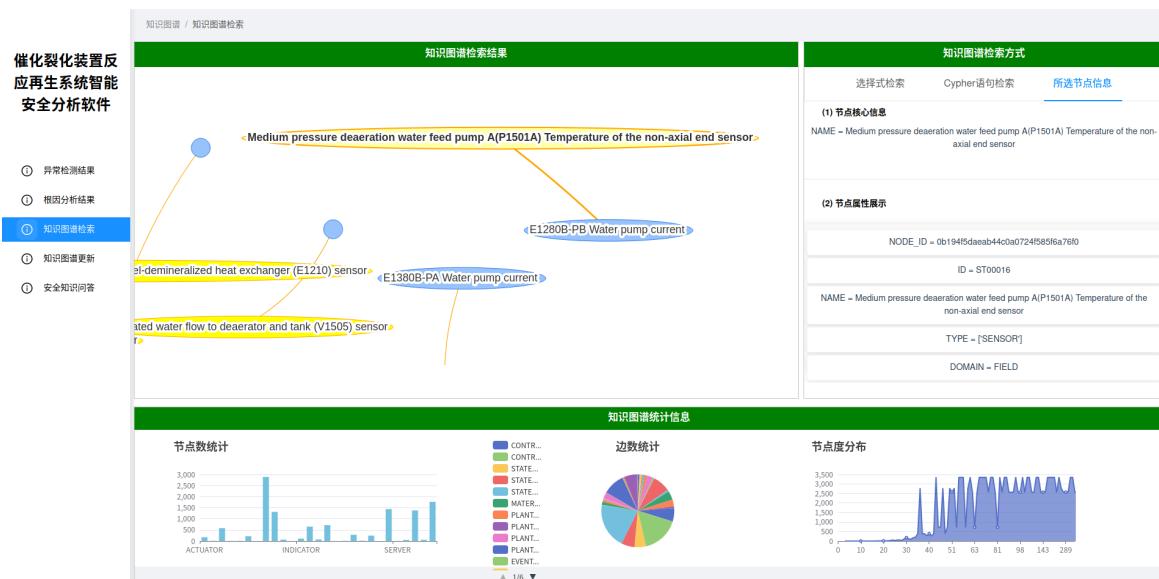


图 6-7 知识图谱检索界面

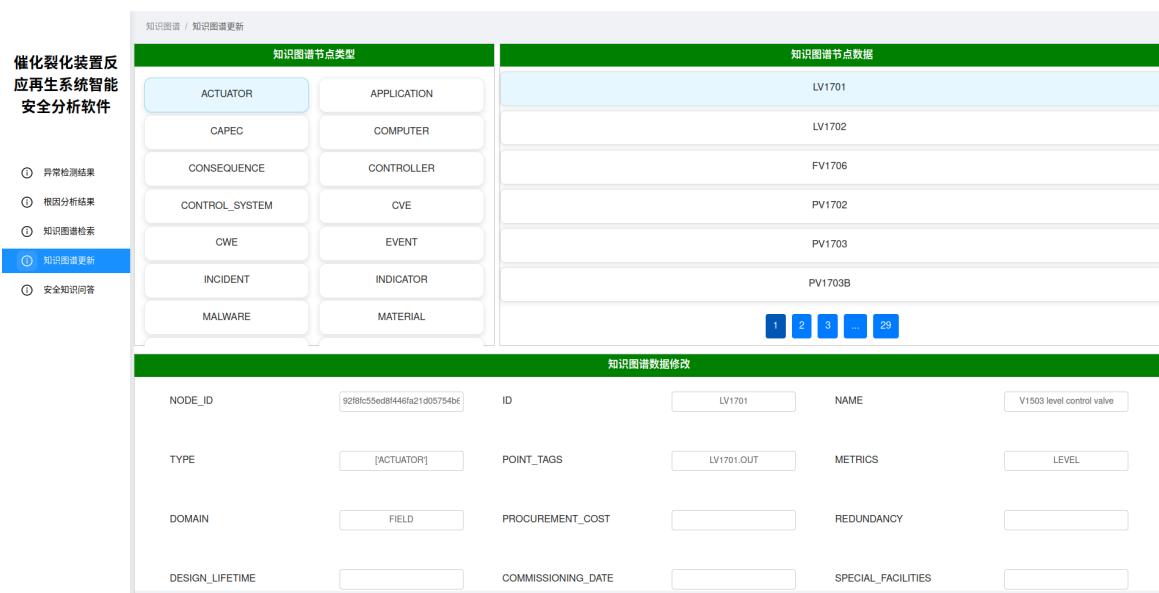


图 6-8 知识图谱更新界面

松、快速地查询到知识图谱中任何类型节点的详细信息，便于数据分析与决策支持。另外，该界面还展示了知识图谱数据的一些统计信息，如图 6-7 所示。知识图谱更新界面允许用户对知识图谱中的节点信息进行编辑和更新。用户可以选择要更新的节点，修改其属性，并通过前端的表单提交更新请求。前端通过 Axios 将更新的数据发送到后端接口，后端完成更新后将反馈结果。此界面使用户能够实时地修改知

识图谱中的节点属性，并将更改应用到知识图谱中，提升了知识图谱管理的灵活性。该界面如图 6-8 所示。在完成知识图谱数据更新后，将会实时完成知识文本嵌入库的相应更新，从而保证 RAG 检索到的知识的准确性。

6.2.2 异常诊断模块

异常诊断模块包括异常检测结果界面和根本原因分析结果界面，两者共同构成异常诊断的可视化展示。该模块支持对反应再生系统的实时监控，并提供异常检测与根本原因分析结果。异常检测结果界面用于展示反应再生系统运行过程中识别出的异常情况，帮助操作人员及时发现并应对潜在安全隐患。界面基于异常检测模型的输出结果，将异常状态以可视化形式呈现，便于操作人员快速定位问题来源。当一个或多个传感器数据的变化趋势异常时，系统自动触发异常检测，并在界面中显示相关异常信息。同时，界面还展示传感器数据的实时变化曲线及对应的实时异常分数。一般而言，异常分数越大，表示异常可能性越大。当异常分数超过设定阈值时，系统将该变量标记为异常，并通过柱状图直观显示。图 6-9 展示了异常检测结果界面的整体效果。以 TI_1149A.PV 为例，对某特定异常场景进行了展示。可以发现其实时数据呈现上升的趋势，并且异常分数逐步上升，这说明当前反应再生系统处于异常状态。柱状图展示了不同变量的异常与否，这可以直观地展现系统的异常程



图 6-9 异常检测结果界面图

华中科技大学硕士学位论文

度。根本原因分析结果界面是异常诊断模块的重要组成部分，主要用于展示根本原因分析模块识别出的故障根源。界面以图形化方式呈现异常传播路径、各变量对整体异常的贡献度及推荐的异常处理方案，帮助操作人员快速定位引发故障的根本原因。根本原因分析结果以因果图形式展示，反映设备各传感器之间的异常传播路径。每个节点对应一个传感器测点，节点之间的有向边表示变量间的信息传递关系，节点上标注测点编号，便于用户识别与查看。通过对因果图逐层推理，操作人员可以识别引发故障的关键因素，并据此制定有效应对措施。此外，界面还通过柱状图展示每个变量对整体异常的贡献度，便于用户从贡献分析的角度进一步判断关键异常变量。当异常发生时，结合安全知识辅助问答系统，完成异常处理方案的推荐。图 6-10 展示了根本原因分析结果界面的整体效果，当前异常的根本原因为 TI_1149A.PV（主提升管出口温度）。右侧展示了推荐的异常处理方案，安全管理人员认根据推荐的异常处理方案及时完成异常的处置，从而避免异常进一步发展为事故。柱状图展示了不同变量对整体反应再生系统异常的贡献度，可以发现当前异常对测点 PI_1180.PV 的影响最大。这些信息也有助于安全管理人员了解当前异常状态，从而采取适当的措施来处理异常。

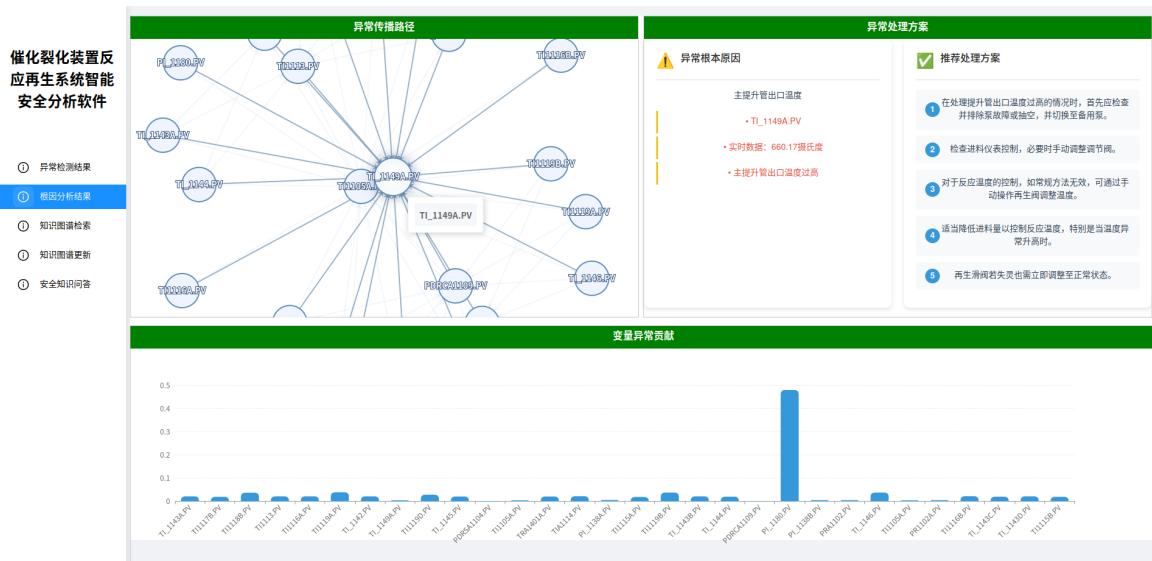


图 6-10 根因分析结果界面图

6.2.3 安全知识辅助问答模块

安全知识辅助问答模块基于安全知识图谱和大语言模型，为操作人员提供智能化的知识检索与解答功能。操作人员可通过自然语言输入问题，系统从安全知识图谱中检索相关知识，并结合大语言模型的推理能力生成答案，帮助操作人员快速获取针对性的安全知识和处置建议。知识问答界面支持操作人员直接输入安全相关问题，并发起查询。前端通过 Axios 向后端 RAG 接口发送请求，后端根据问题内容，结合安全知识文本检索与大语言模型生成结果，形成最终答案，并返回至前端界面。知识问答界面如图 6-11 所示。例如，询问某些异常的现象、处理方案和原因，安全知识辅助问答系统均可正确高效地回答。

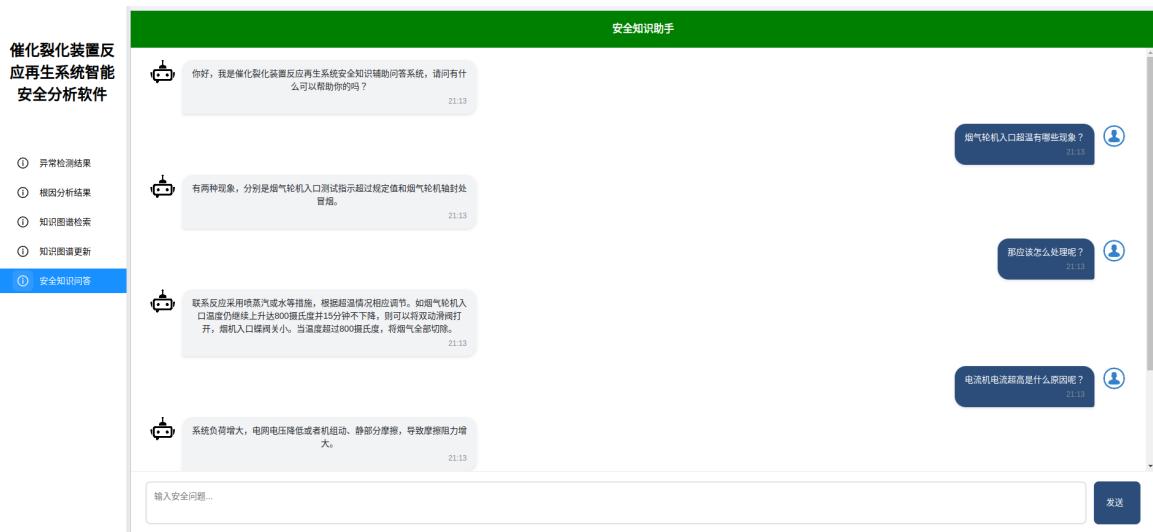


图 6-11 安全知识问答界面

6.3 本章小结

本章介绍了催化裂化装置反应再生系统智能安全分析软件的设计与实现。首先，对智能安全分析软件进行需求分析，总结软件所需的功能点。紧接着进行总体设计，对软件包含的模块和模块间的数据传递关系进行阐述。随后，对安全知识图谱管理、异常诊断、安全知识辅助问答三个模块的详细设计和实现进行介绍。最后，对软件进行功能测试，并对其表现进行分析。该软件能够实时监控反应再生系统的运行状态，自动检测和诊断异常，并自动提供异常处理方案，从而显著提升系统的安全性。

7 总结与展望

7.1 工作总结

随着催化裂化装置反应再生系统在石油化工行业的广泛应用，其安全稳定性对生产过程的影响日益显著。然而，传统安全分析方法难以同时考虑复杂的工艺特征和非结构化文本知识，导致在应对复杂异常工况时，往往无法准确诊断异常并提供有效的处理方案。为此，本文提出了一种融合安全知识图谱与异常诊断的智能安全分析方法，旨在实现实时异常诊断，并结合安全知识图谱生成异常处理方案。本文的主要研究工作包括：

- 1) 针对催化裂化装置反应再生系统安全知识图谱构建与智能安全分析需求，结合安全知识图谱、异常诊断与安全知识辅助问答三部分内容，提出了催化裂化装置反应再生系统安全知识图谱构建与智能安全分析框架。
- 2) 针对催化裂化装置反应再生系统安全知识的高效组织问题，提出了一种基于非结构化文本的安全知识图谱构建方法。该方法结合基于跨度分类的命名实体识别方法和基于大语言模型的关系三元组抽取方法，实现催化操作规程中安全知识的自动化抽取。此外，从多变量时间序列与文本信息中提取变量因果关联性，构建因果图，从而扩展安全知识图谱，以支持后续智能安全分析。
- 3) 针对反应再生系统传感器数据噪声干扰及多变量耦合特性，提出了一种基于多任务变分自编码器的异常检测方法。通过结合图注意力网络和选择状态空间模型，实现高精度的变量级别异常检测。进而，基于安全知识图谱中的变量因果图与变量异常分数，通过概率寻优分析方法，实现异常的根本原因分析。
- 4) 针对人工异常处置效率低且存在信息过载问题，基于安全知识图谱与大语言模型，通过检索增强生成方法构建安全知识辅助问答系统，实现安全知识的快速查询与基于异常根本原因分析结果的异常处理方案自动化推荐。
- 5) 最后集成所提安全知识图谱与智能安全分析方法，本文开发了催化裂化装置反应再生系统智能安全分析软件。该软件集成了安全知识图谱管理、异常诊断和安全知识辅助问答，以实际系统数据与知识为基础，验证了安全知识图

谱构建及智能安全分析方法在异常监测与处置的有效性。

本文的方法在催化裂化装置反应再生系统的异常工况实验中得到验证。实验结果表明，所提方法融合传感器数据与文本知识，显著提升了异常检测与诊断精度，并为操作人员提供了可行的异常处理方案，从而加速异常处置流程，提高系统安全性。

7.2 研究展望

本文针对催化裂化装置反应再生系统异常工况的特点，提出催化裂化装置反应再生系统安全知识图谱构建与智能安全分析方法。尽管本文所提方法在实验中取得了良好效果，但仍存在一定的局限性。未来研究将围绕以下几个方向进一步深入：

- 1) 处理更复杂的振荡工况：本文的异常检测方法主要针对催化裂化装置反应再生系统的常见异常场景，未来可进一步拓展适用范围，涵盖更复杂的异常工况，并优化现有检测方法，以提升对复杂振荡工况的适应能力。
- 2) 扩展至多工艺系统：催化裂化装置是石油炼化工业的重要组成部分，未来可将本文方法扩展至多工艺系统的智能安全分析，特别是在大型石油炼化厂中，多工艺协同与异常处理是关键挑战。通过跨设备的智能安全分析和跨工艺的知识融合，可提升整个生产系统的安全性与稳定性。
- 3) 考虑时延的因果图构建：本文数据驱动部分采用传递熵算法构建变量因果图，并没有考虑变量间的时延相关性。后续可进一步对变量间的时延相关性进行分析，并结合时延传递熵算法进行因果图构建。
- 4) 深化安全知识图谱与大语言模型的融合：本文通过采用检索增强生成方法将安全知识图谱与大语言模型结合，实现了辅助问答功能。但将知识图谱转换为安全知识文本的过程中，可能会有上下文信息丢失的风险。因此，本研究未来将探索图检索生成增强方法，以实现更有效的安全知识图谱与大语言模型的融合，提升问答系统的准确性。

总体而言，尽管本文方法在一定程度上提升了催化裂化装置反应再生系统的智能安全分析精度，但随着技术发展和工业需求变化，仍需持续优化与创新。未来研究将致力于构建更加精准、高效、可扩展的智能安全分析技术，以进一步保障石油化工行业的安全稳定运行。

致 谢

时光荏苒，岁月葱茏，三年的硕士研究生生活即将画上圆满句号。这三年，我在华中科技大学经历了许多难忘的时刻，收获了无数宝贵的知识和经验。我深感自己的成长与进步，离不开许多人的帮助和支持。在此，我由衷感谢所有帮助过我的人。首先，我必须感谢我的父母。他们对我无条件的支持与鼓励，并给予了我坚定的信心，使我能够无忧无虑地专注于学业与研究。接下来，我要特别感谢我的导师周纯杰老师。在学术探索和人生道路上，周老师不仅是我的引路人，更是我的思想启蒙者。他严谨的学术态度、对研究的深刻见解及无私的知识传授，对我影响深远。此外，我还要感谢实验室的同学们，尤其是刘璐博士、李亚辉博士和张岳博士。在这个学术的小家庭中，他们不仅是我的同行，更是生活中的朋友。在研究项目中，我们相互扶持，共同进步；在日常生活中，我们相互关照，共度时艰。感谢他们在我学术道路上提供的宝贵意见与无私帮助。同时，我也要感谢胡震鹏同学对我的生活和学习提供的协助。他的乐观态度和勤奋精神时常激励着我，让我在面对困难和挑战时，也能保持积极和向上的心态。感谢王润龙、韩汶君、刘云中、刘彦君，我不会忘记你们在我科研遇到困难时给予的鼓励和支持。是你们的支持和陪伴，让我这三年的研究生生活充满了收获和快乐。未来的路上，我会继续努力，不负众望。希望在人生的每一个阶段，都能与你们再次相聚，共创佳绩。

参考文献

- [1] F. Yang, M. Xu, W. Lei, et al. Artificial intelligence methods applied to catalytic cracking processes. *Big Data Mining and Analytics*, 2023, 6(3): 361-380
- [2] W. Tian, S. Wang, S. Sun, et al. Intelligent prediction and early warning of abnormal conditions for fluid catalytic cracking process. *Chemical Engineering Research and Design*, 2022, 181: 304-320
- [3] C. Tang, J. Huang, M. Xu, et al. Attention-based early warning framework for abnormal operating conditions in fluid catalytic cracking units. *Applied Soft Computing*, 2024, 153: 111275
- [4] Z. Zhang, Z. Geng, Y. Han. Graph structure change-based anomaly detection in multi-variate time series of industrial processes. *IEEE Transactions on Industrial Informatics*, 2024, 20(4): 6457-6466
- [5] 刘品逸. 催化裂化分馏系统的厂级振荡检测及根源分析研究: [硕士学位论文]. 华中科技大学, 2023
- [6] Y. Zhang, Z. Hu, Q. Sun, et al. Anomaly diagnosis of catalytic cracking process based on autoencoder and causal model. in: 2024 China Automation Congress (CAC). Qingdao, China: IEEE, 2024. 5014-5019
- [7] S. Cai, L. Zhang, J. Hu. Scale-reasoning based risk propagation analysis: An application to fluid catalytic cracking unit. *Process Safety and Environmental Protection*, 2018, 120: 155-165
- [8] J. Long, L. Ye, H. Peng, et al. Efficient prediction framework for large-scale non-linear petrochemical process based on feature selection and temporal-attention LSTM: Applied to fluid catalytic cracking. *Chemical Engineering Science*, 2025, 301: 120733
- [9] H. Gharahbagheri, S. Imtiaz, F. Khan. Root cause diagnosis of process fault using KPCA and Bayesian network. *Industrial & Engineering Chemistry Research*, 2017, 56(8): 2054-2070
- [10] W. Yue, J. Chai, X. Wan, et al. Root cause analysis for process industry using causal knowledge map under large group environment. *Advanced Engineering Informatics*, 2023, 57: 102057
- [11] A. Alzghoul, B. Backe, M. Löfstrand, et al. Comparing a knowledge-based and a data-driven method in querying data streams for system fault detection: A hydraulic drive system application. *Computers in Industry*, 2014, 65(8): 1126-1135

华中科技大学硕士学位论文

- [12] Q. Sun, Y. Li, Z. Hu, et al. Spatial-temporal dependency based multivariate time series anomaly detection for industrial processes. in: International Conference on Intelligent Computing. Tianjin, China: Springer, 2024. 212-223
 - [13] S. A. A. Taqvi, H. Zabiri, L. D. Tufa, et al. A review on data-driven learning approaches for fault detection and diagnosis in chemical processes. ChemBioEng Reviews, 2021, 8(3): 239-259
 - [14] Z. Duan, H. Xu, Y. Huang, et al. Multivariate time series forecasting with transfer entropy graph. Tsinghua Science and Technology, 2022, 28(1): 141-149
 - [15] A. Ragab, M. El-Koujok, B. Poulin, et al. Fault diagnosis in industrial chemical processes using interpretable patterns based on logical analysis of data. Expert Systems with Applications, 2018, 95: 368-383
 - [16] Z. Huang, W. Xu, K. Yu. Bidirectional LSTM-CRF models for sequence tagging. arXiv preprint arXiv:1508.01991, 2015
 - [17] L. Liu, J. Shang, X. Ren, et al. Empower sequence labeling with task-aware neural language model. in: Proceedings of the AAAI Conference on Artificial Intelligence. New Orleans, USA: AAAI, 2018. 644-651
 - [18] X. Ma, E. Hovy. End-to-end sequence labeling via bi-directional LSTM-CNNs-CRF. in: Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin, Germany: Association for Computational Linguistics, 2016. 1064-1074
 - [19] J. P. Chiu, E. Nichols. Named entity recognition with bidirectional LSTM-CNNs. Transactions of the Association for Computational Linguistics, 2016, 4: 357-370
 - [20] J. Devlin, M.-W. Chang, K. Lee, et al. BERT: Pre-training of deep bidirectional transformers for language understanding. in: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, USA: Association for Computational Linguistics, 2019. 4171-4186
 - [21] C. Sun, Z. Yang. Transfer learning in biomedical named entity recognition: An evaluation of BERT in the PharmaCoNER task. in: Proceedings of the 5th Workshop on BioNLP Open Shared Tasks. Hong Kong, China: Association for Computational Linguistics, 2019. 100-104
 - [22] Z. Yuan, C. Tan, S. Huang, et al. Fusing heterogeneous factors with triaffine mechanism for nested named entity recognition. in: Findings of the Association for Computational Linguistics: ACL 2022. Dublin, Ireland: Association for Computational Linguistics, 2022. 3174-3186
-

华中科技大学硕士学位论文

- [23] X. Li, J. Feng, Y. Meng, et al. A unified MRC framework for named entity recognition. in: Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020. 5849-5859
- [24] Y. Shen, Z. Tan, S. Wu, et al. PromptNER: Prompt locating and typing for named entity recognition. in: Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada: Association for Computational Linguistics, 2023. 12492-12507
- [25] H. Yan, T. Gui, J. Dai, et al. A unified generative framework for various NER subtasks. in: Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021. 5808-5822
- [26] S. Zhang, H. Cheng, J. Gao, et al. Optimizing bi-encoder for named entity recognition via contrastive learning. arXiv preprint arXiv:2208.14565, 2022
- [27] J. Zhou, T. Wang, J. Deng. Corpus construction and entity recognition for the field of industrial robot fault diagnosis. in: Proceedings of the 2021 13th International Conference on Machine Learning and Computing. Shenzhen, China: ACM, 2021. 410-416
- [28] A. Koleva, M. Ringsquandl, M. Buckley, et al. Named entity recognition in industrial tables using tabular language models. in: Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: Industry Track. Abu Dhabi, UAE: Association for Computational Linguistics, 2022. 348-356
- [29] S. Fu, X. Zhao, C. Yang. Data heterogeneous federated learning algorithm for industrial entity extraction. Displays, 2023, 80: 102504
- [30] Z. Wei, J. Su, Y. Wang, et al. A novel cascade binary tagging framework for relational triple extraction. in: Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2019. 1476-1488
- [31] X. Zhao, Y. Deng, M. Yang, et al. A comprehensive survey on relation extraction: Recent advances and new frontiers. ACM Computing Surveys, 2024, 56(11): 1-39
- [32] T. Nayak, N. Majumder, P. Goyal, et al. Deep neural approaches to relation triplets extraction: A comprehensive survey. Cognitive Computation, 2021, 13(5): 1215-1232
- [33] Z. Tan, X. Zhao, W. Wang, et al. Jointly extracting multiple triplets with multilayer translation constraints. in: Proceedings of the AAAI Conference on Artificial Intelligence. Hawaii, USA: AAAI, 2019. 7080-7087

华中科技大学硕士学位论文

- [34] H. Zheng, R. Wen, X. Chen, et al. PRGC: Potential relation and global correspondence based joint relational triple extraction. in: Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021. 6225-6235
- [35] H. Han, J. Wang, X. Wang. A relation-oriented model with global context information for joint extraction of overlapping relations and entities. *Frontiers in Neurorobotics*, 2022, 16: 914705
- [36] Z. Zhang, J. Yang, H. Liu, et al. BTDM: A bi-directional translating decoding model-based relational triple extraction. *Applied Sciences*, 2023, 13(7): 4447
- [37] Z. Wei, J. Su, Y. Wang, et al. A novel hierarchical binary tagging framework for joint extraction of entities and relations. *arXiv preprint arXiv:1909.03227*, 2019
- [38] X. Luo, W. Liu, M. Ma, et al. A bidirectional tree tagging scheme for joint medical relation extraction. in: 2023 International Joint Conference on Neural Networks (IJCNN). Gold Coast, Australia: IEEE, 2023. 1-8
- [39] Z. Ding, W. Huang, J. Liang, et al. Improving recall of large language models: A model collaboration approach for relational triple extraction. *arXiv preprint arXiv:2404.09593*, 2024
- [40] J. Wang. LLM-based fine-tuning data generation for relation triplet extraction with expert ensemble and demonstration selection. in: 2024 IEEE 12th International Conference on Intelligent Systems (IS). Varna, Bulgaria: IEEE, 2024. 1-7
- [41] Y. Zhang, T. Sadler, M. R. Taesiri, et al. Fine-tuning language models for triple extraction with data augmentation. in: Proceedings of the 1st Workshop on Knowledge Graphs and Large Language Models (KaLLM 2024). Bangkok, Thailand: Association for Computational Linguistics, 2024. 116-124
- [42] A. Hogan, E. Blomqvist, M. Cochez, et al. Knowledge graphs. *ACM Computing Surveys*, 2021, 54(4): 1-37
- [43] S. Pandithawatta, S. Ahn, R. Rameezdeen, et al. Development of a knowledge graph for automatic job hazard analysis: The schema. *Sensors*, 2023, 23(8): 3893
- [44] W. Wu, C. Wen, Q. Yuan, et al. Construction and application of knowledge graph for construction accidents based on deep learning. *Engineering, Construction and Architectural Management*, 2025, 32(2): 1097-1121

华中科技大学硕士学位论文

- [45] A. Pedro, A.-T. Pham-Hang, P. T. Nguyen, et al. Data-driven construction safety information sharing system based on linked data, ontologies, and knowledge graph technologies. *International Journal of Environmental Research and Public Health*, 2022, 19(2): 794
 - [46] X. Mei, F. Xu, Z. Zhang, et al. Unsafe behavior identification on construction sites by combining computer vision and knowledge graph-based reasoning. *Engineering, Construction and Architectural Management*, 2024
 - [47] H. Wen. A model of proactive safety based on knowledge graph. *arXiv preprint arXiv:2407.15127*, 2024
 - [48] J. Chen, J. Qian, X. Zhang, et al. Root-KGD: A novel framework for root cause diagnosis based on knowledge graph and industrial data. *arXiv preprint arXiv:2406.13664*, 2024
 - [49] C. Liu, S. Yang. Using text mining to establish knowledge graph from accident/incident reports in risk assessment. *Expert Systems with Applications*, 2022, 207: 117991
 - [50] S. Mao, Y. Zhao, J. Chen, et al. Development of process safety knowledge graph: A case study on delayed coking process. *Computers & Chemical Engineering*, 2020, 143: 107094
 - [51] Z. Wang, B. Zhang, D. Gao. A novel knowledge graph development for industry design: A case study on indirect coal liquefaction process. *Computers in Industry*, 2022, 139: 103647
 - [52] J. Zhang, Y. Li, J. Wu, et al. Constructing a coal mine safety knowledge graph to promote the association and reuse of risk management empirical knowledge. *Sustainability*, 2024, 16(20): 8848
 - [53] Z. Chen, D. Chen, X. Zhang, et al. Learning graph structures with transformer for multivariate time-series anomaly detection in IoT. *IEEE Internet of Things Journal*, 2021, 9(12): 9179-9189
 - [54] K. Hundman, V. Constantinou, C. Laporte, et al. Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding. in: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. London, United Kingdom: Association for Computing Machinery, 2018. 387-395
 - [55] D. Wu, Z. Jiang, X. Xie, et al. LSTM learning with Bayesian and Gaussian processing for anomaly detection in industrial IoT. *IEEE Transactions on Industrial Informatics*, 2019, 16(8): 5244-5253
 - [56] X. Wang, S.-H. Ahn. Real-time prediction and anomaly detection of electrical load in a residential community. *Applied Energy*, 2020, 259: 114145
-

华中科技大学硕士学位论文

- [57] H. D. Nguyen, K. P. Tran, S. Thomassey, et al. Forecasting and anomaly detection approaches using LSTM and LSTM autoencoder techniques with the applications in supply chain management. *International Journal of Information Management*, 2021, 57: 102282
- [58] L. Shen, Z. Yu, Q. Ma, et al. Time series anomaly detection with multiresolution ensemble decoding. in: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vancouver, Canada: AAAI, 2021. 9567-9575
- [59] Y. Zhang, Y. Chen, J. Wang, et al. Unsupervised deep anomaly detection for multi-sensor time-series signals. *IEEE Transactions on Knowledge and Data Engineering*, 2023, 35(2): 2118-2132
- [60] L. Li, J. Yan, H. Wang, et al. Anomaly detection of time series with smoothness-inducing sequential variational auto-encoder. *IEEE Transactions on Neural Networks and Learning Systems*, 2020, 32(3): 1177-1191
- [61] Z. Li, Y. Zhao, Y. Geng, et al. Situation-aware multivariate time series anomaly detection through active learning and contrast VAE-based models in large distributed systems. *IEEE Journal on Selected Areas in Communications*, 2022, 40(9): 2746-2765
- [62] P. Veličković, G. Cucurull, A. Casanova, et al. Graph attention networks. *arXiv preprint arXiv:1710.10903*, 2017
- [63] Z. He, P. Chen, X. Li, et al. A spatiotemporal deep learning approach for unsupervised anomaly detection in cloud systems. *IEEE Transactions on Neural Networks and Learning Systems*, 2020, 34(4): 1705-1719
- [64] J. Audibert, P. Michiardi, F. Guyard, et al. USAD: Unsupervised anomaly detection on multivariate time series. in: *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Online: Association for Computing Machinery, 2020. 3395-3404
- [65] Y. Su, Y. Zhao, C. Niu, et al. Robust anomaly detection for multivariate time series through stochastic recurrent neural network. in: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Anchorage, USA: Association for Computing Machinery, 2019. 2828-2837
- [66] B. Zong, Q. Song, M. R. Min, et al. Deep autoencoding gaussian mixture model for unsupervised anomaly detection. in: *International Conference on Learning Representations*. Vancouver, Canada, 2018
- [67] S. Tuli, G. Casale, N. R. Jennings. TranAD: Deep transformer networks for anomaly detection in multivariate time series data. *arXiv preprint arXiv:2201.07284*, 2022

华中科技大学硕士学位论文

- [68] H. Zhao, Y. Wang, J. Duan, et al. Multivariate time-series anomaly detection via graph attention network. in: 2020 IEEE International Conference on Data Mining (ICDM). Sorrento, Italy: IEEE, 2020. 841-850
- [69] H. Chen, X. Li, W. Liu. Multivariate time series anomaly detection by fusion of deep convolution residual autoencoding reconstruction model and ConvLstm forecasting model. Computers & Security, 2024, 137: 103581
- [70] A. Gu, T. Dao. Mamba: Linear-time sequence modeling with selective state spaces. arXiv preprint arXiv:2312.00752, 2023
- [71] M. Iri, K. Aoki, E. O'Shima, et al. An algorithm for diagnosis of system failures in the chemical process. Computers & Chemical Engineering, 1979, 3(1-4): 489-493
- [72] F. Yang, D. Xiao, S. L. Shah. Signed directed graph-based hierarchical modelling and fault propagation analysis for large-scale systems. IET Control Theory & Applications, 2013, 7(4): 537-550
- [73] 孙秀茹, 闫伟伟, 高雨航. 复合数控机床液压故障诊断专家系统优化设计. 液压气动与密封, 2023, 43(8): 118-121
- [74] S. J. Qin. Data-driven fault detection and diagnosis for complex industrial processes. IFAC Proceedings Volumes, 2009, 42(8): 1115-1125
- [75] L.-F. Deng, J.-G. Wang, J.-R. Su, et al. Root cause diagnosis of plant wide oscillations using kernel Granger causality. in: 2020 IEEE 9th Data Driven Control and Learning Systems Conference (DDCLS). Liuzhou, China: IEEE, 2020. 812-816
- [76] L. Ma, M. Wang, K. Peng. Nonlinear dynamic granger causality analysis framework for root-cause diagnosis of quality-related faults in manufacturing processes. IEEE Transactions on Automation Science and Engineering, 2023
- [77] J. Yu, M. M. Rashid. A novel dynamic bayesian network-based networked process monitoring approach for fault detection, propagation identification, and root cause diagnosis. AIChE Journal, 2013, 59(7): 2348-2365
- [78] K. Zope, T. Singhal, S. H. Nistala, et al. Bayesian network based causal map generation and root cause identification in complex industrial processes. in: Annual Conference of the PHM Society. Online: PHM Society, 2021
- [79] G.-Q. Zhao, J.-G. Wang, Z. Chen, et al. Causal network analysis and root cause detection based on parameter variable sequence transfer entropy. in: 2020 IEEE 9th Data Driven Control and Learning Systems Conference (DDCLS). Liuzhou, China: IEEE, 2020. 783-788

华中科技大学硕士学位论文

- [80] R. Chen, J.-G. Wang, X.-Z. Cai, et al. Fault root diagnosis based on partial symbol transfer entropy. in: 2021 40th Chinese Control Conference (CCC). Shanghai, China: IEEE, 2021. 4603-4607
- [81] S. Duan, C. Zhao, M. Wu. Multiscale partial symbolic transfer entropy for time-delay root cause diagnosis in nonstationary industrial processes. *IEEE Transactions on Industrial Electronics*, 2022, 70(2): 2015-2025
- [82] P. Lewis, E. Perez, A. Piktus, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. in: *Advances in Neural Information Processing Systems*. Online: MIT Press, 2020. 9459-9474
- [83] Z. Dai, X. Wang, P. Ni, et al. Named entity recognition using BERT BiLSTM CRF for Chinese electronic health records. in: 2019 12th International Congress on Image and Signal Processing, Biomedical Engineering and Informatics (CISP-BMEI). Suzhou, China: IEEE, 2019. 1-5
- [84] A. Siffer, P.-A. Fouque, A. Termier, et al. Anomaly detection in streams with extreme value theory. in: *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Halifax, Canada: Association for Computing Machinery, 2017. 1067-1075

附录 1 攻读硕士学位期间取得的研究成果

1. 已经发表和录用的论文

- [1] **Qi Sun**, Yahui Li, Zhenpeng Hu, Chunjie Zhou, Lu Liu. Spatial-Temporal Dependency Based Multivariate Time Series Anomaly Detection for Industrial Processes[C]. *International Conference on Intelligent Computing*, Tianjin, China, August 2024, pp. 212-223. (EI 收录源)
- [2] **Qi Sun**, Yahui Li, Chunjie Zhou, Yu-Chu Tian. Root Cause Analysis for Industrial Process Anomalies through the Integration of Knowledge Graph and Large Language Model[C]. *2024 43rd Chinese Control Conference (CCC)*, Kunming, China, August 2024, pp. 6855-6860. (EI 收录源)
- [3] Yahui Li, **Qi Sun**, Chunjie Zhou, Lu Liu, Yu-Chu Tian. Named Entity Recognition Based on Anchor Span for Manufacturing Text Knowledge Extraction[J]. *Engineering Applications of Artificial Intelligence*. (Regular paper, SCI 收录源, IF=7.5, 在审)
- [4] Zhenpeng Hu, **Qi Sun**, Yue Zhang, Chunjie Zhou, Deshun Cao. Anomaly Detection of the Reaction Regeneration Process in a Catalytic Cracking Unit Based on DS2AE[C]. *2025 44th Chinese Control Conference (CCC)*, Chongqing, China, August 2025. (EI 收录源, 已录用)

2. 国家发明专利

- [1] 周纯杰, 李亚辉, 孙琪, 王昆昆, 何劲东, 浦珺妍. 石油炼化装置的告警辅助处置知识图谱的构建方法及应用 [P], 2024.06.04, 中国, CN118133950A.

3. 软件著作权

- [1] 周纯杰, 孙琪, 李亚辉, 刘璐, 胡震鹏, 王润龙, 刘彦君. 催化裂化装置的安全知识图谱管理软件. 计算机软件著作权 (2025SR0301078), 2025.
- [2] 周纯杰, 孙琪, 李亚辉, 刘璐, 胡震鹏, 王润龙, 刘彦君. 催化裂化装置的实时异常检测软件. 计算机软件著作权 (2025SR0301081), 2025.

附录 2 攻读硕士学位期间参与的科研项目

[1] 面向石油炼化装置的攻击检测及动态安全失效分析仪器. 国家重大科研仪器
研制项目, 项目编号: 62127808, 2022-2026. (在研)